

Sistema Inteligente para la Identificación y Seguimiento de Derechos de los NNA en Situación de Orfandad por Femicidio

Héctor Alberto Morales Martínez, M. en C. Ulises Saldaña Velez, M. en C. Gabriel Hurtado Avilés
Escuela Superior de Cómputo I.P.N. México CDMX
Tel. 5616148167. E-mail: hmozaesml500@alumno.ipn.mx

Resumen—Se presenta el diseño, desarrollo y evaluación de un sistema inteligente orientado a identificar y dar seguimiento de las Niñas, Niños y Adolescentes (NNA) en situación de orfandad derivada de feminicidios en México. El sistema integra una arquitectura de microservicios contenerizada en Docker compuesta por tres módulos principales: (1) un recolector multi-fuente basado en *StealthSession* con emulación de firma TLS/JA3 para evadir contramedidas perimetrales en 45 fuentes RSS y Google News; (2) un clasificador neuro-simbólico escalonado de cuatro capas que combina el modelo Transformer BETO con ajuste fino supervisado (*fine-tuning*) y reglas heurísticas con penalizaciones y bonificaciones aditivas para neutralizar el denominado *efecto péndulo*; y (3) un módulo de agrupamiento semántico basado en BERTopic (UMAP + HDBSCAN + c-TF-IDF) y un investigador profundo (*DeepInvestigator*) accionable bajo demanda que sintetiza fichas de caso estructuradas mediante la API de Gemini Flash. La cascada de deduplicación de cuatro fases (MD5, Jaccard, SimHash y coseno TF-IDF) depuró 213 duplicados, resultando en 634 noticias únicas procesadas. Sobre un conjunto de prueba ciego de 41 noticias etiquetadas con acuerdo inter-anotador $\kappa=0.91$, el clasificador alcanzó F1-Score = 0.85, Recall = 0.95 y tasa de falsos positivos del 30 %, cumpliendo el umbral operativo establecido. Los resultados demuestran que la integración de razonamiento simbólico sobre el componente neuronal es esencial para dominios de alta especificidad semántica como la violencia de género y la protección de la infancia.

Palabras clave — Procesamiento de Lenguaje Natural, Web Scraping, BERT, BERTopic, Clasificación Neuro-Simbólica, Femicidio.

I. INTRODUCCIÓN

México atraviesa una crisis documentada de violencia feminicida, el Secretariado Ejecutivo del Sistema Nacional de Seguridad Pública (SESNSP) registra más de 8 000 víctimas de feminicidio entre 2010 y 2023 [1]. La Red por los Derechos de la Infancia en México (REDIM) estima que al menos 3 500 NNA perdieron a su madre como consecuencia directa de estos crímenes [2]. A pesar de la gravedad de esta cifra no existe a nivel nacional un padrón oficial ni un mecanismo estandarizado que documente el estado de estas víctimas indirectas.

La Convención sobre los Derechos del Niño y la Ley General de los Derechos de Niñas, Niños y Adolescentes (LGDNNA) establecen el principio del *interés superior de la niñez* como eje principal, sin embargo, la ausencia de datos estructurados imposibilita su materialización efectiva [3].

A. Limitaciones del monitoreo manual

La atención de esta invisibilidad estadística recae actualmente sobre organizaciones de la sociedad civil. La metodología actual presenta un cuello de botella operativo puesto

que requiere la revisión manual de fuentes hemerográficas. Con más de 1 200 medios periodísticos digitales activos en el país, el factor humano introduce una latencia que provoca que numerosos casos pasen desapercibidos. Como consecuencia, el talento humano especializado es desviado hacia tareas de recolección de datos en lugar de la intervención directa con las víctimas.

B. Contribución del trabajo

El Trabajo Terminal 2026-A135 propone una solución tecnológica que automatiza el ciclo completo de descubrimiento informativo. A diferencia de trabajos previos basados en expresiones regulares [10] o vectorización TF-IDF estática [11], la arquitectura propuesta combina un modelo Transformer bidireccional con reglas simbólicas de dominio para resolver la ambigüedad semántica inherente al periodismo policial mexicano.

II. METODOLOGÍA

El sistema fue desarrollado bajo un enfoque **evolutivo basado en prototipos** [12], dado la alta incertidumbre tecnológica en dos frentes como lo son las infraestructuras dinámicas de evasión web (WAF, JA3 fingerprinting) y la alta variabilidad e inferencia de los modelos Transformer. Cuatro prototipos sirvieron como entornos de diagnóstico; la iteración final constituyó el estado de producción.

A. Recolección multi-fuente

Los prototipos iniciales utilizaron *BeautifulSoup* sobre peticiones HTTP directas, obteniendo bloqueos HTTP 403 en el 80 % de las fuentes por *TLS/JA3 fingerprinting* [9]. El módulo *StealthSession* resolvía esto mediante la emulación de fingerprint TLS vía *cloudscraper* con hashes JA3 idénticos a Chrome/Windows; con delays log-normales ($\mu=2.5$, $\sigma=0.7$, mediana ≈ 12.2 s) que imitan comportamiento humano; y un *Circuit Breaker* por dominio que detiene las peticiones tras tres fallos consecutivos.

El recolector scrapea 45 feeds RSS nacionales, Google News y fuentes complementarias mediante scraping HTML, procesando ≈ 900 noticias brutas por ciclo. La cascada de deduplicación de cuatro fases (MD5 $\rightarrow$ Jaccard $\rightarrow$ SimHash $\rightarrow$ coseno TF-IDF) elimina un aproximado del 25 % del corpus, entregando al módulo clasificador noticias únicas.

B. Clasificador neuro-simbólico escalonado

El motor de clasificación opera en cuatro capas autónomas y secuenciales. La Fig. 1 ilustra el flujo completo.

Capa 0. Escudo léxico. Filtro de rechazo temprano $O(1)$ mediante *frozenset* de dominios ajenos (deportes, economía, tecnología). Única capa con bloqueo absoluto ($\text{score} = 0$).

Capa 1. Escudo suave. Términos legislativos y estadísticos aplican penalización aditiva $\delta = -0,35$, sin bloquear la noticia. Una noticia con score BETO de 0.72 que menciona “según datos del REDIM” obtiene score ajustado de 0.37 (*Media*).

Capa 2 — Inferencia BETO. BETO (*bert-base-spanish-wwm-cased*) es un Transformer bidireccional con 110 M de parámetros, 12 capas de autoatención y embeddings de 768 dimensiones, preentrenado sobre Wikipedia en español mediante MLM [4]. El *hidden state* del token [CLS] se extrae como representación global normalizada con norma L2. El sistema opera en modo *Finetuned* (prioritario) o *Zero-Shot* con Temperature Scaling factor 5 (fallback) [6].

Capa 3 — Post-filtro heurístico. Inyecta bonificaciones (+0.10 a +0.25) al detectar patrones de orfandad real (quedó al cuidado, menores bajo resguardo, hijos quedaron) y penalizaciones para roles invertidos (menor como agresor). Esta capa nunca produce exclusiones absolutas para noticias *Media*.

El score final acumulado que determina la clasificación de una noticia se expresa formalmente como:

$$S_{\text{final}}(x) = P_{\text{BETO}}(x) + \sum_i \delta_i(x) \quad (1)$$

donde $P_{\text{BETO}}(x) \in [0, 1]$ es la probabilidad de relevancia emitida por el modelo Transformer y $\delta_i(x) \in \mathbb{R}$ son las penalizaciones o bonificaciones aditivas aplicadas por las capas simbólicas 0, 1 y 3 en función del contenido textual de x .

Este diseño neuro-simbólico neutraliza el **efecto péndulo** observado en el Prototipo 3, donde BETO clasificaba erróneamente discursos normativos con scores de hasta 0.81 por correlación superficial de tokens.

C. Agrupamiento Semántico — BERTopic

El pipeline BERTopic (UMAP + HDBSCAN + c-TF-IDF) procesa las 634 noticias deduplicadas sobre embeddings BETO de 768 dimensiones reducidos a 5D por UMAP [5]. Se generaron 15 tópicos semánticos coherentes (casos con intervención del DIF, disputas por custodia, NNA testigos, manifestaciones de colectivos). El porcentaje de outliers se redujo del 81.4 % al 55 % mediante reducción multi-etapa. El Silhouette Score mejoró de 0.23 (K-Means TF-IDF, P2) a una coherencia cualitativa verificable sobre el espacio semántico de 768 dimensiones.

D. Módulo DeepInvestigator

El módulo *DeepInvestigator* se activa bajo demanda desde el dashboard sobre noticias de clasificación *Alta*. Ejecuta cuatro pasos: (1) generación de query de alta especificidad vía Gemini Flash; (2) búsqueda dual en DuckDuckGo HTML y Lite; (3) scraping complementario con *StealthSession*; y (4) síntesis estructurada en JSON con siete campos (*ubicacion*, *victimas*, *nicos_afectados*, *edades*,




Fig. 1. Arquitectura del clasificador neuro-simbólico escalonado de cuatro capas. Las capas simbólicas (0 y 1) modulan la salida neuronal de BETO (Capa 2) mediante penalizaciones y bonificaciones aditivas antes del post-filtro (Capa 3).

situacion_actual, *medios_contacto*, *resumen*). El campo *medios_contacto* retorna el DIF municipal y la Fiscalía competente según la ubicación del caso. Tiempo promedio: **47 segundos por caso**.

El siguiente ejemplo ilustra una ficha de caso representativa generada por Gemini Flash (datos completamente anonimizados):

Listing 1. Ejemplo de ficha JSON generada por DeepInvestigator (anonimizada).

```

{
  "ubicacion": "Municipio de [ANONIMIZADO], Estado de [ANONIMIZADO]",
  "victimas": "Mujer adulta, 32 años",
  "nicos_afectados": 2,
  "edades": ["7 años", "11 años"],
  "situacion_actual": "Menores bajo resguardo provisional"
}

```

```

de familiares maternos; DIF municipal en proceso
de evaluacion de tutela definitiva.",
"medios_contacto": {
  "DIF": "DIF Municipal de [ANONIMIZADO], tel. [OMITIDO]"
  ,
  "Fiscalia": "Fiscalia Especializada en Violencia de
  Genero del Estado de [ANONIMIZADO]"
},
"resumen": "Caso de orfandad derivada de feminicidio.
Dos menores identificados; intervencion institucional
activa. Se recomienda seguimiento prioritario."
}

```

E. Arquitectura de Despliegue

El sistema se despliega mediante orquestación Docker con tres contenedores sobre una red virtual privada (nna-network). La Fig. 2 muestra la arquitectura general. nna-postgres ejecuta PostgreSQL 16-alpine con volumen persistente e índices GIN para búsqueda de texto completo (FTS) en español. nna-analyzer aloja el backend analítico con pesos BETO fine-tuned (≈ 440 MB en caché local). nna-webapp sirve el dashboard Flask y la API REST en el puerto 5000. Los contenedores dependientes aguardan el *healthcheck* de nna-postgres para eliminar condiciones de carrera.




Fig. 2. Arquitectura de microservicios contenerizada. Tres contenedores Docker se comunican sobre la red privada nna-network, garantizando aislamiento de recursos y persistencia de datos ante reinicios del sistema.

III. RESULTADOS

A. Recolección y Deduplicación

En el ciclo de validación final se procesaron ≈ 900 noticias brutas; la cascada eliminó 213 duplicados: 89 por MD5 (10.5 %), 61 por Jaccard (7.2 %), 43 por SimHash (5.1 %) y 20 por coseno TF-IDF (2.4 %), obteniendo **634 noticias únicas**. Esto representa un incremento del 125 % respecto a las 281 noticias del TT-1.

B. Evaluación del Clasificador Escalonado

Para validar el desempeño sobre datos no vistos durante el fine-tuning, se construyó un conjunto de prueba ciego de 43 noticias por muestreo segmentado. Dos anotadores independientes (un docente de la ESCOM y el autor) etiquetaron cada noticia con protocolo binario. El acuerdo inter-anotador fue $\kappa=0.91$ (*casi perfecto* según Landis y Koch [8]); 2 noticias

sin consenso fueron excluidas, dejando $n=41$ para el cálculo de métricas [7].

La TABLA I resume los resultados. El clasificador alcanzó un F1-Score de **0.85**, un Recall de **0.95** y una tasa de falsos positivos del **30 %**, cumpliendo el umbral operativo ($\leq 30\%$). La matriz de confusión arrojó VP = 20, VN = 14, FP = 6, FN = 1; el único falso negativo corresponde a una noticia con redacción ambigua sin mención explícita de víctimas menores.

TABLA I
MÉTRICAS DEL CLASIFICADOR ESCALONADO ($n=41$)

Métrica	Valor
Precisión	0.77
Recall (Sensibilidad)	0.95
F1-Score	0.85
Tasa de Falsos Positivos	30.0 %
κ de Cohen (inter-anotador)	0.91

C. Distribución del Embudo Analítico

El corpus de 634 noticias fue reducido secuencialmente: 409 superaron la Capa 0 (64.5 %), 225 la Capa 1 (35.5 %), 128 la inferencia BETO con score > 0.50 (20.2 %), de los cuales **27 fueron clasificados como Alta relevancia** (4.4 %) y **101 como Media** (15.9 %). Los 27 casos de Alta correspondieron a eventos de orfandad verificables manualmente.

D. Agrupamiento y DeepInvestigator

BERTopic generó 15 tópicos semánticos coherentes sobre las 634 noticias. El DeepInvestigator completó el flujo de investigación sobre 15 noticias de Alta clasificación con tiempo promedio de 47s por caso y generación correcta de fichas con contactos institucionales (DIF municipal, Fiscalía competente). La TABLA II presenta los cinco tópicos de mayor frecuencia identificados por el modelo.

TABLA II
TOP 5 TÓPICOS IDENTIFICADOS POR BERTOPIC

ID	Palabras clave (c-TF-IDF)	Frec.
0	orfandad, hijos, madre, feminicidio, resguardo	41
1	custodia, DIF, abuelos, tutela, menor	28
2	manifestación, colectivos, justicia, marcha	22
3	sentencia, juicio, agresor, carpeta, proceso	19
4	NNA, testigo, presencia, crimen, escena	14

E. Evaluación Comparativa TT-1 / TT-2

La TABLA III consolida el cumplimiento de los objetivos cuantitativos definidos al inicio del TT-2.

TABLA III
COMPARATIVA DE MÉTRICAS TT-1 VS. TT-2

Métrica	TT-1	Meta TT-2	P4 final
Falsos positivos	60 %	≤ 30 %	30.0 % ✓
Fuentes	10 RSS	45 RSS+GNews	45+GN+Stealth ✓
Noticias únicas	281	>500	634 ✓
Motor PLN	RegEx	BETO ft.	BETO Escalonado ✓
Persistencia	CSV	PostgreSQL	PostgreSQL ACID ✓

IV. CONCLUSIONES

Se desarrolló e implementó un sistema de monitoreo inteligente que demuestra la viabilidad de automatizar la identificación de NNA en situación de orfandad por feminicidio a partir de fuentes periodísticas digitales. Las contribuciones técnicas principales son: (i) la arquitectura de clasificación neuro-simbólica escalonada que supera tanto los enfoques puramente léxicos como los modelos Transformer en modo *zero-shot*, y (ii) la cascada de deduplicación multi-algoritmo que garantiza la integridad del corpus. El F1-Score de 0.85 con Recall de 0.95 valida la hipótesis de que la integración de reglas simbólicas de dominio sobre la salida neuronal de BETO es necesaria para dominios de alta especificidad.

A. Trabajo Futuro

Se identifican tres líneas prioritarias: (1) **Active Learning**: incorporar retroalimentación del analista para reentrenar el clasificador de forma incremental; (2) **Reentrenamiento en GPU**: el fine-tuning actual se realizó en CPU con 8 GB RAM; hardware acelerado permitiría explorar modelos de mayor capacidad (RoBERTa-es, mDeBERTa); y (3) **Extensión geográfica**: adaptar el catálogo de fuentes hacia Centroamérica para ampliar el impacto del sistema.

RECONOCIMIENTOS

Los autores agradecen a la Escuela Superior de Cómputo (ESCOM) del Instituto Politécnico Nacional (IPN) por el apoyo institucional brindado durante el desarrollo del Trabajo Terminal 2026-A135, así como a los sinodales y profesores que enriquecieron el proyecto con su orientación técnica y metodológica.

REFERENCIAS

- [1] Secretariado Ejecutivo del Sistema Nacional de Seguridad Pública, "Información sobre violencia contra las mujeres," Gobierno de México, Informe anual, 2023. [En línea]. Disponible en: <https://www.gob.mx/sesnsp>
- [2] Red por los Derechos de la Infancia en México (REDIM), "Infancia y feminicidio en México: impacto en niñas, niños y adolescentes," REDIM, Ciudad de México, Informe técnico, 2022.
- [3] Oficina del Alto Comisionado de las Naciones Unidas para los Derechos Humanos, "Diagnóstico sobre la situación de los derechos humanos en México," ONU-DH México, 2019.
- [4] J. Cañete, G. Chaperon, R. Fuentes, J.-H. Ho, H. Kang, y J. Pérez, "Spanish Pre-trained BERT Model and Evaluation Data," en *Proc. PML4DC at ICLR 2020*, Addis Abeba, Etiopía, 2020.
- [5] M. Grootendorst, "BERTopic: Neural Topic Modeling with a Class-Based TF-IDF Procedure," *arXiv preprint arXiv:2203.05794*, 2022.
- [6] C. Guo, G. Pleiss, Y. Sun, y K. Q. Weinberger, "On Calibration of Modern Neural Networks," en *Proc. 34th Int. Conf. Machine Learning (ICML)*, Sydney, Australia, 2017, pp. 1321–1330.
- [7] J. Cohen, "A Coefficient of Agreement for Nominal Scales," *Educational and Psychological Measurement*, vol. 20, no. 1, pp. 37–46, 1960.
- [8] J. R. Landis y G. G. Koch, "The Measurement of Observer Agreement for Categorical Data," *Biometrics*, vol. 33, no. 1, pp. 159–174, 1977.
- [9] B. Anderson y D. McGrew, "OS Fingerprinting: New Techniques and the Impact on Security Tools," en *Proc. IEEE Security & Privacy Workshops*, San Francisco, CA, EE. UU., 2019, pp. 1–7.
- [10] S. Bird, E. Klein, y E. Loper, *Natural Language Processing with Python*. Sebastopol, CA: O'Reilly Media, 2009.
- [11] T. Joachims, "Text Categorization with Support Vector Machines: Learning with Many Relevant Features," en *Proc. 10th European Conf. Machine Learning (ECML)*, Chemnitz, Alemania, 1998, pp. 137–142.
- [12] R. S. Pressman y B. R. Maxim, *Software Engineering: A Practitioner's Approach*, 8th ed. Nueva York, NY: McGraw-Hill, 2014.