

2026-A135: Sistema Inteligente para la Identificación y Seguimiento de NNA

Documento Técnico Final

Trabajo Terminal II – Prototipo 4

Escuela Superior de Cómputo (ESCOM – IPN)

Comisión de Trabajos Terminales – ESCOM

Borrador Fecha de creación de documento
(para revisión)



1. Introducción	1
1.1. Planteamiento del Problema	1
1.2. Justificación	2
1.2.1. Justificación Social y Operativa	2
1.2.2. Justificación Tecnológica	2
1.3. Objetivos	3
1.3.1. Objetivo General	3
1.3.2. Objetivos Específicos	3
1.4. Evolución y Alcances del Proyecto	3
2. Justificación y Alcance del Proyecto	5
2.1. Justificación Social	5
2.2. Justificación Tecnológica	6
2.3. Justificación Ética y Moral: Protección de la Privacidad de los NNA	6
2.3.1. Principio rector: El interés superior del niño	7
2.3.2. Naturaleza de la información procesada	7
2.3.3. ¿Por qué el sistema no proporciona nombres de NNA?	7
2.3.4. Fortaleza ética del enfoque adoptado	8
2.3.5. Compromiso de privacidad	8
2.4. Alcance del Sistema	8
2.4.1. Alcance funcional	8
2.4.2. Alcance geográfico y temporal	9
2.5. Limitaciones y Exclusiones	9
2.5.1. Exclusiones explícitas del alcance	9
2.5.2. Limitaciones técnicas conocidas	9
2.6. Alineación con el Protocolo 2026-A135	10
3. Marco Teórico	11
3.1. Procesamiento de Lenguaje Natural (PLN) y Modelos de Lenguaje	11
3.1.1. Evolución hacia la Arquitectura Transformer y Mecanismos de Atención	11
3.1.2. BETO: BERT Preentrenado en Español	12

3.1.3. Zero-Shot Classification vs. Fine-Tuning	12
3.2. Clustering y Agrupación Semántica	12
3.2.1. Reducción de Dimensionalidad con UMAP	12
3.2.2. Clustering Basado en Densidad con HDBSCAN	12
3.2.3. Representación de Tópicos con c-TF-IDF	13
3.3. Técnicas de Deduplicación Cross-Site	13
3.3.1. Hashing Exacto (MD5)	13
3.3.2. Similitud de Conjuntos (Índice de Jaccard)	13
3.3.3. Hashing Localmente Sensible (SimHash)	13
3.3.4. Similitud del Coseno sobre Matrices TF-IDF	14
3.4. Web Scraping Dinámico y Evasión	14
3.4.1. Protocolo de Exclusión de Robots y Ética de Extracción	14
3.4.2. Técnicas Avanzadas de Evasión	14
3.5. Persistencia y Búsqueda Textual	15
3.5.1. Bases de Datos Relacionales (PostgreSQL)	15
3.5.2. Full-Text Search (FTS) e Índices Especializados	15
4. Estado del Arte	17
4.1. Sistemas de Monitoreo de Medios Tradicionales	17
4.2. NLP Aplicado a la Detección de Violencia de Género	17
4.3. Herramientas y Esfuerzos Existentes en México	18
4.3.1. Red por los Derechos de la Infancia en México (REDIM)	18
4.3.2. El Mapa de los Feminicidios en México	18
4.3.3. Fundación Futuro con Derechos	18
4.4. Análisis Comparativo y Brecha Identificada (El Factor Diferenciador)	18
5. Metodología de Desarrollo	21
5.1. Metodología de Desarrollo Evolutivo Incremental	21
5.2. Evolución de los Prototipos (P0 al P4)	22
5.2.1. Fase 1: Trabajo Terminal I (Prototipos 0, 1 y 2)	22
5.2.2. Fase 2: Trabajo Terminal II (Prototipos 3 y 4)	22
5.2.3. Stack Tecnológico Comparativo	22
5.3. Arquitectura del Sistema (Visión General)	23
6. Desarrollo del TT1: Antecedentes y Prototipos Iniciales	25
6.1. Prototipo 0: Web Scraping Directo (El Fracaso Documentado)	25
6.2. Prototipo 1: RSS + K-Means (La Línea Base)	26
6.3. Prototipo 2: Triple Fuente y Detección Heurística	26
6.4. Métricas de Desempeño y Limitaciones Identificadas	26
6.5. Conclusiones del TT1 (Motivación Absoluta para el TT2)	27
7. Desarrollo del TT2: Prototipos 3 y 4	29
7.1. Prototipo 3: Migración a la Arquitectura Semántica	29
7.1.1. Evolución del Almacenamiento: De Archivos Planos a Entidades Relacionales	29
7.1.2. El Motor de Detección BETO: Arquitectura de Inferencias	30
7.1.3. Estrategias de Scraping Dinámico y Ofuscación	31
7.2. Prototipo 4: Sistema Neuro-Simbólico y Agrupamiento Global	31
7.2.1. El Gran Filtro: BERTopic como Contexto Macro	31

7.2.2. Lógica Híbrida de Clasificación (El Árbol Inquebrantable)	31
7.2.3. El Dashboard de Visualización y Explotación de Datos	32
8. Resultados y Evaluación	35
8.1. Evaluación de la Recolección (Volumen de Ingesta)	35
8.2. Evaluación de la Detección Semántica (Filtro del Embudo)	35
8.3. Evaluación del Agrupamiento (BERTopic)	36
8.4. Análisis de la Interfaz (UI/UX) e Impacto Operativo	36
9. Conclusiones	37
10. Trabajo Futuro	39
10.1.Extracción de Entidades Nombradas (NER) bajo Principios Éticos	39
10.2.Generación Automática de Reportes (Exportación)	39
10.3.API Pública e Interoperabilidad para Organizaciones Civiles	40
10.4.Despliegue en la Nube (Cloud Architecture) y Escalabilidad	40
10.5.Validación Piloto en Campo y Refinamiento UX/UI	40

Índice de tablas

1. Resumen del proyecto (Project Charter)	VIII
2.1. Distinción entre información procesada y excluida	7
2.2. Correspondencia entre objetivos del protocolo y componentes implementados	10
5.1. Evolución del Stack Tecnológico (TT1 vs TT2)	23

Project Charter

Proyecto:	2026-A135: Sistema Inteligente para la Identificación y Seguimiento de NNA		
Responsable:	Héctor Morales, Desarrollador Principal		
Autoriza:	Comisión de Trabajos Terminales (Academia)		
Background/Contexto:	Miles de NNA quedan en orfandad por feminicidios anualmente; actualmente no existe un sistema centralizado de seguimiento para apoyarlos.		
Beneficios esperados:	Visibilidad del fenómeno, reducción de trabajo manual para ONGs y generación de base de datos histórica mediante NLP.		
Costo estimado:	Proyecto Académico (TT1/TT2)		
Fecha de inicio:	Septiembre 2025	Fecha de término:	Junio 2026
Objetivo:	Sistema automatizado de recolección, análisis NLP y visualización de noticias sobre NNA afectados por feminicidios.		
Entregables Principales			
	SIST-01	Sistema web y pipeline NLP funcional (Contenedores Docker)	
	DOC-01	Documentación Técnica Final (este documento)	
	COD-01	Código fuente completo en repositorio	
Alcance del proyecto			
Incluye:	• Recolección automatizada multi-fuente (RSS, Google Search). • Scraping web dinámico y evasión heurística. • Scoring de 4 ejes mediante Zero-Shot y Fine-Tuning. • Clasificación semántica con modelo BETO. • Agrupación de noticias (clustering) mediante BERTopic. • Deduplicación cross-site avanzada. • Base de datos PostgreSQL y Dashboard interactivo.		
Excluye:	• Identificación y almacenamiento de datos personales reales de NNA. • Intervención social directa o canalización oficial a las autoridades. • Validación pericial de la veracidad de los hechos periodísticos.		
Criterio de éxito:	Detección de notas verdaderas con menos del 5 % de falsos positivos.		
Metodología:	Desarrollo Evolutivo Incremental (Iteraciones de Prototipo P0 a P4)		
Datos de contacto			
Desarrollador:	Héctor Morales (Autor del TT)		
Directores:	Directores asignados del TT		
Organización de Apoyo:	Fundación Futuro con Derechos (Asesoría Social)		
Riesgos y peligros:	• Bloqueos anti-scraping progresivos por parte de los medios periodísticos. • Lentitud en la inferencia del modelo neuronal por falta de hardware GPU.		
Supuestos:	• Los medios noticiosos mantienen un estándar semántico en su redacción de crímenes. • Los servicios de búsqueda como Google News permanecen públicamente consultables.		
Restricciones y dependencias:	• El sistema no puede operar en tiempo real exacto; opera por lotes (cron-jobs). • Restricción absoluta de protección de identidad del menor por normativas vigentes.		

Tabla 1: Resumen del proyecto (Project Charter)

El presente Trabajo Terminal aborda una problemática crítica en la intersección de los derechos humanos, la violencia de género y la ingeniería de datos: la invisibilidad estadística y la ausencia de seguimiento sistemático de las Niñas, Niños y Adolescentes (NNA) en situación de orfandad por feminicidio en México. A través de la conceptualización, diseño y desarrollo de un sistema inteligente de información, esta investigación propone una solución tecnológica para mitigar la dispersión de datos que obstaculiza la labor de las organizaciones de la sociedad civil y las instituciones gubernamentales en la procuración de justicia y la reparación integral del daño.

1.1. Planteamiento del Problema

El feminicidio, tipificado como el asesinato de mujeres por razones de género, constituye una crisis sistémica de seguridad y derechos humanos en el territorio mexicano. De acuerdo con los registros del Secretariado Ejecutivo del Sistema Nacional de Seguridad Pública (SESNSP) y la Secretaría de Gobernación, entre los años 2010 y 2023 se han contabilizado más de 8,000 víctimas de este delito. Sin embargo, el impacto de esta violencia trasciende la pérdida de la víctima directa, generando un daño colateral profundo y frecuentemente indocumentado: la situación de orfandad repentina en la que quedan miles de NNA.

La Red de los Derechos de la Infancia en México (REDIM) estima que existen al menos 3,500 NNA que han perdido a su madre como consecuencia de un feminicidio. Pese a la gravedad de esta cifra, a nivel nacional no existe un padrón oficial, un censo unificado, ni un mecanismo de seguimiento estandarizado que documente el estado y la evolución de estas víctimas indirectas. La Convención sobre los Derechos del Niño y la Ley General de los Derechos de Niñas, Niños y Adolescentes (LGDNNA) establecen el “interés superior de la niñez” como principio rector, garantizando el derecho a la protección, la salud, la educación y la reparación integral. No obstante, la ausencia de datos estructurados imposibilita la materialización de estos derechos.

Actualmente, la información sobre los NNA en situación de orfandad por feminicidio se encuentra críticamente fragmentada. Los datos relevantes sobre la existencia, el estado legal y las condiciones de resguardo de los hijos de una víctima suelen estar dispersos en notas periodísticas de medios locales, comunicados aislados de fiscalías estatales o en los registros internos y fragmentados de diversas organizaciones no gubernamentales. Al carecer de una plataforma que interconecte estos fragmentos informativos, resulta materialmente imposible para las instituciones rastrear qué sucede con los menores tras el evento traumático, impidiendo evaluar si han recibido atención psicológica especializada,



si su continuidad educativa está garantizada o si se han activado los mecanismos legales para la reparación del daño.

Las consecuencias de esta opacidad informativa son multidimensionales. En primer lugar, las organizaciones de la sociedad civil se ven imposibilitadas para dimensionar patrones geográficos o temporales de orfandad que permitan dirigir esfuerzos de intervención. En segundo lugar, las autoridades carecen de la evidencia empírica necesaria para evaluar la eficacia de los programas de apoyo a víctimas indirectas. Finalmente, los familiares extendidos que asumen el cuidado de los menores frecuentemente desconocen las instituciones de apoyo y los derechos legales que amparan a los NNA, dejándolos en un estado de vulnerabilidad institucional prolongada.

1.2. Justificación

1.2.1. Justificación Social y Operativa

La mitigación de la invisibilidad estadística de los NNA huérfanos recae, en gran medida, sobre los hombros de las organizaciones de la sociedad civil. Entidades como la Fundación “Futuro con Derechos” y el proyecto del “Mapa de Feminicidios en México” han asumido la labor de documentar estos casos para brindar acompañamiento legal y psicológico. Sin embargo, la metodología actual subyacente a esta documentación presenta un cuello de botella logístico y operativo severo: la revisión manual, hemerográfica y periodística de fuentes de información.

El proceso de monitoreo manual exige que los analistas y voluntarios de estas organizaciones dediquen decenas de horas semanales a la revisión individual de portales de noticias, buscando menciones colaterales de hijos en las narrativas de notas policiacas o coberturas de feminicidios. Este enfoque analógico es fundamentalmente inviable frente al volumen de información que se genera diariamente en el país. La latencia introducida por el factor humano limita drásticamente la capacidad de procesamiento, provocando que una cantidad incuantificable de casos pasen completamente desapercibidos simplemente porque es imposible auditar todas las fuentes periodísticas nacionales y regionales disponibles de forma concurrente.

Este cuello de botella operativo agota los recursos humanos, técnicos y financieros de las organizaciones, desviando talento especializado (psicólogos, abogados, trabajadores sociales) hacia labores de recolección de datos en lugar de la intervención directa con las víctimas. Por consiguiente, se requiere imperativamente un sistema automatizado que actúe como un embudo de procesamiento inicial: una arquitectura capaz de ingerir cientos de noticias diarias de manera programática, identificar con precisión aquellas que contienen menciones potencialmente relevantes sobre NNA afectados por violencia feminicida, y presentar esta información de manera estructurada. Esto permitirá a las organizaciones reasignar sus recursos hacia el seguimiento de casos concretos y la atención a las víctimas, maximizando su impacto social.

1.2.2. Justificación Tecnológica

Desde una perspectiva de ingeniería en sistemas computacionales, la recolección y estructuración de esta información representa un desafío de alta complejidad debido a la naturaleza no estructurada y volátil de los datos en la web. Durante la primera fase de esta investigación (Trabajo Terminal I), se demostró empíricamente la insuficiencia de métodos de recolección triviales. Las arquitecturas de *web scraping* directo enfrentaron bloqueos persistentes por infraestructuras de mitigación como Cloudflare (errores HTTP 403), mientras que la dependencia exclusiva de canales RSS demostró ser insuficiente para alcanzar una cobertura estadísticamente significativa, recolectando apenas un centenar de noticias en periodos quincenales.

La evolución hacia un modelo híbrido de recolección (combinando sindicación web, interfaces de programación de aplicaciones como Google News API y recolección histórica basada en heurísticas) evidenció la viabilidad de capturar el volumen de datos necesario. No obstante, el desafío tecnológico trasciende la mera adquisición de los documentos; reside en la comprensión semántica de los mismos. La implementación de técnicas de Procesamiento de Lenguaje

Natural (PLN) es fundamental para distinguir una mención relevante de una víctima indirecta frente al ruido estadístico, reportes gubernamentales generales o menciones no relacionadas.

El desarrollo de este sistema justifica la aplicación de arquitecturas de software modernas, procesamiento concurrente, bases de datos relacionales y modelos de aprendizaje automático (vectorización de texto, modelado de tópicos y algoritmos de *clustering* para la deduplicación de eventos periodísticos). Al transformar texto no estructurado en una base de conocimientos consultable, el proyecto no solo provee una herramienta de impacto social inmediato, sino que aporta un caso de estudio robusto sobre la aplicación de la inteligencia artificial para la inteligencia de fuentes abiertas (OSINT) enfocada en derechos humanos.

1.3. Objetivos

1.3.1. Objetivo General

Desarrollar y desplegar una plataforma tecnológica integral y automatizada que recolecte, analice, estructure y persista información sobre Niñas, Niños y Adolescentes (NNA) en situación de orfandad por feminicidios en México, aplicando metodologías avanzadas de *web scraping* y algoritmos de Procesamiento de Lenguaje Natural (PLN) sobre fuentes periodísticas de acceso público.

1.3.2. Objetivos Específicos

- Implementar una arquitectura de recolección de datos distribuida e híbrida que integre canales RSS, APIs de búsqueda indexada y rutinas de *scraping* histórico para garantizar una cobertura exhaustiva de medios periodísticos a nivel nacional y regional.
- Desarrollar y calibrar un motor de análisis semántico y detección de eventos que discrimine con alta precisión las noticias de violencia de género e identifique algorítmicamente las menciones de NNA afectados, minimizando la tasa de falsos positivos frente a reportes puramente estadísticos.
- Diseñar un flujo de procesamiento de lenguaje natural que incorpore normalización lexicológica, vectorización, modelado probabilístico de tópicos y técnicas de *clustering* espacial basado en densidad (DBSCAN) para la consolidación de múltiples reportes mediáticos referentes a un mismo evento fáctico.
- Construir una arquitectura de microservicios que integre una API RESTful y un panel de control interactivo (*dashboard*) que permita a los usuarios finales la consulta eficiente de registros históricos, la visualización de métricas analíticas y la exportación de datos estructurados.

1.4. Evolución y Alcances del Proyecto

El ciclo de desarrollo del sistema está estructurado en dos fases semestrales. La primera fase (Trabajo Terminal I) se centró en la validación de la viabilidad técnica mediante el desarrollo de prototipos iterativos. Esta etapa demostró que la combinación de expresiones regulares complejas, modelos de espacio vectorial (TF-IDF) y técnicas de agrupamiento permite identificar patrones relevantes en el corpus periodístico, reduciendo significativamente la carga de revisión manual.

Sin embargo, los prototipos iniciales delimitaron las restricciones tecnológicas a superar en el presente ciclo (Trabajo Terminal II). Específicamente, el sistema transitó de depender de bases de datos planas (archivos CSV), las cuales impiden el acceso concurrente y limitan la complejidad transaccional, hacia un modelo de persistencia relacional robusto. Asimismo, se identificó la necesidad de superar las limitaciones de la agrupación puramente sintáctica para incorporar

motores de inferencia semántica (como modelos basados en arquitecturas Transformer) que comprendan el contexto del lenguaje periodístico y extraigan de forma automatizada las entidades nombradas, como ubicaciones geográficas y nombres de víctimas.

Estos requerimientos fundamentan el alcance del Trabajo Terminal II, cuyo propósito final es la entrega de un sistema de calidad de producción, altamente escalable y listo para su adopción por parte de organizaciones civiles que exigen herramientas tecnológicas precisas para la defensa de los derechos humanos.



Justificación y Alcance del Proyecto

Este capítulo presenta la justificación social, tecnológica y ética que sustenta el desarrollo del *Sistema Inteligente para la Identificación y Seguimiento de NNA*, así como el alcance del sistema, sus limitaciones y la alineación con el protocolo de Trabajo Terminal 2026-A135.

2.1. Justificación Social

Entre 2010 y 2023, más de 8,000 mujeres fueron víctimas de feminicidio en México, según datos de la Secretaría de Gobernación [?]. Detrás de estas cifras se encuentran miles de niñas, niños y adolescentes (NNA) que quedaron en condición de orfandad. La Red por los Derechos de la Infancia en México (REDIM) estima que al menos 3,500 NNA perdieron a su madre por feminicidio entre 2012 y 2022 [?]; sin embargo, no existe un censo oficial ni un sistema de seguimiento que permita dimensionar con precisión el alcance de esta crisis.

La información sobre los hijos e hijas de las víctimas se encuentra fragmentada y dispersa: puede aparecer en una nota periodística local, en el comunicado de una fiscalía estatal o en los archivos internos de alguna organización civil. Sin un mecanismo que conecte estos fragmentos de información, resulta prácticamente imposible rastrear qué ha sucedido con esos menores: si recibieron atención psicológica, si mantienen acceso a educación, si se les garantizó reparación del daño o si fueron canalizados a instituciones como el Sistema DIF.

Las consecuencias de esta dispersión son directas y cuantificables:

- **Para las organizaciones civiles:** Fundaciones como *Futuro con Derechos* dedican varias horas semanales a revisar manualmente decenas de sitios de noticias buscando casos donde se mencione a hijos de víctimas de feminicidio. Reconocen que muchos casos pasan desapercibidos porque es imposible revisar todas las fuentes disponibles con recursos humanos limitados.
- **Para las autoridades:** Sin datos estructurados ni trazables, las instituciones gubernamentales carecen de información para evaluar la efectividad de sus programas de atención a víctimas indirectas y para diseñar políticas públicas basadas en evidencia.
- **Para las familias:** Los familiares de las víctimas frecuentemente desconocen sus derechos, las instituciones de apoyo disponibles y los mecanismos de reparación del daño. La falta de un sistema de seguimiento dificulta la coordinación interinstitucional.



Un sistema automatizado que actúe como filtro inicial —procesando cientos de noticias diarias, identificando las potencialmente relevantes y presentándolas estructuradas— permite que las organizaciones dediquen su tiempo al seguimiento de casos concretos en lugar de a la búsqueda manual de información.

2.2. Justificación Tecnológica

La revisión manual de medios de comunicación es inviable a escala nacional. México cuenta con cientos de medios digitales —nacionales, estatales y locales— que publican diariamente noticias relacionadas con feminicidios. La cobertura periodística de cada caso varía significativamente: algunos eventos son cubiertos por múltiples medios con redacciones diferentes, mientras que otros aparecen exclusivamente en medios regionales de bajo alcance.

Durante el desarrollo del Trabajo Terminal 1 (TT1), se probaron tres enfoques de recolección que evidenciaron la complejidad técnica del problema:

1. **Scraping directo (Prototipo 0):** Fracasó completamente. Los medios modernos emplean protecciones como Cloudflare, contenido renderizado con JavaScript y bloqueos HTTP 403, haciendo inviable la extracción directa de HTML.
2. **RSS básico (Prototipo 1):** Funcionó parcialmente con 8 fuentes RSS, recolectando aproximadamente 96 noticias en dos semanas. Sin embargo, la cobertura se limitaba a medios nacionales con feeds públicos.
3. **Triple fuente (Prototipo 2):** Combinó 10 RSS, Google News API y scraping histórico, alcanzando 281 noticias únicas. Este enfoque demostró la viabilidad de la recolección multi-fuente, pero mantenía limitaciones en la detección semántica (10 % de falsos positivos con regex).

El TT2 evoluciona estas estrategias mediante la integración de tecnologías de Procesamiento de Lenguaje Natural (PLN) de última generación:

BETO (BERT en español): Modelo de lenguaje preentrenado con 110 millones de parámetros que permite comprender el contexto semántico de las noticias, distinguiendo entre casos concretos de feminicidio con NNA afectados y noticias de legislación, campañas o estadísticas que mencionan las mismas palabras clave.

BERTopic: Sistema de clustering semántico que combina embeddings contextuales (BETO), reducción de dimensionalidad (UMAP) y clustering basado en densidad (HDBSCAN) para agrupar noticias por similitud de significado, no solo de vocabulario.

Deduplicación cross-site: Cascada de cuatro algoritmos (Hash MD5, Jaccard, SimHash, TF-IDF coseno) que elimina automáticamente noticias duplicadas o cuasi-duplicadas provenientes de diferentes medios.

PostgreSQL: Base de datos relacional que reemplaza el almacenamiento en archivos CSV, habilitando consultas complejas, integridad referencial y acceso concurrente.

Estas tecnologías transforman texto no estructurado en datos consultables, permitiendo análisis cuantitativos (tendencias temporales, distribución geográfica) y cualitativos (agrupación temática, seguimiento de casos) que serían imposibles mediante revisión manual.

2.3. Justificación Ética y Moral: Protección de la Privacidad de los NNA

2.3.1. Principio rector: El interés superior del niño

El desarrollo de este sistema se enmarca en un principio ético fundamental: **el interés superior del niño**, consagrado en el artículo 3 de la Convención sobre los Derechos del Niño de las Naciones Unidas [?] y en el artículo 2 de la Ley General de los Derechos de Niñas, Niños y Adolescentes de México [?]. Este principio establece que cualquier acción que involucre a menores de edad debe priorizar su bienestar, protección y dignidad por encima de cualquier otro interés.

En concordancia con este principio, el sistema ha sido diseñado desde su concepción con una restricción deliberada y no negociable: **no identifica ni almacena datos personales de los NNA reales**.

2.3.2. Naturaleza de la información procesada

Es fundamental aclarar la naturaleza de los datos que el sistema procesa y la distinción entre lo que el sistema *identifica* y lo que *no identifica*:


Tabla 2.1: Distinción entre información procesada y excluida

El sistema SÍ identifica	El sistema NO identifica
Noticias que mencionan feminicidios	Nombres reales de los NNA afectados
Menciones genéricas a NNA como víctimas indirectas (ej.: “dejó 3 hijos menores”)	Datos personales de los menores (edad exacta, CURP, domicilio)
Contexto del caso: ubicación geográfica, fecha, instituciones involucradas	Identidad verificada de ningún menor
Nombres de víctimas adultas (cuando aparecen en la nota periodística)	Fotografías ni datos biométricos de NNA
Patrones y tendencias estadísticas	Información no publicada en medios

2.3.3. ¿Por qué el sistema no proporciona nombres de NNA?

La ausencia de nombres e identidades de los NNA en los resultados del sistema **no es una limitación técnica, sino una decisión ética respaldada por un marco normativo y periodístico sólido**:

1. **Los medios de comunicación protegen la identidad de los menores.** El Código de Ética Periodística de la UNESCO y los códigos editoriales de los principales medios mexicanos establecen que la identidad de los NNA víctimas —directas o indirectas— debe ser resguardada. Por esta razón, las notas periodísticas que constituyen la fuente primaria del sistema rara vez incluyen los nombres completos de los menores. En su lugar, utilizan referencias genéricas: “sus tres hijos menores de edad”, “una niña de 5 años”, “los menores quedaron bajo custodia de la abuela”. Esta práctica periodística responsable se refleja necesariamente en los datos que el sistema puede extraer.
2. **La Ley General de los Derechos de Niñas, Niños y Adolescentes (LGDNNA).** El artículo 76 de la LGDNNA prohíbe la difusión de datos personales de NNA que permitan su identificación cuando estos se encuentran en situación de vulnerabilidad. Los NNA que han perdido a su madre por feminicidio se encuentran, por definición, en una de las situaciones de mayor vulnerabilidad contempladas por la ley. Cualquier sistema que pretendiera identificarlos nominalmente estaría en violación directa de esta disposición legal.



3. **El Protocolo de Palermo y la normativa internacional.** Los instrumentos internacionales de protección a la infancia, incluido el Protocolo Facultativo de la Convención sobre los Derechos del Niño, establecen que los Estados deben garantizar la privacidad de los menores víctimas en todos los procedimientos, incluidos los de documentación e investigación. Nuestro sistema respeta este marco al limitarse a identificar *la existencia* de NNA afectados, sin revelar *quiénes son*.
4. **Principio de minimización de datos (RGPD/LFPDPPP).** Siguiendo las mejores prácticas internacionales de protección de datos —reflejadas en el Reglamento General de Protección de Datos de la Unión Europea y en la Ley Federal de Protección de Datos Personales en Posesión de Particulares de México— el sistema recolecta y almacena únicamente los datos estrictamente necesarios para cumplir su propósito: identificar *la existencia de noticias* sobre NNA afectados, no la identidad de los NNA mismos.

2.3.4. Fortaleza ética del enfoque adoptado

Lejos de ser una debilidad, esta restricción constituye una **fortaleza ética fundamental** del sistema:

- **El sistema identifica el fenómeno, no a las personas.** Su valor radica en hacer visible la dimensión de la crisis de orfandad por feminicidio —cuántos casos, dónde, con qué frecuencia— sin comprometer la dignidad ni la privacidad de los menores involucrados.
- **Herramienta de apoyo, no sustituto de intervención.** El sistema está concebido como un instrumento de alerta temprana y documentación que facilita el trabajo de organizaciones especializadas. La intervención social, la verificación de datos y el contacto con las familias corresponden exclusivamente a profesionales capacitados en trabajo social, psicología y derecho, quienes operan bajo protocolos estrictos de confidencialidad.
- **Alineación con IA ética.** El diseño del sistema se adhiere a los principios de Inteligencia Artificial ética establecidos por la OECD [?]: transparencia en el procesamiento, responsabilidad en el uso de datos, y priorización del bienestar humano sobre la capacidad técnica.

2.3.5. Compromiso de privacidad

El equipo de desarrollo establece el siguiente compromiso formal:

El Sistema Inteligente para la Identificación y Seguimiento de NNA se compromete a no recolectar, almacenar, procesar ni difundir datos personales de niñas, niños y adolescentes. Toda la información procesada proviene exclusivamente de fuentes periodísticas públicas, y los resultados del sistema se limitan a identificar la existencia de noticias relevantes, patrones estadísticos y tendencias temporales, sin revelar la identidad de ningún menor de edad.

2.4. Alcance del Sistema

2.4.1. Alcance funcional

El sistema desarrollado abarca las siguientes capacidades, implementadas progresivamente a lo largo de cinco prototipos (P0–P4):

- **Recolección automatizada multi-fuente:** Extracción de noticias desde aproximadamente 45 fuentes RSS, 14 queries de Google News, scraping dinámico de HTML/Sitemap y búsquedas en Google Search con StealthSession.
- **Detección semántica de relevancia:** Clasificación de noticias mediante un scoring de 4 ejes (feminicidio, NNA, caso individual, víctima indirecta) utilizando el modelo BETO (BERT en español) con inferencia por lotes (batch inference) en PyTorch.



- **Deduplicación cross-site:** Eliminación automática de noticias duplicadas o cuasi-duplicadas mediante cascada de 4 algoritmos (Hash MD5, Jaccard, SimHash, TF-IDF coseno).
- **Clustering semántico:** Agrupación de noticias por similitud de significado mediante BERTopic (BETO embeddings + UMAP + HDBSCAN + c-TF-IDF).
- **Almacenamiento relacional:** Persistencia en PostgreSQL con esquema normalizado, Full-Text Search e índices optimizados.
- **Dashboard interactivo:** Interfaz web con autenticación (Argon2id), gestión de fuentes, filtros avanzados, visualización de estadísticas con Chart.js y exportación de datos.
- **Gestión de fuentes:** Módulo para agregar, editar, probar, sondear y activar/desactivar fuentes de noticias directamente desde la interfaz web.

2.4.2. Alcance geográfico y temporal

Geográfico: Cobertura nacional con énfasis en medios mexicanos. Incluye medios nacionales (La Jornada, Proceso, Animal Político, El Universal, Milenio, entre otros), medios especializados en género y derechos humanos (CIMAC Noticias, Luchadoras) y medios regionales (El Sol de Toluca, Diario de Xalapa, Noroeste, entre otros).

Temporal: El sistema procesa noticias desde enero de 2025 hasta la fecha actual (mayo 2026), con capacidad de extensión retrospectiva mediante el módulo de scraping histórico.

2.5. Limitaciones y Exclusiones

2.5.1. Exclusiones explícitas del alcance

El sistema **no** contempla las siguientes funcionalidades:

- No identifica ni almacena nombres ni datos personales de NNA reales (justificación ética detallada en la Sección 2.3).
- No realiza intervención social directa. Es una herramienta de documentación y alerta, no un sistema de gestión de casos.
- No accede a bases de datos gubernamentales cerradas (fiscalías, DIF, registros civiles). Toda la información proviene de fuentes periodísticas públicas.
- No valida la veracidad de las noticias. El sistema asume que las fuentes periodísticas monitoreadas mantienen estándares editoriales mínimos, pero no verifica la exactitud factual de cada nota.
- No implementa Named Entity Recognition (NER) completo con fine-tuning. Esta funcionalidad se identifica como trabajo futuro.

2.5.2. Limitaciones técnicas conocidas

1. **Dependencia de fuentes periodísticas:** La cobertura del sistema está limitada a lo que los medios publican. Feminicidios no cubiertos por la prensa o que ocurren en zonas con escasa cobertura mediática no serán detectados.
2. **Precisión del modelo semántico:** Aunque BETO mejora sustancialmente la detección respecto a los patrones regex del TT1, el modelo de zero-shot classification tiene limitaciones inherentes al no estar fine-tuned específicamente para el dominio. Se estima una tasa de falsos positivos $\leq 5\%$.
3. **Protecciones anti-scraping:** Algunos medios implementan protecciones agresivas (CAPTCHAs, rate limiting estricto, paywalls) que pueden impedir la recolección de sus contenidos.

4. **Latencia en tiempo real:** El sistema opera con ciclos de recolección programados (cada 6–24 horas), no en tiempo real. Existe un desfase entre la publicación de una noticia y su procesamiento.
5. **Idioma:** El sistema está optimizado exclusivamente para noticias en español. Noticias en lenguas indígenas o en inglés no son procesadas.

2.6. Alineación con el Protocolo 2026-A135

El desarrollo del TT2 se alinea con las metas y entregables definidos en el protocolo de registro 2026-A135, aprobado por la Comisión de Trabajos Terminales. La siguiente tabla establece la correspondencia entre los objetivos del protocolo y los componentes implementados:

Tabla 2.2: Correspondencia entre objetivos del protocolo y componentes implementados

Meta del Protocolo	Componente Implementado	Estado
Migrar detección de regex a modelos semánticos	SemanticDetector con BETO (zero-shot + 4 ejes)	✓
Implementar base de datos relacional	PostgreSQL con SQLAlchemy ORM	✓
Ampliar cobertura de fuentes	45+ fuentes RSS + Google Search + scraping dinámico	✓
Implementar clustering semántico	BERTopic (BETO + UMAP + HDBSCAN)	✓
Desarrollar interfaz web completa	Dashboard con autenticación, gestión de fuentes, filtros	✓
Deduplicación avanzada	Cascada de 4 fases (Hash, Jaccard, SimHash, TF-IDF)	✓
Implementar NER completo	Parcial: extracción contextual básica	~

Nota: La implementación de Named Entity Recognition (NER) con fine-tuning de spaCy, originalmente contemplada en el protocolo, se implementó de forma parcial mediante extracción contextual basada en patrones. La versión completa con modelos fine-tuned se identifica como trabajo futuro, justificado por la priorización de la precisión del detector semántico y la estabilización de la arquitectura de producción.

Para comprender a cabalidad la arquitectura neuro-simbólica y los algoritmos implementados en el *Sistema Inteligente para la Identificación y Seguimiento de NNA*, es imperativo establecer el fundamento matemático y conceptual subyacente. Este capítulo detalla las tecnologías habilitadoras que sustentan el flujo de trabajo del sistema, abarcando desde la adquisición automatizada de datos hasta el análisis semántico de última generación.

3.1. Procesamiento de Lenguaje Natural (PLN) y Modelos de Lenguaje

El Procesamiento de Lenguaje Natural (PLN) ha experimentado un cambio de paradigma radical en los últimos años, transitando de enfoques estadísticos clásicos (como TF-IDF y modelos ocultos de Markov) hacia arquitecturas profundas basadas en redes neuronales.

3.1.1. Evolución hacia la Arquitectura Transformer y Mecanismos de Atención

El punto de inflexión contemporáneo en la literatura de PLN es la introducción de la arquitectura *Transformer* [?]. A diferencia de las Redes Neuronales Recurrentes (RNN) y las redes Long Short-Term Memory (LSTM), que procesan las secuencias de texto de manera estrictamente lineal y sufren de desvanecimiento de gradiente en secuencias largas, el Transformer prescinde de la recurrencia. En su lugar, emplea un mecanismo denominado Auto-Atención (*Self-Attention*).

El mecanismo de atención permite al modelo ponderar la relevancia de todas las palabras en una oración simultáneamente al procesar una palabra específica, independientemente de la distancia posicional entre ellas. Matemáticamente, la atención se calcula mediante la función *Scaled Dot-Product Attention*:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (3.1)$$

Donde Q (Queries), K (Keys) y V (Values) son proyecciones lineales de los estados de entrada, y d_k es la dimensión de las claves, utilizada como factor de escalado para evitar regiones de gradientes extremadamente pequeños en la función *softmax* [?].



3.1.2. BETO: BERT Preentrenado en Español

Basado en la arquitectura Transformer, el modelo BERT (*Bidirectional Encoder Representations from Transformers*) revolucionó la inferencia contextual al entrenar representaciones profundas de manera bidireccional conjunta [?]. Para mitigar la barrera del idioma en el análisis de fuentes periodísticas mexicanas, este proyecto adopta BETO [?].

BETO es un modelo BERT base (con 12 capas ocultas, 12 cabezales de atención y 110 millones de parámetros) entrenado exclusivamente sobre un corpus masivo en español, derivado de Wikipedia y el proyecto OPUS. La principal ventaja de BETO radica en su capacidad para codificar texto produciendo *embeddings* (vectores de 768 dimensiones) que capturan la semántica contextual dependiente; es decir, una misma palabra posee un vector distinto dependiendo de las palabras que la rodean.

3.1.3. Zero-Shot Classification vs. Fine-Tuning

Convencionalmente, adaptar un modelo preentrenado a una tarea específica requiere *Fine-Tuning*, un proceso computacionalmente intensivo donde se actualizan los pesos del modelo utilizando un conjunto de datos etiquetado específico del dominio. Sin embargo, dada la escasez de corpus etiquetados en el dominio de la violencia feminicida, este proyecto emplea *Zero-Shot Classification* [?].

La clasificación *Zero-Shot* permite categorizar texto en clases arbitrarias sin entrenamiento explícito previo en dichas clases. Esto se logra reformulando la tarea de clasificación como un problema de Inferencia de Lenguaje Natural (NLI). El modelo evalúa una premisa (el texto a analizar) contra una hipótesis construida dinámicamente (ej. “Este texto trata sobre NNA en orfandad”). Si el modelo infiere que la premisa conlleva lógicamente a la hipótesis (*entailment*), la secuencia se clasifica positivamente sin necesidad de un entrenamiento a medida, dotando al sistema de una alta flexibilidad.

3.2. Clustering y Agrupación Semántica

Para consolidar el vasto volumen de noticias en eventos fácticos discretos y descubrir tópicos emergentes, el sistema emplea BERTopic [?], un algoritmo de modelado de tópicos secuencial altamente modular.

A nivel conceptual y matemático, la arquitectura de BERTopic se desglosa en las siguientes etapas fundamentales:

3.2.1. Reducción de Dimensionalidad con UMAP

Los *embeddings* generados por modelos Transformer (como BETO) residen en espacios de altísima dimensión (768 ejes). Aplicar algoritmos de *clustering* directamente sobre estos espacios resulta ineficaz debido a la “Maldición de la Dimensionalidad”, donde la métrica de distancia pierde significancia. BERTopic soluciona esto utilizando UMAP (*Uniform Manifold Approximation and Projection*) [?].

UMAP se basa en la geometría Riemanniana y la topología algebraica. Construye una aproximación de variedad (*manifold*) topológica difusa de los datos en alta dimensión y, posteriormente, optimiza un espacio de baja dimensión (típicamente 5 dimensiones) para mantener la misma estructura topológica. La función de costo minimizada es la entropía cruzada difusa entre las representaciones topológicas de alta y baja dimensión, garantizando la conservación de estructuras globales y vecindarios locales de manera superior a algoritmos tradicionales como PCA o t-SNE.

3.2.2. Clustering Basado en Densidad con HDBSCAN

Una vez reducido el espacio, se requiere agrupar los documentos. Dado que el volumen de noticias por evento periodístico es altamente asimétrico y ruidoso, algoritmos como K-Means (que asumen clústeres globulares y requieren



especificar la cantidad de centroides) fallan. Por ello, se implementa HDBSCAN (*Hierarchical Density-Based Spatial Clustering of Applications with Noise*) [?].

HDBSCAN transforma el espacio según la distancia de alcanzabilidad mutua (*mutual reachability distance*) para separar regiones escasas, construyendo un árbol de expansión mínima (*Minimum Spanning Tree*). A partir de este, extrae una jerarquía de clústeres y selecciona la partición óptima basándose en la estabilidad topológica de los mismos. Los documentos que no caen en regiones densas son etiquetados heurísticamente como ruido, filtrando noticias irrelevantes.

3.2.3. Representación de Tópicos con c-TF-IDF

Una vez agrupados los documentos, BERTopic extrae la representación del tópico utilizando un TF-IDF modificado basado en clases (c-TF-IDF). En lugar de evaluar la importancia de una palabra por documento, evalúa su importancia por clúster:

$$W_{t,c} = \text{tf}_{t,c} \times \log \left(1 + \frac{A}{\text{tf}_t} \right) \quad (3.2)$$

Donde $\text{tf}_{t,c}$ es la frecuencia del término t concatenado en todos los documentos del clúster c , A es el promedio de palabras por clúster, y tf_t es la frecuencia del término en todos los clústeres. Esto asegura la extracción de palabras clave exclusivas y representativas para cada tópico generado.

3.3. Técnicas de Deduplicación Cross-Site

La dispersión de información conlleva a la redundancia mediática; diferentes agencias periodísticas reportan el mismo evento fáctico. El sistema implementa una cascada de deduplicación para mitigar este ruido, fundamentada en diversas métricas.

3.3.1. Hashing Exacto (MD5)

La primera barrera es la detección de copias bit a bit. Se emplea el algoritmo de digestión de mensajes MD5 (*Message-Digest Algorithm 5*) [?], una función criptográfica de hash unidireccional que toma un texto de longitud arbitraria y retorna un valor hash de 128 bits. Cualquier alteración mínima en la cadena de texto de entrada provocará un efecto avalancha, alterando el hash resultante por completo. Se utiliza para eliminar noticias insertadas en base de datos de manera duplicada de forma computacionalmente trivial.

3.3.2. Similitud de Conjuntos (Índice de Jaccard)

Para evaluar superposiciones de vocabulario exacto a nivel token (como en títulos de noticias), se utiliza el Coeficiente de Jaccard [?]. Define la similitud entre dos conjuntos A y B como la razón entre el tamaño de su intersección y la magnitud de su unión:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|} \quad (3.3)$$

3.3.3. Hashing Localmente Sensible (SimHash)

A diferencia de MD5, el algoritmo SimHash [?] es un hash localmente sensible (*Locality-Sensitive Hashing*). El propósito de SimHash es generar *fingerprints* (huellas digitales) tales que los documentos similares produzcan hashes



con una baja Distancia de Hamming. El algoritmo extrae características del texto (ej. n-gramas), las hashea individualmente en bits y pondera la frecuencia vectorial. Es ideal para detectar documentos casi idénticos (*near-duplicates*) tolerando ediciones menores, alteraciones gramaticales o reescrituras de formato.

3.3.4. Similitud del Coseno sobre Matrices TF-IDF

Para consolidar documentos donde la redacción difiere drásticamente pero el contenido semántico fáctico es el mismo, se implementa la Similitud del Coseno. Los documentos se vectorizan usando TF-IDF clásico, y se calcula el coseno del ángulo entre los dos vectores resultantes:

$$\cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}} \quad (3.4)$$

Un valor cercano a 1 indica que los documentos, dimensionalmente proyectados, son semánticamente paralelos.

3.4. Web Scraping Dinámico y Evasión

La recolección masiva de OSINT requiere interactuar programáticamente con la arquitectura web. La simple extracción de modelos de objetos del documento (DOM parsing) resulta inoperante ante infraestructuras modernas de seguridad perimetral.

3.4.1. Protocolo de Exclusión de Robots y Ética de Extracción

El protocolo `robots.txt` [?] es un estándar *de facto* donde los administradores web declaran explícitamente qué segmentos del servidor están restringidos para los rastreadores automatizados (*crawlers*). El sistema respeta estas directivas para mantener la extracción dentro del marco de la ética hacker y evitar la sobrecarga maliciosa en infraestructuras de terceros.

3.4.2. Técnicas Avanzadas de Evasión

Ante bloqueos sistemáticos (ej. HTTP 403 Forbidden) orquestados por Firewalls de Aplicaciones Web (WAF) como Cloudflare o Akamai, el sistema adopta heurísticas de evasión:

- **Simulación de User-Agents:** Rotación dinámica de cabeceras HTTP que declaran versiones legítimas y recientes de navegadores comerciales de escritorio y móviles, disimulando la firma de la librería de solicitudes en Python.
- **Stealth Sessions y Evasión de Fingerprinting TLS/JA3:** Los WAF modernos examinan los metadatos del saludo TLS (*TLS handshake*) para identificar clientes automatizados. Las *Stealth Sessions* implican forzar parámetros de cifrado (*ciphers*) y extensiones TLS idénticas a las emitidas por navegadores reales [?].
- **Resolución de Rate Limiting:** Implementación de control de concurrencia y mecanismos de *Exponential Backoff*. Ante un código HTTP 429 (*Too Many Requests*), el hilo de extracción suspende su ejecución por un intervalo que aumenta logarítmicamente para disipar la sanción antes de reintentar la conexión.

3.5. Persistencia y Búsqueda Textual

El rendimiento analítico a escala del sistema demanda un soporte de persistencia capaz de operar en arquitecturas concurrentes y resolver búsquedas semánticas sobre millones de tokens en tiempo real.

3.5.1. Bases de Datos Relacionales (PostgreSQL)

El sistema descarta arquitecturas de almacenamiento plano e implementa PostgreSQL, un Sistema de Gestión de Bases de Datos Relacional-Objeto (ORDBMS) que cumple estrictamente con las propiedades ACID (Atomicidad, Consistencia, Aislamiento, Durabilidad) [?]. Garantiza la integridad referencial entre los modelos lógicos de entidades (Medios, Artículos, Clusters y Georreferencias).

3.5.2. Full-Text Search (FTS) e Índices Especializados

Una de las capacidades más robustas de PostgreSQL es su motor nativo de Full-Text Search (FTS). A diferencia del operador LIKE, que impone un escaneo secuencial (*Seq Scan*) evaluando expresiones regulares sobre cada fila, FTS opera preprocesando el texto.

El flujo FTS convierte el texto bruto en un documento *tsvector*, optimizando la cadena mediante *stemming* (eliminación de sufijos, reduciendo la palabra a su raíz lingüística) y remoción de *stopwords*. Las consultas del usuario se transforman paralelamente en formato *tsquery*.

Para dotar al sistema de respuestas en latencias sub-milisegundo, se utilizan índices invertidos generalizados (GIN - *Generalized Inverted Index*) [?]. Un índice GIN asocia cada lexema único de la base de datos con un árbol B (B-Tree) que contiene apuntadores físicos directos a todas las tuplas donde dicho lexema es referenciado, evitando recorrer la tabla completa y posibilitando analíticas operacionales complejas sobre volúmenes masivos de registros periodísticos históricos.



El presente capítulo examina críticamente las plataformas, metodologías y proyectos de investigación contemporáneos orientados a la recolección, sistematización y análisis de datos en el contexto de la violencia de género y sus externalidades. El análisis riguroso de estas aproximaciones permite identificar la brecha tecnológica actual y fundamentar el carácter innovador de la arquitectura neuro-simbólica propuesta en este Trabajo Terminal.

4.1. Sistemas de Monitoreo de Medios Tradicionales

En el ámbito de la inteligencia de fuentes abiertas (OSINT) y el monitoreo mediático comercial, existen plataformas consolidadas con infraestructuras formidables para la ingestión de datos en tiempo real (e.g., Google Alerts, Meltwater, Mention). Estas herramientas operan primordialmente sobre arquitecturas de agregación RSS y rastreadores web de propósito general [?].

No obstante, la debilidad fundamental de estos sistemas radica en su dependencia exclusiva de la coincidencia exacta de cadenas de texto y expresiones regulares (RegEx). Al carecer de capacidades de inferencia semántica, la búsqueda de heurísticas combinadas como “feminicidio” y “NNA” o “menores” produce un volumen estadísticamente inmanejable de ruido informativo y falsos positivos. Por ejemplo, estos sistemas son incapaces de discernir sintácticamente entre un reporte donde el agresor resultó ser menor de edad, una noticia puramente estadística, y un caso fáctico donde un menor quedó en orfandad como víctima indirecta. Esta incapacidad de desambiguación contextual hace que las herramientas tradicionales resulten operativamente ineficaces para el dominio específico de este proyecto.

4.2. NLP Aplicado a la Detección de Violencia de Género

Desde la perspectiva académica, la intersección entre el Procesamiento de Lenguaje Natural (PLN) y la sociología forense ha ganado tracción empírica en la última década. La literatura documenta la transición de modelos de aprendizaje automático superficial (como *Support Vector Machines* o *Random Forests*) hacia arquitecturas de aprendizaje profundo (Deep Learning) para la clasificación de discursos de odio, misoginia en redes sociales y categorización automática de reportes policiales por violencia doméstica [?, ?].

Recientemente, se han implementado modelos basados en Transformers (como RoBERTa y BERT) para extraer relaciones de causalidad en narrativas de violencia armada y feminicidios documentados en la prensa [?]. Sin embargo,



al realizar una revisión bibliográfica exhaustiva, se evidencia una carencia alarmante de investigación computacional enfocada en las víctimas indirectas. La inmensa mayoría de los clasificadores binarios se detienen en la categorización del evento fáctico (feminicidio vs. homicidio culposo), omitiendo por completo la extracción de entidades relacionadas con los NNA afectados.

4.3. Herramientas y Esfuerzos Existentes en México

En la República Mexicana, ante la insuficiencia de datos gubernamentales en tiempo real, la sociedad civil ha asumido el liderazgo en la documentación de la violencia feminicida, desarrollando iniciativas fundamentales que, si bien son invaluable, presentan severas limitaciones de escalabilidad computacional.

4.3.1. Red por los Derechos de la Infancia en México (REDIM)

La REDIM es la entidad sociopolítica más prominente en la articulación de datos macroeconómicos y demográficos sobre la niñez mexicana. Sus informes sobre las infancias vulneradas son fundamentales para el diseño de políticas públicas [?]. No obstante, a nivel metodológico, la organización depende fuertemente de la agregación estadística derivada de solicitudes formales de transparencia, bases de datos gubernamentales frecuentemente desfasadas o censos esporádicos. En consecuencia, REDIM carece de una plataforma tecnológica de trazabilidad *per-caso* que opere en tiempo real mediante ingestión automatizada de medios de comunicación masiva.

4.3.2. El Mapa de los Feminicidios en México

El proyecto cartográfico desarrollado por la investigadora María Salguero constituye un esfuerzo pionero e históricamente vital para la visibilización geográfica de la crisis [?]. El sistema geolocaliza y documenta variables sociodemográficas complejas. Sin embargo, su principal cuello de botella es arquitectónico: la ingesta, lectura, extracción de características y captura en base de datos de cada caso reportado en prensa obedece a un flujo de trabajo predominantemente manual y artesanal. Esta dependencia absoluta de la curaduría humana impide la escalabilidad de la herramienta e imposibilita el análisis retrospectivo masivo de fuentes hemerográficas a velocidad computacional.

4.3.3. Fundación Futuro con Derechos

Organizaciones civiles dedicadas a la intervención directa, como la Fundación Futuro con Derechos, ilustran el problema operativo en su nivel más granular. En su intento por identificar casos emergentes de orfandad para ofrecer resguardo institucional o asesoría legal expedita, el personal de estas organizaciones invierte rutinariamente decenas de horas-hombre semanales realizando búsquedas manuales exhaustivas en portales de noticias [?]. Este proceso es no determinista, propenso a sesgos de fatiga y económicamente insostenible para asociaciones sin fines de lucro.

4.4. Análisis Comparativo y Brecha Identificada (El Factor Diferenciador)

El análisis del estado actual del arte revela una brecha tecnológica insalvable bajo los paradigmas vigentes: **la desconexión entre la recolección masiva de datos no estructurados y la comprensión semántica profunda de las víctimas colaterales**. Las herramientas comerciales recolectan sin comprender, mientras que los esfuerzos civiles comprenden profundamente pero no logran recolectar ni escalar la información de forma automatizada.

La aportación fundamental de este Trabajo Terminal yace precisamente en la clausura de esta brecha. El sistema propuesto no es un simple buscador de palabras clave ni un mapa de captura manual. Su innovación radica en la



orquestración integral de un *pipeline* automatizado que suprime la intervención humana en las etapas de descubrimiento y filtrado:

1. **Recolección:** Ingesta concurrente y evasiva de fuentes RSS y motores de búsqueda.
2. **Deduplicación Cross-Site:** Colapso de redundancia mediática mediante hashing geométrico y algebraico.
3. **Agrupación Temática:** Modelado latente no supervisado mediante reducción topológica de dimensionalidad y clústering de densidad (BERTopic).
4. **Clasificación Semántica:** Inferencia computacional del contexto exacto de orfandad utilizando modelos fundacionales de atención profunda en español (BETO).

En suma, no existe en la literatura actual, ni en el ecosistema civil mexicano, una herramienta de software que ejecute este ciclo completo (recolección, limpieza, deduplicación y clasificación neuro-simbólica) de forma unificada y específicamente calibrada para el problema social de los NNA víctimas indirectas de feminicidio. Este proyecto trasciende la estadística descriptiva para instaurar una plataforma de inteligencia prospectiva y de respuesta rápida.



El presente capítulo detalla el marco metodológico utilizado para la concepción, ingeniería y despliegue del *Sistema Inteligente para la Identificación y Seguimiento de NNA*. Debido a la alta complejidad algorítmica y la inherente incertidumbre tecnológica del proyecto, se adoptó un enfoque estructurado pero flexible que garantizara la convergencia hacia una solución óptima y escalable.

5.1. Metodología de Desarrollo Evolutivo Incremental

Para la construcción de la arquitectura de *software*, se seleccionó el **Modelo de Desarrollo Evolutivo Incremental basado en Prototipos**. Esta decisión técnica se fundamenta en dos desafíos críticos identificados desde la fase de concepción del proyecto:

1. **Incertidumbre en la Ingesta de Datos:** El ecosistema web actual cuenta con infraestructuras de seguridad (*Firewalls* de Aplicaciones Web, bloqueos anti-scraping, variabilidad de esquemas DOM) que cambian impredeciblemente. Era imposible predecir qué mecanismos de recolección tendrían éxito sin antes desplegarlos en entornos reales.
2. **Experimentación Algorítmica (IA):** La transición de clasificadores sintácticos rígidos (Expresiones Regulares) hacia modelos fundacionales de Procesamiento de Lenguaje Natural (BETO) requería calibración estocástica, medición de inferencias y ajuste de hiperparámetros.

El modelo evolutivo incremental mitiga estos riesgos al dividir el desarrollo en iteraciones cíclicas y rápidas, donde cada ciclo produce un prototipo funcional que refina o expande las capacidades del anterior gracias a una retroalimentación constante empírica. Cada iteración consta de cuatro fases estrictas:

- **Análisis:** Definición de requerimientos del ciclo (e.g., mitigar falsos positivos).
- **Diseño:** Arquitectura de los algoritmos (e.g., introducir *Zero-Shot Classification*).
- **Implementación:** Codificación del módulo e integración en el ecosistema.
- **Evaluación:** Pruebas de integración, validación de falsos positivos y medición de rendimiento (*benchmarking*) que dictan las mejoras del siguiente ciclo.



5.2. Evolución de los Prototipos (P0 al P4)

El ciclo de vida del proyecto se desplegó orgánicamente a lo largo de dos semestres académicos (Fases TT1 y TT2), materializándose a través de la construcción progresiva de cinco prototipos funcionales.

5.2.1. Fase 1: Trabajo Terminal I (Prototipos 0, 1 y 2)

La primera fase se centró en probar la viabilidad fáctica de la extracción de información y la mitigación rudimentaria de ruido sintáctico.

- **Prototipo 0 (P0): Pruebas de Concepto y Fracaso Rápido.** Iteración focalizada en web scraping profundo utilizando selectores de HTML. Se determinó su inviabilidad inmediata debido a bloqueos generalizados por *Cloudflare* (HTTP 403) y *Timeouts*.
- **Prototipo 1 (P1): Recolección Pasiva.** Transición hacia la ingesta de *feeds* RSS de diez medios periodísticos clave y exportación de hallazgos a formato plano (CSV). Proveyó el primer conjunto de datos real para análisis.
- **Prototipo 2 (P2): Agrupamiento Estadístico.** Introdujo algoritmos de NLP tradicional, empleando un clasificador de Expresiones Regulares (RegEx) altamente condicionado para la detección de NNA, vectorización TF-IDF y algoritmos de *clustering* básicos. Reveló el “techo semántico”: RegEx no comprende el contexto, elevando dramáticamente los falsos positivos en narrativas complejas.

5.2.2. Fase 2: Trabajo Terminal II (Prototipos 3 y 4)

Ante las limitaciones heurísticas y operativas expuestas en TT1, la segunda fase reestructuró la arquitectura hacia un paradigma neuro-simbólico de nivel producción.

- **Prototipo 3 (P3): Inferencia Semántica y Persistencia Relacional.** Se abandonaron las heurísticas rígidas (RegEx) para migrar a una arquitectura semántica profunda basada en **BETO** (Arquitectura Transformer) procesado mediante PyTorch. Adicionalmente, el almacenamiento en CSV mutó hacia **PostgreSQL**, solventando la falta de integridad referencial y permitiendo la deduplicación transaccional masiva (*cross-site deduplication*).
- **Prototipo 4 (P4): Agrupación Topológica y Despliegue Visual (Versión Final).** Se consolidó el *pipeline* implementando **BERTopic** (UMAP + HDBSCAN) para la extracción de tópicos subyacentes. Se culminó la interfaz de interacción, exponiendo una API REST robusta que alimenta un *Dashboard Web* interactivo e institucional, proporcionando la herramienta visual definitiva para los usuarios finales.

5.2.3. Stack Tecnológico Comparativo

La maduración iterativa forzó una refactorización severa de las dependencias de *software*. La Tabla 5.1 esquematiza la divergencia tecnológica y el incremento de complejidad arquitectónica entre el final de la Fase TT1 y la consolidación de la Fase TT2.



Tabla 5.1: Evolución del Stack Tecnológico (TT1 vs TT2)

Capa Arquitectónica	Trabajo Terminal 1 (P2)	Trabajo Terminal 2 (P4)
Lenguaje Base	Python 3.10	Python 3.11
Persistencia de Datos	Archivos planos granulares (.csv) y manipulación local con <i>Pandas</i>	Motor RDBMS PostgreSQL con índices invertidos para FTS (<i>Full-Text Search</i>)
Clasificación NLP	Patrones de exclusión sintáctica explícita (<i>RegEx</i>) y tokenización <i>NLTK</i>	Modelo pre-entrenado <i>BETO</i> , <i>Zero-Shot Classification</i> y Tensores vía <i>PyTorch</i>
Agrupamiento Semántico	Vectorización <i>TF-IDF</i> y <i>Clustering</i> de densidad elemental (<i>DBSCAN</i>)	<i>BERTopic</i> : Reducción de Dimensionalidad Topológica (<i>UMAP</i>) y <i>HDBSCAN</i>
Gestión de Duplicados	Deduplicación estricta por URLs idénticas (<i>Set de Enlaces</i>)	Algoritmos tolerantes a fallos (<i>SimHash</i> , Distancia Coseno <i>TF-IDF</i>)
Despliegue e Interfaz	Scripts por consola (CLI) dependientes del desarrollador	Microservicios contenerizados (<i>Docker</i>), Servidor <i>Flask</i> REST y <i>Dashboard</i> HTML5

5.3. Arquitectura del Sistema (Visión General)

La culminación de este modelo metodológico (Prototipo 4) es un ecosistema distribuido regido por el principio de separación de responsabilidades (*Separation of Concerns*). A nivel conceptual, el *pipeline* neuro-simbólico fluye a través de cuatro módulos orquestados que interactúan secuencialmente:

- Módulo Colector (Ingesta de Datos):** Rutinas asíncronas encargadas de escanear canales RSS y motores indexados para extraer el corpus crudo en lenguaje natural, burlando bloqueos mediante sesiones ofuscadas (*Stealth Sessions*).
- Módulo de Deduplicación Cross-Site:** Filtro algorítmico geométrico (*SimHash*, *Jaccard*) que confronta el texto crudo entrante contra la base de datos viva, purgando las copias exactas y las reescrituras de paráfrasis periodísticas antes de que consuman ciclos costosos de cómputo GPU/CPU.
- Motor de Inferencia Semántica y Agrupación (Analizador):** El núcleo computacional. Mapea cada artículo depurado mediante la inferencia de **BETO** para discriminar positivamente los escenarios de orfandad por feminicidio. Posteriormente, somete los artículos aprobados al agrupador topológico **BERTopic** para encontrar la correlación entre eventos distintos sin supervisión humana.
- Capa de Persistencia y Tablero Visual (Dashboard):** Todos los registros validados, junto con sus tópicos y nivel de prioridad algorítmica, son depositados transaccionalmente en la base de datos relacional. Esta información es servida inmediatamente vía *endpoints* HTTP a un tablero analítico, donde los tomadores de decisiones pueden auditar las noticias, visualizar clústeres interactivos y gestionar respuestas fácticas.



Desarrollo del TT1: Antecedentes y Prototipos Iniciales

El presente capítulo constituye un análisis retrospectivo y profundamente autocrítico del trabajo de ingeniería de *software* realizado durante el primer semestre del proyecto (Trabajo Terminal I). El desarrollo se orquestó a través de tres iteraciones fundacionales (P0, P1 y P2). A continuación, se documentan empíricamente los éxitos parciales obtenidos, los fracasos arquitectónicos frente a barreras de seguridad perimetral, y las limitaciones algorítmicas insoslayables que fungieron como el catalizador insustituible para la evolución hacia la arquitectura neuro-simbólica desplegada en el Trabajo Terminal II.

6.1. Prototipo 0: Web Scraping Directo (El Fracaso Documentado)

La aproximación arquitectónica inicial (P0) suponía ingenuamente que la extracción masiva de texto periodístico podía lograrse mediante un ciclo iterativo de peticiones HTTP estándar acoplado a un análisis estático del Modelo de Objetos del Documento (DOM) utilizando librerías de *parsing* como BeautifulSoup.

Esta hipótesis resultó ser un fracaso ingenieril de documentación crítica frente a la realidad del ecosistema web moderno. Al someter el prototipo a pruebas contra portales informativos de alto tráfico en México, la ingesta de datos colapsó casi inmediatamente. Los sistemas de recolección se toparon de frente con *Firewalls* de Aplicaciones Web (WAF) de grado empresarial, tales como Cloudflare y Akamai. Estos WAFs no operan mediante simples listas negras de direcciones IP, sino que emplean técnicas avanzadas de *fingerprinting* de clientes, analizando la asimetría en el saludo criptográfico (*TLS/JA3 fingerprinting*) y exigiendo la resolución de desafíos *JavaScript* computacionalmente costosos para validar la naturaleza humana del cliente. Ante la incapacidad del prototipo para emular un navegador legítimo, el WAF denegó sistemáticamente el acceso, retornando persistentes códigos HTTP 403 Forbidden.

De manera paralela, las pocas extracciones exitosas evidenciaron una segunda vulnerabilidad insuperable: la volatilidad de las interfaces de usuario. Los portales modernos de noticias están contruidos sobre *frameworks* reactivos (como React.js o Vue.js) que generan el DOM dinámicamente. Las etiquetas HTML, los identificadores de contenedores (`<div>`) y los nombres de las clases CSS mutan a diario por motivos de ofuscación o despliegue continuo (CI/CD). Esta inestabilidad estructural rompió incesantemente los *scripts* de extracción diseñados paramétricamente, demostrando categóricamente que el *web scraping* frontal y estático es una metodología inviable y computacionalmente insostenible para monitorear un ecosistema de fuentes abiertas heterogéneas a largo plazo.



6.2. Prototipo 1: RSS + K-Means (La Línea Base)

Para evadir la barrera insalvable de los WAFs y la inestabilidad del DOM, la arquitectura del Prototipo 1 (P1) pivotó hacia un paradigma de recolección pasiva. Se adoptó la ingestión estandarizada mediante canales de Sindicación Realmente Simple (RSS) legítimamente expuestos por 8 medios periodísticos nacionales. Esto garantizó un flujo de datos constante, inherentemente estructurado en formato XML, y completamente exento de bloqueos de infraestructura, permitiendo recolectar los primeros lotes estables de noticias.

Para otorgar valor analítico a este *corpus* crudo, se procedió a vectorizar el texto utilizando la métrica de Frecuencia de Término – Frecuencia Inversa de Documento (TF-IDF) clásica, alimentando posteriormente al algoritmo de agrupamiento particional *K-Means*. Aunque esta iteración logró establecer la línea base (*baseline*) del proyecto, la calidad del *clustering* fue deficiente.

La vectorización TF-IDF sufre de la “maldición de la dimensionalidad”; crea matrices dispersas (*sparse matrices*) donde cada palabra única es una dimensión ortogonal, asumiendo erróneamente que palabras diferentes no tienen relación semántica (ej. “asesinato” y “homicidio” son vistas como dimensiones inconexas). Al introducir estos tensores esféricos de alta dimensión en *K-Means*, el algoritmo fue incapaz de converger lógicamente. *K-Means* fuerza geométricamente a que todas las noticias pertenezcan a uno de los K centroides predefinidos, asumiendo varianzas isotrópicas. En el periodismo, donde un evento trágico puede generar docenas de notas y otro evento solo una, la estructura de los datos no es esférica ni uniforme, sino densa y asimétrica. Esto provocó agrupaciones “sucias”, donde noticias de economía terminaban forzadas en *clusters* de violencia de género meramente por el ruido estadístico de conectores y determinantes compartidos, restando toda validez metodológica a la agrupación.

6.3. Prototipo 2: Triple Fuente y Detección Heurística

El Prototipo 2 (P2) representó el pináculo del desarrollo durante el cierre del TT1. La recolección se sofisticó transicionando hacia una arquitectura de “Triple Fuente”. Se integraron consultas automatizadas adaptativas contra la API de Google News y *scripts* de recuperación histórica, expandiendo masivamente el espectro de captura más allá de la limitada cobertura temporal de los canales RSS.

La innovación central de P2 fue la delegación de la clasificación de relevancia a un módulo heurístico denominado *FeminicideDetector*. Este componente operaba sobre un árbol de decisión cimentado en diccionarios léxicos exhaustivos y complejas reglas de Expresiones Regulares (RegEx). El algoritmo evaluaba la proximidad de términos de violencia (*feminicidio*, *homicidio*, *hallada sin vida*) con términos de minoría de edad (*hijo*, *hija*, *orfandad*, *menor*), asignando penalizaciones o bonificaciones ponderadas para generar un *score* de pertinencia. Simultáneamente, el ineficiente *K-Means* fue sustituido por *DBSCAN*, un algoritmo de agrupamiento basado en densidad que permitió identificar grupos temáticos de forma orgánica, desechando automáticamente las noticias periféricas sin forzarlas a pertenecer a un clúster fáctico.

6.4. Métricas de Desempeño y Limitaciones Identificadas

Al someter la arquitectura P2 a un ciclo de estrés en un entorno de producción controlado de dos semanas, se obtuvieron las siguientes métricas cuantificables, conformando el desempeño base del sistema:

- **Volumen de Ingesta:** ~281 artículos periodísticos únicos depurados.
- **Precisión Heurística (Recall):** ~52 noticias identificadas algorítmicamente y marcadas con relevancia “Alta.” “Media”.
- **Tasa de Falsos Positivos:** ~10 % tras un proceso de validación cruzada y auditoría manual.

Si bien se documentó un avance superlativo frente a los prototipos anteriores, una tasa de error residual del 10 % constituye un margen algorítmicamente inaceptable cuando el objetivo del *software* es el monitoreo sensible de derechos humanos e infancias vulneradas.

6.5. Conclusiones del TT1 (Motivación Absoluta para el TT2)

El cierre académico del Trabajo Terminal I culminó con una deducción irrefutable: la arquitectura del Prototipo 2 había alcanzado su límite asintótico de optimización. Las heurísticas basadas en reglas eran insuficientes para construir una herramienta de grado institucional.

El análisis forense profundo de la tasa de falsos positivos dejó al descubierto la deficiencia estructural de las Expresiones Regulares: **la ceguera sintáctica absoluta frente a la semántica del lenguaje natural**. Un modelo RegEx simplemente busca la concurrencia espacial de los caracteres, pero es incapaz de abstraer el sujeto, verbo y predicado de una oración. Esto generó escenarios de falla sistémica altamente perjudiciales. Por ejemplo:

1. **El Agresor Menor de Edad:** Ante un titular como *“Un menor infractor fue detenido por cometer feminicidio”*, el modelo RegEx detectaba los tokens “menor” y “feminicidio” muy próximos entre sí, detonando erróneamente la alerta de un NNA en estado de orfandad, cuando en realidad el menor era el perpetrador del delito.
2. **La Víctima Directa Menor de Edad:** Frente a crónicas reportando que *“Una menor de 14 años fue víctima directa de feminicidio”*, el sistema sumaba un “falso positivo de orfandad”, siendo incapaz de discernir que la tragedia recaía directamente sobre la menor, y no como un daño colateral hacia la descendencia de una víctima adulta.
3. **Ruido Estadístico Gubernamental:** Notas periodísticas que citaban *“La entidad concentra 10 feminicidios mensuales, dejando 5 huérfanos en promedio”*, disparaban las alarmas con prioridad máxima al encontrar todos los términos detonantes en un solo párrafo, mezclando reportes macroeconómicos con verdaderas urgencias fácticas emergentes.

Sumado a la incapacidad cognitiva del analizador de texto, la persistencia de los datos presentaba un serio cuello de botella. El almacenamiento dependía exclusivamente de archivos planos (CSV). La lectura, escritura y vectorización concurrente “a vuelo” de estos archivos consumía gigabytes de memoria RAM, volviendo prohibitivamente lenta la carga del tablero interactivo y eliminando cualquier posibilidad de realizar búsquedas transaccionales complejas (*queries*).

Estas fronteras operativas representaron la motivación técnica absoluta para la segunda fase del proyecto. El Trabajo Terminal II nació bajo la directriz innegociable de desechar la inferencia sintáctica en favor de modelos de inteligencia artificial neuro-simbólicos de atención profunda (BETO) capaces de abstraer la intencionalidad del lenguaje, y la migración total de la persistencia plana hacia motores relacionales transaccionales (PostgreSQL).





Desarrollo del TT2: Prototipos 3 y 4

El presente capítulo vertebra el núcleo ingenieril y arquitectónico del Trabajo Terminal II. Tras haber documentado exhaustivamente las limitaciones operativas, algorítmicas y de persistencia inherentes a los prototipos preliminares, esta sección desglosa analíticamente la conceptualización, diseño, codificación y despliegue de los Prototipos 3 y 4. Estos artefactos representan la cristalización del protocolo de registro 2026-A135, materializando la transición definitiva de un sistema sintáctico-estático hacia una plataforma neuro-simbólica robusta, tolerante a fallos e impulsada por modelos fundacionales de Procesamiento de Lenguaje Natural (NLP).

7.1. Prototipo 3: Migración a la Arquitectura Semántica

El diseño del Prototipo 3 fue regido por el imperativo absoluto de erradicar la ceguera contextual del sistema. Para lograr este cometido, fue indispensable refactorizar el código base desde sus cimientos, comenzando por la capa de persistencia de datos hasta culminar con el motor de inferencia neuronal.

7.1.1. Evolución del Almacenamiento: De Archivos Planos a Entidades Relacionales

Durante el primer semestre (TT1), la capa de datos operaba de manera efímera y rudimentaria. El *corpus* textual extraído se volcaba incondicionalmente sobre archivos separados por comas (CSV). La indexación, transformación y vectorización matemática recaía enteramente en el uso de estructuras en memoria RAM a través de *DataFrames* de Pandas. Si bien este paradigma es estandarizado en la experimentación inicial de ciencia de datos, en un entorno de producción transaccional generaba una penalización asintótica en el rendimiento temporal: a medida que el número de noticias crecía, la complejidad computacional para la simple lectura y cruce de datos ($O(n^2)$ en el peor de los casos para búsquedas no indexadas) saturaba la memoria del servidor.

Además, los archivos planos carecen intrínsecamente de las propiedades ACID (*Atomicity, Consistency, Isolation, Durability*). La ausencia total de integridad referencial imposibilitaba trazar relaciones complejas bidireccionales, como vincular de forma segura y consistente un clúster semántico con los artículos individuales que lo conforman, o gestionar el estado de revisión manual sin el riesgo inherente de corrupción por escrituras concurrentes (*race conditions*).

Para solventar esta falla sistémica, en el Prototipo 3 se diseñó y desplegó una capa de base de datos relacional altamente normalizada utilizando PostgreSQL 16. La orquestación de la base de datos se maneja a través del patrón



arquitectónico *Object-Relational Mapping* (ORM) implementado con SQLAlchemy. Este cambio paradigmático liberó a los procesos de Python de la pesada carga del filtrado de datos. Ahora, el sistema delega la búsqueda transaccional masiva al motor relacional, aprovechando la inserción de índices invertidos especializados (*GIN Indexing*) para las capacidades nativas de *Full-Text Search* de PostgreSQL. Las búsquedas de subcadenas o cruces de llaves foráneas entre las tablas noticias, detecciones y clusters se ejecutan en tiempos logarítmicos ($O(\log n)$), dotando al ecosistema de una tolerancia a concurrencia indispensable para un colector asíncrono.

7.1.2. El Motor de Detección BETO: Arquitectura de Inferencias

El componente lógico responsable de dotar de comprensión.^{al} sistema reside en el módulo `semantic_detector.py`. Tras el descarte del inoperante motor heurístico de RegEx, se procedió a instanciar **BETO** (*BERT para español*), un modelo transformador bidireccional masivo entrenado sobre un vasto corpus hispanohablante.

El funcionamiento interno del clasificador transcurre en una secuencia metodológica rigurosa. En primer lugar, el texto bruto extraído de la noticia es sometido a un algoritmo de fragmentación sub-palabra denominado *WordPiece Tokenization*. Este mecanismo descompone palabras complejas u ortográficamente atípicas en sufijos y prefijos vectorizados, mitigando el problema crítico de palabras fuera del vocabulario (*Out-Of-Vocabulary*). El arreglo de *tokens* resultante se trunca estrictamente a la dimensión máxima de entrada del modelo (512 secuencias posicionales) y es inyectado en el paso hacia adelante (*forward pass*) a través de doce capas sucesivas de mecanismos de autoatención (*Self-Attention*). Estas capas permiten a cada *token* recalcular su valor en estricta dependencia del contexto que lo rodea, tanto a su izquierda como a su derecha (bidireccionalidad profunda).

El vector final de 768 dimensiones extraído del *token* especial [CLS] actúa como la representación latente global del documento. Al no contar con un conjunto masivo de decenas de miles de notas periodísticas sobre orfandad por feminicidio pre-etiquetadas manualmente para un entrenamiento supervisado, la red fue implementada para operar bajo el paradigma de clasificación *Zero-Shot* (Transferencia de Aprendizaje de Cero Disparos). El modelo inyecta el documento en un espacio latente junto con declaraciones premisa (e.g. *Esta noticia trata sobre un feminicidio donde un menor quedó en orfandad*) y calcula la similitud del coseno entre ambos tensores.

Para transformar estos puntajes de similitud crudos y a menudo muy cercanos entre sí en una distribución probabilística discretizada (una certidumbre útil para la lógica del programa), se implementó una agresiva función termodinámica denominada **Temperature Scaling**. Multiplicando empíricamente la similitud por un factor de escala de valor 5 antes de aplicar la exponencial euclidiana de la función *Softmax*, el algoritmo fuerza a la distribución a polarizarse.

Listing 7.1: Cálculo Matemático de Probabilidad Zero-Shot mediante Temperature Scaling

```
# La variable sim_relevante es el producto escalar normalizado (coseno)
# entre el embedding de la noticia y el embedding del target semantico.
# Un multiplicador termico alto (5) amplifica artificialmente la diferencia
# latente antes de que Softmax asimile las probabilidades.

exp_rel = np.exp(sim_relevante * 5)
exp_norel = np.exp(sim_no_relevante * 5)

# Probabilidad final distribuida y polarizada
score_final = exp_rel / (exp_rel + exp_norel)
```

Este escalamiento evita un colapso de confianza.^{en} escenarios donde la red dudaba entre una probabilidad de 0.55 y 0.45. La temperatura amplifica la varianza, separando radicalmente el puntaje a un contundente 0.82 contra un 0.18, permitiendo que las subsecuentes capas de umbral lógico tomen decisiones booleanas irrefutables.



7.1.3. Estrategias de Scraping Dinámico y Ofuscación

El colector de datos original (`collector.py`) exhibía una extrema ingenuidad técnica. Dependía de firmas de red por defecto provenientes de bibliotecas estándar (como *Requests* o *urllib*). Frente a la fortificación digital del ecosistema periodístico, estas peticiones eran bloqueadas de inmediato.

En el Prototipo 3 se instituyeron las *StealthSessions*. La arquitectura de red fue reescrita para manipular y enmascarar los protocolos criptográficos del apretón de manos (*handshake* de TLS). Modificando la configuración de encriptación *ciphers* y el orden de negociación de las extensiones, el *script* de recolección pasó de emitir un *fingerprint* de un servidor Linux desatendido a simular con una precisión criptográfica milimétrica la petición proveniente de un navegador Chrome corriendo en un sistema operativo Windows convencional.

Paralelamente, se implementó una rotación estocástica de *User-Agents* y se establecieron algoritmos de *backoff* exponencial (*Exponential Backoff*). Esta dilación asíncrona de los intervalos de recolección simula los tiempos fisiológicos de lectura humana, eludiendo proactivamente cualquier monitor de frecuencia de peticiones (*Rate Limiting*) de los servidores comerciales, y permitiendo escalar la recolección sin arriesgar un veto por dirección IP.

7.2. Prototipo 4: Sistema Neuro-Simbólico y Agrupamiento Global

La conceptualización del Prototipo 4 respondió a la necesidad de fusionar las ventajas del discernimiento de la Inteligencia Artificial (conexionismo) con las garantías de la lógica estricta y tradicional (simbolismo), resultando en la creación formal del **pipeline neuro-simbólico** definitivo.

7.2.1. El Gran Filtro: BERTopic como Contexto Macro

Históricamente, los procesos de *clustering* actuaban al final del ciclo de vida de los datos, intentando ordenar lo que previamente la inteligencia artificial había aprobado. El Prototipo 4 subvirtió este paradigma arquitectónico, trasladando **BERTopic** hacia las capas iniciales del flujo, posicionándolo como ^[1] Gran Filtro contextual.

Antes de forzar a BETO a intentar discernir el significado aislado de una noticia, el sistema introduce el volumen completo del acervo documental a BERTopic. La arquitectura interna de este modelo utiliza primero UMAP (*Uniform Manifold Approximation and Projection*) para contraer topológicamente los vectores semánticos de alta dimensionalidad hacia un espacio manejable tridimensional. Inmediatamente después, el módulo HDBSCAN (*Hierarchical Density-Based Spatial Clustering of Applications with Noise*) identifica densidades no lineales dentro de esa contracción.

El resultado de esta orquestación técnica es un "mapa global" de la realidad periodística. El sistema adquiere conciencia inmediata de que, por ejemplo, cuarenta noticias distintas están correlacionadas y orbitan semánticamente alrededor de un mismo evento crítico. Al inyectar posteriormente este identificador de clúster a BETO, la red neuronal opera con una ventaja incalculable: ya no analiza una noticia huérfana en el vacío, sino que evalúa el texto respaldada por la fuerza gravitacional del contexto temático de sus pares.

7.2.2. Lógica Híbrida de Clasificación (El Árbol Inquebrantable)

La fase analítica más profunda reside en la función `step_9_semantic_detection`. Para combatir la ocasional, aunque desastrosa, alucinación de los modelos fundacionales masivos, se diseñó un flujo de decisión neuro-simbólico. BETO provee el componente neuronal (un puntaje probabilístico no determinista derivado del análisis de atención latente), mientras que el código Python impone el componente simbólico (una lógica dura, booleana e inquebrantable derivada de axiomas sintácticos).

Este árbol de decisión interviene el puntaje crudo mediante tres niveles arquitectónicos de control jerárquico:

Nivel 1 (Bypass de Oro): Se analizan vectores heurísticos generados directamente por el motor de recolección. Si la noticia posee un *score* de orfandad puro $\geq 0,80$ (indiscutible presencia del trinomio agresor, víctima y mención de



descendencia), el sistema simbólico impone un *override* absoluto sobre la IA. Se confiere a la noticia el estatus máximo (*Alta Prioridad*), *bypassando* el escrutinio profundo para acelerar el procesamiento y evitar que la IA desestime un caso obvio por ruidos estadísticos o formato literario atípico.

Nivel 2 (Bozal de Penalización): Actuando como la antítesis del nivel anterior, se busca el descarte draconiano de los falsos positivos comprobados matemáticamente en TT1. Si el puntaje heurístico decreta un nivel infractor $\leq 0,15$ (típicamente notas de agresores menores de edad o víctimas de acoso sin homicidio documentado), la lógica impone un "bozal". El puntaje arrojado por BETO es intencionalmente dividido a la mitad y empujado artificialmente por debajo del umbral de rechazo, blindando el sistema de alarmas nocivas.

Nivel 3 (Inferencia Ponderada de α): El núcleo matemático de la fusión neuro-simbólica. Para aquellas noticias ambiguas que eluden el "Bypass de Oro" o el "Bozal", la confianza neuronal se combina con el vector analítico a través de una sumatoria ponderada controlada por un factor α completamente dinámico. El grado de inferencia que la IA (*beto_score*) tiene sobre la nota depende de qué tan segura esté la propia IA de su respuesta. La certidumbre se mide calculando la distancia absoluta del *score* respecto a la frontera de duda (0.5). Si BETO emite un puntaje de 0.99, α crece exponencialmente, otorgando casi el 100 % del peso decisivo a la red neuronal. Si BETO emite un 0.51, α disminuye, forzando a que la decisión dependa matemáticamente de los indicios numéricos (*heuristic_score*) generados durante el raspado web.

Listing 7.2: Bypass de Oro y Fusión Simbólica mediante ponderación α

```
# NIVEL 1: Bypass de Oro (Regla Simbolica Estricta)
if heuristic_score >= 0.80:
    return max(0.90, beto_score)

# NIVEL 2: Bozal de Penalizacion (Castigo Heuristico)
if heuristic_score <= 0.15:
    return beto_score * 0.5

# NIVEL 3: Fusion Neuro-Simbolica (Alpha Dinamico)
# Distancia hacia la incertidumbre (0.5). A mayor distancia , mas peso a BETO.
distancia_certidumbre = abs(beto_score - 0.5) * 2.0
alpha_beto = 0.5 + (0.5 * distancia_certidumbre)
alpha_heuristic = 1.0 - alpha_beto

# Puntaje final fusionado matematicamente
final_score = (beto_score * alpha_beto) + (heuristic_score * alpha_heuristic)
```

7.2.3. El Dashboard de Visualización y Explotación de Datos

El ciclo de recolección y análisis carece de valor empírico sin una interfaz de explotación para el usuario no técnico final (e.g. organizaciones civiles, periodistas de datos). El diseño arquitectónico del tablero web (*Dashboard*) representó la culminación del Prototipo 4.

Construida sobre el micro-framework *Flask Blueprint*, la interfaz expone la monumental base de datos PostgreSQL de manera simplificada e intuitiva. Las densidades matemáticas inescrutables arrojadas por HDBSCAN en el clúster semántico son renderizadas lógicamente bajo la nomenclatura visual de "Grupos Temáticos". La interfaz le otorga a cada "Grupo" un espacio cohesivo, traduciendo la cercanía topológica de UMAP en tarjetas legibles que compilan instantáneamente distintas fuentes sobre un mismo caso criminal.



Además, la plataforma expone el nivel de confianza de la clasificación neuro-simbólica mediante identificadores cromáticos y porcentajes de certidumbre. El operador final solo visualiza un producto periodístico curado, exento de duplicados e indexado bajo estricto orden de criticidad fáctica de orfandad, demostrando que la complejidad teórica subyacente ha sido completamente dominada a favor de la usabilidad operativa en la protección de los derechos de la infancia.



Resultados y Evaluación

Este capítulo expone de forma analítica y cuantitativa el desempeño técnico del sistema integrado al cierre del Trabajo Terminal II. Se demuestra empíricamente la superioridad de la arquitectura neuro-simbólica (Prototipo 4) frente a los resultados obtenidos mediante las heurísticas tradicionales del primer semestre. La evaluación se fundamenta en métricas extraídas directamente de una corrida de producción en el entorno de despliegue final.

8.1. Evaluación de la Recolección (Volumen de Ingesta)

La migración hacia un esquema de recolección dinámico apoyado por *StealthSessions* y consultas históricas programáticas detonó un incremento exponencial en la capacidad de ingesta del sistema.

Durante el ciclo de pruebas final, el módulo colector procesó y deduplicó exitosamente un lote masivo de **627 noticias únicas** en un solo bloque de ejecución continuo. Este hito operativo representa un aumento superior al 220 % en contraste directo con el rendimiento del TT1, el cual apenas logró compilar 281 noticias a lo largo de múltiples semanas de recolección pasiva. El éxito en la ingesta valida categóricamente la robustez de la arquitectura frente a los bloqueos de *Firewalls* comerciales y certifica la resiliencia de la deduplicación *cross-site* al mantener la base de datos libre de redundancia periodística.

8.2. Evaluación de la Detección Semántica (Filtro del Embudo)

El desafío principal del proyecto no radicaba únicamente en recolectar información, sino en discriminarla con alta precisión. De la muestra total de 627 noticias, la fase de filtrado preliminar determinó que **225 artículos** contenían menciones explícitas a "Niñas, Niños y Adolescentes"(NNA) en las proximidades semánticas de crímenes violentos (véase Figura ??).

Posteriormente, este subconjunto fue inyectado al motor de inferencia neuronal BETO bajo el esquema del "Árbol Inquebrantable". Los resultados del embudo analítico fueron sobresalientes:

- **75 noticias de Alta Relevancia:** Casos fácticos innegables de orfandad por feminicidio, validados por la IA y priorizados por el "Bypass Simbólico".



- **53 noticias de Media Relevancia:** Reportes donde el contexto sugiere vulnerabilidad infantil colateral o casos en desarrollo.

Es crítico destacar la efectividad del mecanismo denominado "Bozal de Penalización". Este estrato lógico descartó de forma autónoma casi un centenar de noticias basura y falsos positivos recurrentes del TT1 (como menores infractores o reportes macroestadísticos), protegiendo la carga cognitiva del usuario final y demostrando la asertividad matemática de la fusión neuro-simbólica.

8.3. Evaluación del Agrupamiento (BERTopic)

La inclusión del modelo topológico BERTopic resolvió de manera definitiva el problema histórico de fragmentación analítica. Al operar sobre la base de datos curada, el algoritmo logró comprimir el caos informativo en exactamente **15 Grupos Temáticos** altamente cohesivos.

A diferencia del ruido generado previamente por *K-Means*, estos 15 clústeres demostraron una congruencia humana excepcional. El sistema agrupó de manera autónoma narrativas periodísticas complejas, creando clústeres no solo basados en el nombre de la víctima o ubicación geográfica, sino en la semántica del evento, tales como: disputas legales por custodia, manifestaciones y exigencias de justicia colectiva, o crónicas sobre el impacto psicológico en las víctimas indirectas.

8.4. Análisis de la Interfaz (UI/UX) e Impacto Operativo

La evaluación final del sistema trasciende las métricas computacionales y se sitúa en la usabilidad operativa para los actores de la sociedad civil. La interfaz del *Dashboard Web* fue concebida bajo principios de jerarquía visual.

Como se observa en la Figura ??, la plataforma dota a cada registro de *tags* visuales distintivos (por ejemplo, etiquetas verdes brillantes para "NNAz "Feminicidio") junto con sus respectivos porcentajes probabilísticos de certidumbre calculados por BETO. Esta arquitectura de la información permite a los analistas de fundaciones, como *Futuro con Derechos*, realizar un barrido visual (*skimming*) inmediato sobre un clúster de noticias. Lo que históricamente representaba una inversión de docenas de horas-hombre navegando entre pestañas de navegadores, buscando manualmente coincidencias textuales, ha sido optimizado por el Prototipo 4 a una revisión jerárquica y determinista que exige apenas un par de segundos por evento fáctico.

Conclusiones

El desarrollo y culminación del *Sistema Inteligente para la Identificación y Seguimiento de NNA* ratifica de manera categórica e innegable el cumplimiento íntegro de los objetivos tecnológicos y sociales delineados en el protocolo de registro 2026-A135. El ciclo de vida de este proyecto atestiguó la metamorfosis de un planteamiento computacionalmente frágil, fundamentado en el análisis sintáctico lineal y el almacenamiento plano, hacia una plataforma neuro-simbólica de grado de producción, dotada de bases de datos transaccionales, infraestructura *anti-bot* y visualización analítica avanzada.

El hallazgo arquitectónico de mayor trascendencia emanado de esta investigación reside en el entendimiento empírico de las limitantes de la Inteligencia Artificial moderna frente al caos del lenguaje periodístico humano. Durante la fase experimental, quedó demostrado que depender exclusivamente del conexionismo puro de los modelos de lenguaje masivos, como los *Transformers* (BETO), resulta insuficiente para un despliegue sin supervisión. Estas arquitecturas neuronales sufren de "fugas de confianza" ante narrativas semánticamente difusas, provocando alucinaciones estructurales, tales como confundir a un adolescente que comete un feminicidio con un menor de edad que ha quedado en orfandad tras el asesinato de su madre.

La respuesta definitiva a este escollo técnico fue la conceptualización y despliegue exitoso de la Arquitectura Neuro-Simbólica. Se demostró que al injertar la estricta rigurosidad del simbolismo algorítmico tradicional (mecanismos de "Bypass" heurístico y el "Bozal de Penalización") como guardianes controladores de la inferencia neuronal, el sistema adquiere una resiliencia formidable. Esta fusión logró amalgamar la flexibilidad cognitiva de BETO con el determinismo inquebrantable de la lógica condicional, abatiendo la tasa de falsos positivos a márgenes históricamente bajos (cerca de cero) y estableciendo un nuevo estándar metodológico para la lectura automatizada de notas fácticas de extrema sensibilidad.

Más allá de la complejidad del código y las optimizaciones matemáticas en el espacio hiperdimensional de BERTopic, el éxito supremo de este Trabajo Terminal II se materializa en su impacto social directo. La solución entregada trasciende el entorno académico para convertirse en una herramienta de alivio operativo real. Organizaciones civiles y colectivos defensores de los derechos humanos, como la fundación *Futuro con Derechos*, quedan liberadas del agotador desgaste psicológico y logístico que impone la curaduría manual de la prensa roja. Al automatizar la recolección, deduplicación y clasificación de los eventos de orfandad, el sistema reduce intervenciones manuales de horas o días a escasos segundos, proveyendo bases de datos estructuradas que habilitan una acción rápida, priorizada y estratégicamente focalizada sobre las víctimas.

Finalmente, este proyecto reafirma una de las máximas más nobles de la ingeniería de sistemas: el poder compu-



tacional carece de valor si no está anclado en el profundo respeto por la dignidad humana. A pesar de procesar e ingerir volúmenes masivos de datos periodísticos a velocidades maquinales, contabilizar tragedias y clústeres geográficos, el sistema se diseñó bajo una inquebrantable doctrina de privacidad *by design*. La arquitectura clasifica, cuantifica y visibiliza la urgencia de los menores, pero jamás expone sus nombres ni vulnera su derecho inalienable a la privacidad, operando en absoluta consonancia con los más altos estándares de la ética informática y la protección integral de las infancias vulneradas en México.



A pesar de la madurez tecnológica alcanzada por la arquitectura neuro-simbólica y la culminación exitosa de los prototipos delineados en el Trabajo Terminal II, la magnitud y urgencia del problema social abordado exigen una visión de escalabilidad continua. Este capítulo traza la hoja de ruta técnica a mediano y largo plazo, proponiendo las optimizaciones e integraciones de *software* necesarias para transicionar el sistema de un entorno de validación hacia una infraestructura operativa a nivel nacional.

10.1. Extracción de Entidades Nombradas (NER) bajo Principios Éticos

El siguiente hito evolutivo en el procesamiento de lenguaje natural del sistema consiste en la implementación de un módulo robusto de Extracción de Entidades Nombradas (NER, por sus siglas en inglés). Si bien BETO y BERTopic otorgan comprensión y contexto a nivel de documento, es imperativo extraer la granularidad de los actores involucrados. Se propone realizar un *fine-tuning* sobre arquitecturas especializadas como *spaCy* o integrar Modelos de Lenguaje de Gran Escala (LLMs) para minar entidades críticas como nombres de municipios, autoridades judiciales a cargo (jueces, fiscales) e instituciones gubernamentales responsables (e.g., el Desarrollo Integral de la Familia, DIF).

Sin embargo, el rasgo distintivo de esta futura implementación será su diseño *ético por defecto*. El módulo NER deberá ser programado con heurísticas de enmascaramiento estricto para ignorar, ofuscar o destruir deliberadamente cualquier token clasificado como nombre propio de un menor de edad. De este modo, se garantiza la extracción de inteligencia táctica para el seguimiento institucional, blindando al mismo tiempo la identidad y la integridad de las víctimas indirectas contra cualquier exposición accidental en las bases de datos.

10.2. Generación Automática de Reportes (Exportación)

El tablero interactivo actual posee un alto valor para el análisis en tiempo real, pero el trabajo de defensa de derechos humanos requiere materialización documental. El desarrollo futuro debe contemplar la creación de un subsistema de renderizado para la generación de expedientes descargables en formatos estandarizados, como PDF y hojas de cálculo (Excel).

Esta capacidad de exportación automatizada dotará a las organizaciones civiles de una herramienta formidable. Podrán transformar instantáneamente los clústeres semánticos de BERTopic y las métricas de BETO en expedientes



impresos, proveyendo evidencia estadística sólida y curada que puede ser directamente presentada ante comisiones legislativas, mesas de trabajo interinstitucionales o tribunales, eliminando las horas de transcripción manual que sufren los trabajadores sociales.

10.3. API Pública e Interoperabilidad para Organizaciones Civiles

La verdadera democratización de la tecnología radica en su interoperabilidad. Actualmente, el ecosistema funciona como un monolito cerrado al exterior, donde el usuario debe ingresar forzosamente al *Dashboard* visual. Como trabajo a mediano plazo, se proyecta el desarrollo de una Interfaz de Programación de Aplicaciones (API) pública, implementada bajo el estándar RESTful o a través de GraphQL, protegida mediante autenticación robusta (OAuth 2.0).

La apertura de esta API permitirá que fundaciones como *Futuro con Derechos* conecten sus propios sistemas internos, aplicaciones móviles o bases de datos directamente a nuestro núcleo neuro-simbólico. En lugar de adaptar sus flujos de trabajo a nuestra plataforma, podrán consumir bajo demanda los datos deduplicados, clasificados y libres de ruido, integrando la inteligencia de NNA directamente en los tableros propietarios que ya dominan y operan diariamente.

10.4. Despliegue en la Nube (Cloud Architecture) y Escalabilidad

El entorno de ejecución presente depende de la contenerización local en *Docker*, lo cual restringe el poder de cómputo a los fierros del servidor anfitrión. Para sostener un monitoreo ininterrumpido sobre cientos de fuentes de todo el país, la arquitectura debe migrar obligatoriamente hacia una infraestructura de nube pública, como Amazon Web Services (AWS) o Google Cloud Platform (GCP).

Esta transición arquitectónica habilitará el uso de bases de datos relacionales completamente gestionadas y replicadas, como Amazon RDS para PostgreSQL, garantizando tolerancia a fallos y copias de seguridad continuas. Asimismo, la orquestación del núcleo de inteligencia artificial se verá profundamente beneficiada. Desplegar los pesados modelos de tensores de BETO y BERTopic bajo servicios de elasticidad computacional permitiría asignar Unidades de Procesamiento Gráfico (GPUs) bajo demanda, escalando la capacidad del análisis semántico automáticamente durante picos de contingencia noticiosa, y apagando los recursos cuando el flujo informativo disminuya, optimizando dramáticamente los costos operativos.

10.5. Validación Piloto en Campo y Refinamiento UX/UI

Finalmente, la culminación de cualquier herramienta de *software* con impacto social no ocurre en el repositorio de código, sino en las manos de sus usuarios. El trabajo futuro ineludible consiste en sacar el sistema del entorno académico y someterlo a pruebas piloto exhaustivas directamente en campo.

El despliegue en fase *beta* con los trabajadores sociales, psicólogos y analistas de datos de las Organizaciones No Gubernamentales resulta indispensable. Solo a través del monitoreo de su interacción diaria se podrán capturar las métricas cualitativas necesarias para afinar la Experiencia de Usuario (UX) y la Interfaz de Usuario (UI). Comprender cómo leen los clústeres, qué información necesitan de un vistazo y qué botones resultan confusos, es el paso final para transformar este modelo de ingeniería en un aliado transparente y natural en la lucha diaria por la protección de las infancias en México.

