

Sistema Inteligente para la Identificación y Seguimiento de los derechos de los NNA por feminicidios

Trabajo Terminal II

Morales Martinez Hector Alberto

Directores:

M. en C. Ulises Saldaña Velez

M. en C. Gabriel Hurtado Avilés

Ciudad de México, a 4 de junio de 2026



0.1. Términos del Negocio	1
1. Introducción	3
1.1. Presentación del proyecto	3
1.2. Planteamiento del problema	4
1.2.1. La inviabilidad del monitoreo manual	4
1.3. Objetivos del Proyecto	4
1.3.1. Objetivo General	4
1.3.2. Objetivos Específicos	4
2. Especificación de requerimientos del sistema	5
2.1. Casos de uso del sistema	5
2.2. Requerimientos Funcionales del Motor Back-end	7
2.2.1. RF — Subsistema de Recolección de Datos	7
2.2.2. RF — Subsistema de Deduplicación en Cascada	8
2.2.3. RF — Subsistema de Análisis Semántico Neuro-Simbólico	9
2.2.4. RF — Subsistema de Agrupamiento Semántico (BERTopic)	10
2.2.5. RF — Subsistema de Persistencia Relacional	11
2.3. Requerimientos No Funcionales	12
3. Justificación y Alcance del Proyecto	13
3.1. Justificación Social	13
3.2. Justificación Tecnológica	14
3.3. Justificación ética y moral: Protección de la privacidad de los NNA	14
3.3.1. El interés superior del niño	15
3.3.2. Naturaleza de la información procesada	15
3.3.3. ¿Por qué el sistema no proporciona nombres de NNA?	15
3.3.4. Fortaleza ética del enfoque adoptado	16
3.3.5. Compromiso de privacidad	16
3.4. Alcance del Sistema	16
3.4.1. Alcance funcional	16
3.4.2. Alcance geográfico y temporal	17

3.5. Limitaciones y exclusiones	17
3.5.1. Exclusiones explícitas del alcance	17
3.5.2. Limitaciones técnicas	17
3.6. Alineación con el protocolo	18
4. Marco Teórico	19
4.1. Procesamiento de lenguaje natural y representación lingüística	19
4.1.1. Tokenización y el algoritmo WordPiece	19
4.1.2. Lematización y normalización lexicológica	20
4.1.3. Modelo de espacio vectorial: TF-IDF	20
4.1.4. Arquitectura Transformer y mecanismo de auto-atención	21
4.1.5. BETO: representaciones bidireccionales para el español	21
4.2. Paradigmas de inferencia y clasificación semántica	22
4.2.1. Clasificación zero-shot por similitud coseno	22
4.3. Agrupamiento semántico y reducción de dimensionalidad	22
4.3.1. UMAP: Proyección Topológica Preservadora de Estructura	22
4.3.2. HDBSCAN: Agrupamiento Jerárquico por Densidad Variable	23
4.3.3. c-TF-IDF: Relevancia de Términos por Clúster	24
4.4. Técnicas de Deduplicación <i>Cross-Site</i>	24
4.4.1. Hash Exacto MD5	24
4.4.2. Similitud de Jaccard sobre Conjuntos de Tokens	24
4.4.3. SimHash: Huellas Digitales Localmente Sensibles	25
4.4.4. Similitud Coseno sobre Vectores TF-IDF	25
4.5. Tecnologías de Extracción de Datos y Persistencia	25
4.5.1. Protocolos de Sindicación: RSS y Atom	25
4.5.2. Evasión de WAF: <i>StealthSession</i> y TLS/JA3 Fingerprinting	25
4.5.3. Propiedades ACID de postgresql	26
4.5.4. Índices GIN y Full-Text Search en Español	26
4.6. Sistemas Neuro-Simbólicos: Fundamentos Teóricos	27
5. Estado del Arte	28
5.1. Sistemas de monitoreo de medios tradicionales	28
5.2. NLP Aplicado a la Detección de Violencia de Género	28
5.3. Herramientas y Esfuerzos Existentes en México	29
5.3.1. Red por los Derechos de la Infancia en México (REDIM)	29
5.3.2. El Mapa de los Feminicidios en México	29
5.3.3. Fundación Futuro con Derechos	29
5.4. Análisis comparativo y brecha identificada	29
5.5. Técnicas de extracción de datos	30
5.5.1. Extracción Estática (HTML Parsing con BeautifulSoup)	30
5.5.2. Automatización de Navegador (Selenium / Playwright)	31
5.5.3. Agregación Estructurada (RSS/Atom) y Stealth Sessions	31
5.5.4. Tabla Comparativa de Técnicas de Extracción	32
5.6. Evolución del Almacenamiento: de Archivos Planos a PostgreSQL	32
5.6.1. Archivos Planos (CSV): Ventajas, Limitaciones y el Techo del TT1	32
5.6.2. PostgreSQL 16: Justificación de la Selección	33
5.7. Evolución de los Modelos de Representación Lingüística para NLP	34
5.7.1. Representaciones Vectoriales Estáticas: Word2Vec y GloVe	34

5.7.2. Modelos Recurrentes: LSTM y GRU	35
5.7.3. Arquitectura Transformer y Atención Bidireccional: BERT	35
5.7.4. Justificación de BETO frente a Modelos Multilingües (mBERT)	35
5.7.5. Clasificación <i>Zero-Shot</i> frente al <i>Fine-Tuning</i> Supervisado	36
5.7.6. Soberanía de Datos y Rechazo de APIs Privativas	36
5.8. Técnicas de Agrupamiento Semántico y Organización Temática	37
5.8.1. Métodos Tradicionales: K-Means y su Inadecuación para Datos de Alta Dimensionalidad	37
5.8.2. DBSCAN: Ventajas y Limitaciones Residuales	37
5.8.3. BERTopic: Arquitectura Modular para Descubrimiento de Tópicos Semánticos	38
5.8.4. Evolución Comparativa TT1 → TT2: de Léxico a Semántica	40
5.9. Conclusión del Capítulo: La Convergencia Tecnológica al Servicio de los Derechos de la Infancia	41
6. Metodología de Desarrollo	42
6.1. Metodología de desarrollo evolutivo	42
6.1.1. Cronograma General del Proyecto	43
6.2. Evolución de los Prototipos (P0 al P4)	43
6.2.1. Fase TT-1: Prototipos Exploratorios (P0–P2)	43
6.2.2. Fase TT-2: Arquitectura Neuro-Simbólica (P3–P4)	43
6.3. Stack Tecnológico: Evolución TT-1 → TT-2	44
6.4. Arquitectura de Microservicios y Contenerización	44
6.4.1. Contenedor de Base de Datos: <i>nna-postgres</i>	45
6.4.2. Contenedor del Motor de Análisis: <i>nna-analyzer</i>	45
6.4.3. Contenedor de la Aplicación Web: <i>nna-webapp</i>	45
6.5. Matriz de Trazabilidad: Requerimientos por Prototipo	46
7. Desarrollo del Trabajo Terminal I	47
7.1. Prototipo 0: Scraping directo sobre HTML	47
7.1.1. Premisa y Enfoque	47
7.1.2. Resultado: Inviabilidad por seguridad perimetral	47
7.1.3. Decisión Técnica	48
7.2. Prototipo 1: RSS + K-Means	48
7.2.1. Arquitectura implementada	48
7.2.2. Limitaciones Identificadas	48
7.3. Prototipo 2: Triple Fuente + DBSCAN + <i>FeminicideDetector</i>	49
7.3.1. Evolución del sistema	49
7.4. Limitaciones identificadas	49
7.4.1. Falsos positivos: Insuficiencia de la Sintaxis	49
7.4.2. Clustering Léxico: DBSCAN sobre TF-IDF	50
7.4.3. La poca escalabilidad del almacenamiento en CSV	50
7.4.4. Síntesis: La necesidad de comprensión semántica	50
7.5. Arquitectura del Sistema	51
7.5.1. Diagrama de Componentes (Arquitectura en Capas)	51
7.5.2. Diagrama de Secuencia (Ciclo de Vida de la Noticia)	51
7.6. Diseño de Datos	54
7.6.1. Modelo de Dominio	54
7.6.2. Diccionario de Datos Extendido	54

8. Desarrollo de Trabajo Terminal II	58
8.1. Contexto: Limitaciones del Prototipo 2	58
8.2. Patrones arquitectónicos del flujo analítico	59
8.2.1. Patrón <i>Repository</i> para la capa de persistencia	59
8.2.2. Patrón <i>Pipeline</i> para el flujo analítico	59
8.3. Prototipo 3 Motor semántico BETO y migración de persistencia	59
8.3.1. Migración de CSV a PostgreSQL	60
8.3.2. Arquitectura del motor BETO	60
8.3.3. Clasificación <i>Zero-Shot</i> y <i>Temperature Scaling</i>	61
8.3.4. Evolución del recolector	61
8.3.5. Deduplicación en cascada de cuatro fases	63
8.4. Prototipo 4: Arquitectura Neuro-Simbólica Completa	63
8.4.1. Por qué la IA Sola No Basta: Alucinaciones de BETO	64
8.4.2. BERTopic como Filtro de Contexto Global (OE-4)	64
8.4.3. El Bypass de Oro: Decisión Simbólica Absoluta	65
8.4.4. El Bozal de Penalización: El Contexto de Clúster como Corrector	65
8.4.5. El Factor Alpha Dinámico: Fusión Neuro-Simbólica para Casos Ambiguos	66
8.4.6. Investigador Profundo: DuckDuckGo y Gemini Flash	66
8.5. Síntesis: El Pipeline v5.0 como Sistema de Doble Árbol	69
8.6. Diagrama Conceptual del Sistema	70
8.7. Verificación, Validación y Pruebas (QA)	72
8.7.1. Pruebas Unitarias y Aislamiento de Componentes	72
8.7.2. Pruebas de Caja Negra: Validación del Bozal de Penalización	72
8.7.3. Matriz de Casos de Prueba	72
9. Resultados y Evaluación	74
9.1. Evaluación de la Recolección (Volumen de Ingesta)	74
9.2. Evaluación de la Detección Semántica (Filtro del Embudo)	74
9.3. Evaluación del Agrupamiento (BERTopic)	75
9.4. Análisis de la Interfaz (UI/UX) e Impacto Operativo	75
10. Conclusiones	77
11. Trabajo Futuro	79
11.1. Extracción de Entidades Nombradas (NER) bajo Principios Éticos	79
11.2. Generación Automática de Reportes (Exportación)	79
11.3. API Pública e Interoperabilidad para Organizaciones Civiles	80
11.4. Despliegue en la Nube (Cloud Architecture) y Escalabilidad	80
11.5. Validación Piloto en Campo y Refinamiento UX/UI	80

Índice de figuras

7.1. Diagrama de Componentes de la Arquitectura del Sistema.	52
7.2. Diagrama de Secuencia ilustrando el ciclo de vida de una noticia.	53
7.3. Diagrama de Clases / Dominio detallando Tipos de Datos y Relaciones.	55
8.1. Arquitectura del motor BETO y clasificación <i>Zero-Shot</i> con <i>Temperature Scaling</i>	62
8.2. Flujo de deduplicación en cascada.	63
9.1. Métricas de filtrado preliminar en el Dashboard Web.	75
9.2. Visualización jerárquica de noticias de Alta Relevancia en el Dashboard.	76

Índice de tablas

1. Resumen del proyecto (Project Charter)	VIII
2.1. Catálogo de Casos de Uso del Sistema	6
2.2. Requerimientos Funcionales: Subsistema de Recolección	7
2.3. Requerimientos Funcionales: Subsistema de Deduplicación	8
2.4. Requerimientos Funcionales: Subsistema de Análisis Semántico (Motor BETO)	9
2.5. Requerimientos Funcionales: Subsistema de Agrupamiento BERTopic	10
2.6. Requerimientos Funcionales: Subsistema de Persistencia	11
2.7. Requerimientos No Funcionales: Métricas de Calidad y Restricciones	12
3.1. Distinción entre información procesada y excluida	15
3.2. Correspondencia entre objetivos del protocolo y componentes implementados	18
5.1. Comparativa de técnicas de extracción de datos para monitoreo de medios	32
5.2. Comparativa de modelos de representación lingüística para clasificación semántica	36
5.3. Comparativa de algoritmos de agrupamiento semántico para corpus periodístico	40
6.1. Evolución del Stack Tecnológico (TT-1 vs TT-2)	44
6.2. Matriz de Trazabilidad: Requerimientos vs. Prototipos de Implementación	46
7.1. Comparativa de métricas: TT1 vs. metas del TT2	50
7.2. Diccionario de Datos: Entidad noticias.	54
7.3. Diccionario de Datos: Entidad detecciones.	56
7.4. Diccionario de Datos: Entidad clusters_semanticos.	56
7.5. Diccionario de Datos: Entidad fuentes.	57
7.6. Diccionario de Datos: Entidad usuarios.	57
8.1. Árbol de decisión neuro-simbólico del Prototipo 4	66
8.2. Casos de uso del módulo DeepInvestigator	69
8.3. Pipeline v5.0: síntesis de los once pasos de análisis	70
8.4. Matriz de Casos de Prueba Críticos y Resultados de Ejecución.	73

Project Charter

Proyecto:	2026-A135: Sistema Inteligente para la Identificación y Seguimiento de NNA		
Responsable:	Héctor Alberto Morales Martínez, desarrollador principal		
Autoriza:	Comisión de Trabajos Terminales (CATT)		
Background/Contexto:	Miles de NNA quedan en orfandad por feminicidios anualmente; actualmente no existe un sistema centralizado de seguimiento para apoyarlos.		
Beneficios esperados:	Visibilidad del fenómeno, reducción de trabajo manual para ONGs y generación de base de datos histórica mediante NLP.		
Costo estimado:	Proyecto Académico (TT1/TT2)		
Fecha de inicio:	Septiembre 2025	Fecha de término:	Junio 2026
Objetivo:	Sistema automatizado de recolección, análisis NLP y visualización de noticias sobre NNA afectados por feminicidios.		
Entregables Principales			
	SIST-01	Sistema web y flujo de NLP funcional (Contenedores Docker)	
	DOC-01	Documentación Técnica (este documento)	
	COD-01	Código fuente completo en repositorio	
Alcance del proyecto			
Incluye:	• Recolección automatizada multi-fuente (RSS, Google Search). • Web scraping dinámico y evasión de bloqueos. • Clasificación semántica con modelo BETO. • Agrupación de noticias (clustering) mediante BERTopic. • Deduplicación cross-site avanzada. • Base de datos PostgreSQL y dashboard interactivo.		
Excluye:	• Identificación de datos personales completos de NNA. • Intervención social directa o canalización oficial a las autoridades. • Validación pericial de la veracidad de los hechos periodísticos.		
Metodología:	Desarrollo evolutivo (Iteraciones de Prototipo P0 a P4)		
Datos de contacto			
Desarrollador:	Héctor Alberto Morales Martínez		
Directores:	M. en C. Ulises Saldaña Velez, M. en C. Gabriel Hurtado Avilés		
Organización de Apoyo:			
Riesgos y peligros:	• Bloqueos anti-scraping progresivos por parte de los medios periodísticos. • Lentitud en la inferencia del modelo neuronal por falta de hardware GPU.		
Supuestos:	• Los medios mantienen un estándar semántico en su redacción de crímenes. • Los servicios de búsqueda como Google News permanecen públicamente consultables.		
Restricciones y dependencias:	• El sistema no puede operar en tiempo real exacto; opera por lotes (cron-jobs). • Restricción absoluta de protección de identidad del menor por normativas vigentes.		

Tabla 1: Resumen del proyecto (Project Charter)

0.1. Términos del Negocio

En esta sección se definen los conceptos técnicos, legales y operativos fundamentales para la comprensión del sistema.

BETO: Modelo de lenguaje basado en la arquitectura *BERT* (Bidirectional Encoder Representations from Transformers) preentrenado específicamente con un corpus masivo en español. Es el núcleo del análisis semántico del sistema[cite: 17, 240].

BERTopic: Técnica de modelado de tópicos que utiliza *embeddings* de Transformers y un flujo de trabajo basado en reducción de dimensionalidad y clustering para encontrar agrupaciones temáticas en documentos[cite: 41, 116, 241].

Bozal de Penalización: Mecanismo de lógica simbólica diseñado para este proyecto que reduce artificialmente el puntaje de confianza de la IA ante casos detectados como "falsos positivos"(ej. menores agresores), evitando su clasificación como alta relevancia.

Bypass de Oro: Regla de negocio estricta que prioriza la detección heurística sobre la IA; si una noticia contiene palabras clave críticas de orfandad con alta densidad, se marca como relevante sin esperar la inferencia neuronal.

Deduplicación Cross-site: Proceso de identificar y eliminar noticias que narran el mismo evento pero provienen de diferentes medios de comunicación, utilizando algoritmos de similitud como SimHash o Jaccard[cite: 113, 242, 266].

Feminicidio: Muerte violenta de las mujeres por razones de género, tipificada en el sistema penal mexicano. Es el evento origen que el sistema busca monitorear[cite: 218, 245].

GIN Index (Generalized Inverted Index): Tipo de índice en PostgreSQL diseñado para manejar elementos de datos compuestos (como documentos de texto), fundamental para la rapidez de las búsquedas Full-Text Search.

NNA: Acrónimo de Niñas, Niños y Adolescentes. En este proyecto, se refiere específicamente a los menores en situación de orfandad o vulnerabilidad tras un feminicidio[cite: 220, 245, 247].

Pipeline Neuro-Simbólico: Arquitectura híbrida que combina el aprendizaje estadístico de las redes neuronales (BETO) con la rigurosidad de las reglas de decisión programadas (Simbólico).

StealthSession: Técnica de recolección de datos que simula el comportamiento y las firmas criptográficas de un navegador humano para evadir bloqueos automáticos de servidores web (WAF).

Víctima Indirecta: Familiares o personas dependientes de la víctima directa de un feminicidio; en el contexto de este sistema, se enfoca en los hijos e hijas menores de edad[cite: 247, 259].

UMAP (Uniform Manifold Approximation and Projection): Algoritmo de aprendizaje múltiple utilizado en el módulo BERTopic para reducir la alta dimensionalidad de los vectores generados por BETO (768 dimensiones) a un espacio de menor dimensionalidad (e.g., 3 dimensiones). Esto permite optimizar computacionalmente el proceso de agrupamiento preservando la estructura topológica global de las noticias periodísticas.

HDBSCAN (Hierarchical Density-Based Spatial Clustering of Applications with Noise): Algoritmo de agrupamiento espacial basado en densidad integrado en la tubería de BERTopic. El sistema lo emplea para identificar densidades de noticias afines y aislar proactivamente anomalías (*outliers*) o ruido estadístico sin necesidad de predefinir empíricamente la cantidad de clústeres esperados.

c-TF-IDF (Class-based Term Frequency-Inverse Document Frequency): Modificación del algoritmo clásico de ponderación textual empleado internamente por BERTopic. En el proyecto, se utiliza de forma extensiva para calcular y extraer las palabras clave más significativas que describen semánticamente a cada clúster de noticias generado, facilitando la legibilidad en el Dashboard.

Temperature Scaling (Escalamiento de Temperatura): Técnica matemática de calibración termodinámica aplicada a la función *Softmax*. En la arquitectura de inferencia neuronal, se utiliza un factor de escala térmico (multiplicador de 5) para amplificar o polarizar las diferencias probabilísticas, destruyendo la incertidumbre matemática al clasificar un texto como relevante.

Zero-Shot Classification (Clasificación de Cero Disparos): Paradigma de inferencia de Inteligencia Artificial que habilita la clasificación de textos en categorías para las cuales la red no fue explícitamente entrenada. El motor lo implementa proyectando una noticia y una categoría descriptiva de orfandad hacia el mismo espacio latente para medir la similitud del coseno entre ambos tensores.

El presente Trabajo Terminal registrado bajo el número de protocolo 2026-A135, constituye la segunda fase de un proyecto de investigación aplicada que aborda una problemática crítica en la intersección de los derechos humanos, la violencia de género y la ingeniería de sistemas inteligentes: la invisibilidad estadística y la ausencia de seguimiento sistemático de las Niñas, Niños y Adolescentes (NNA) en situación de orfandad por feminicidio en México. Mediante la conceptualización, diseño, desarrollo y despliegue de un sistema inteligente de monitoreo de medios, el proyecto propone una solución tecnológica para mitigar la dispersión de datos que obstaculiza la labor de las organizaciones civiles y de las instituciones gubernamentales en la procuración de justicia y la reparación integral del daño.

1.1. Presentación del proyecto

México atraviesa una crisis sistémica de violencia feminicida de proporciones documentadas. De acuerdo con los registros del Secretariado Ejecutivo del Sistema Nacional de Seguridad Pública (SESNSP) y la Secretaría de Gobernación, entre los años 2010 y 2023 se han contabilizado **más de 8,000 víctimas** de feminicidio en el territorio nacional. Esta cifra ya de por sí alarmante, oculta una dimensión adicional del daño: el impacto colateral sobre los hijos e hijas de las víctimas, quienes quedan en situación de orfandad repentina y traumática.

La Red por los Derechos de la Infancia en México (REDIM) estima que existen **al menos 3,500 Niñas, Niños y Adolescentes** que han perdido a su madre como consecuencia directa de un feminicidio. Pese a la gravedad de esta cifra no existe a nivel nacional un padrón oficial, un censo unificado ni un mecanismo de seguimiento estandarizado que documente el estado de estas víctimas indirectas. La Convención sobre los Derechos del Niño y la Ley General de los Derechos de Niñas, Niños y Adolescentes (LGDNNA) establecen el principio del *interés superior de la niñez* como eje que orienta, garantizando el derecho a la protección, la salud, la educación y la reparación integral. No obstante la ausencia de datos estructurados imposibilita la materialización efectiva de estos derechos.

El TT no. 2026-A135 surge como respuesta tecnológica a esta brecha. El sistema automatiza el ciclo completo de descubrimiento informativo desde la recolección de noticias en fuentes periodísticas de acceso público hasta la clasificación semántica y la persistencia relacional de los casos identificados, esto con el objetivo de que ningún NNA en situación de orfandad por feminicidio permanezca invisible para las instituciones que tienen la obligación legal de protegerlo.

1.2. Planteamiento del problema

La información sobre los NNA en situación de orfandad por feminicidio se encuentra fragmentada en el ecosistema informativo mexicano. Los datos relevantes sobre la existencia, el estado legal y las condiciones de resguardo de los hijos de una víctima suelen estar dispersos en notas periodísticas de medios locales, comunicados aislados de fiscalías estatales y registros internos de organizaciones no gubernamentales que no se interconectan entre sí. La información existe pero no es accesible de forma sistemática ni procesable a escala computacional.

1.2.1. La inviabilidad del monitoreo manual

La mitigación de esta invisibilidad estadística recae actualmente sobre organizaciones de la sociedad civil como la Fundación "Futuro con Derechos".^{el} proyecto cartográfico de la investigadora María Salguero y la REDIM. La metodología subyacente a este trabajo de documentación presenta un cuello de botella operativo: la **revisión manual y artesanal de fuentes hemerográficas**. El proceso exige que analistas y voluntarios dediquen muchas horas semanales a la revisión individual de portales de noticias, buscando menciones colaterales de hijos en narrativas de notas policíacas. Este enfoque es inviable frente al volumen de información que se genera diariamente en el país ya que México cuenta con más de 1,200 medios periodísticos digitales activos, produciendo decenas de miles de artículos diarios.

La latencia introducida por el factor humano limita drásticamente la capacidad de procesamiento, provocando que una enorme cantidad de casos pasen desapercibidos porque es imposible auditar concurrentemente todas las fuentes periodísticas nacionales y regionales. Además este proceso consume los recursos de talento especializado (psicólogos, abogados, trabajadores sociales), desviando su capacidad hacia labores de recolección de datos en lugar de la intervención directa con las víctimas.

1.3. Objetivos del Proyecto

1.3.1. Objetivo General

Desarrollar un sistema inteligente que sea capaz de automatizar la recolección, clasificación y análisis de información relacionadas con casos de feminicidio, para facilitar la identificación de niños, niñas y adolescentes que se encuentren en una situación de orfandad en consecuencia de los crímenes de violencias. Mediante el uso de Web Scraping y Procesamiento de Lenguaje Natural

1.3.2. Objetivos Específicos

- OE-1** Identificar y seleccionar fuentes públicas confiables que contengan información relacionada con feminicidios y posibles víctimas indirectas.
- OE-2** Diseñar y desarrollar una herramienta automatizada de Web Scraping para la recolección sistemática de datos provenientes de dichas fuentes.
- OE-3** Implementar técnicas de Procesamiento de Lenguaje Natural (PLN) para extraer y estructurar información clave a partir de textos no estructurados.
- OE-4** Diseñar una base de datos estructurada que permita almacenar la información recolectada de manera eficiente y segura.

Especificación de requerimientos del sistema

El presente capítulo formaliza el contrato técnico del sistema bajo el protocolo 2026-A135. Atendiendo a la naturaleza predominantemente autónoma del sistema, la especificación refleja una distribución de peso de **30 % en Casos de Uso** —interacciones del usuario con el dashboard de resultados— y **70 % en Requerimientos de Sistema**, que definen el comportamiento del motor de recolección, procesamiento y análisis semántico que opera de forma completamente independiente de la intervención humana. El usuario final consume únicamente los resultados que el pipeline de IA procesó de manera autónoma; no interviene en ninguna etapa del análisis.

2.1. Casos de uso del sistema

Los casos de uso modelan las interacciones entre los actores externos y el dashboard web. La Tabla [2.1](#) presenta el catálogo completo; los actores interactúan exclusivamente con resultados pre-procesados por el pipeline de IA.

Tabla 2.1: Catálogo de Casos de Uso del Sistema

ID	Nombre	Descripción
CU-01	Autenticación de Usuario	El actor introduce credenciales (usuario + contraseña). El sistema verifica el hash Argon2id almacenado en PostgreSQL. En caso de éxito genera un token de sesión criptográfico (Flask-Login) con TTL de 8 horas. Tras 5 intentos fallidos se bloquea la cuenta.
CU-02	Visualizar Panel de Estadísticas	El actor accede al dashboard principal. El sistema recupera de PostgreSQL las métricas de las últimas 24/48/72 horas: total de noticias procesadas, distribución por nivel de prioridad (Alta/Media/Baja), cantidad de casos en seguimiento y tópicos BERTopic activos. Todos los datos son resultado del último ciclo autónomo del pipeline.
CU-03	Filtrar Noticias por Ejes Semánticos	El actor selecciona filtros combinados: eje semántico (Feminicidio / NNA / Orfandad / Violencia), nivel de prioridad, entidad federativa o rango de fechas. El sistema ejecuta una consulta FTS sobre el índice GIN (to_tsquery) y retorna los resultados ordenados por ts_rank en < 200 ms.
CU-04	Consultar Ficha de Caso Identificado	El actor selecciona una noticia de prioridad Alta. El sistema renderiza la ficha de caso mostrando: título, medio, fecha, resumen semántico, clúster BERTopic asignado, score BETO, y las detecciones de víctimas y entidades geográficas identificadas por el pipeline. El actor puede añadir notas de investigación.
CU-05	Gestionar Fuentes de Datos (CRUD)	El actor agrega, edita o desactiva una URL de fuente RSS o HTML. Al agregar, el sistema ejecuta un health check HTTP GET y valida que el endpoint responda con código 200. Las fuentes desactivadas son excluidas del siguiente ciclo de recolección sin eliminar su historial.
CU-06	Marcar Caso en Seguimiento	El actor activa la bandera en_seguimiento sobre un caso identificado. El sistema persiste el registro en la tabla detecciones y lo añade a la vista "Seguimiento de Casos" donde es monitoreable de forma independiente.
CU-07	Exportar Datos Estructurados (CSV)	El actor solicita la exportación de un subconjunto filtrado de noticias. El sistema serializa los campos titulo, medio, fecha, prioridad, cluster_id, score_beto, victimas, entidades en formato CSV y lo entrega como descarga HTTP con tipo MIME text/csv; charset=utf-8.
CU-08	Ejecutar Análisis Manual On-Demand	El actor solicita un ciclo de análisis inmediato (sin esperar el scheduler de 6 horas). El sistema encola la tarea de recolección+análisis y retorna un identificador de trabajo. El actor puede consultar el estado del proceso mediante polling al endpoint /api/v1/status/{job_id}.

2.2. Requerimientos Funcionales del Motor Back-end

Los Requerimientos Funcionales (RF) de esta sección describen el comportamiento interno del sistema que opera de forma autónoma, sin intervención del usuario. Se organizan en cinco subsistemas del pipeline: Recolección, Deduplicación, Análisis Semántico, Agrupamiento y Persistencia.

2.2.1. RF — Subsistema de Recolección de Datos

Tabla 2.2: Requerimientos Funcionales: Subsistema de Recolección

ID	Requerimiento	Descripción Técnica
RF-01	Ingesta RSS Multi-fuente	El sistema debe parsear feeds RSS 2.0 y Atom de 45 fuentes configuradas mediante <code>feedparser</code> , extrayendo por cada <code><item></code> : <code>title</code> , <code>link</code> , <code>summary</code> , <code>published</code> . El intervalo de recolección es de 6 horas, gestionado por <code>scheduler.py</code> . Los feeds no modificados (mismo ETag o Last-Modified) son omitidos sin re-descarga.
RF-02	Recolección HTML con Evasión de WAF	Para fuentes sin RSS, el sistema debe realizar requests HTTP mediante <code>StealthSession v7.0</code> , que utiliza <code>cloudscraper</code> para generar hashes TLS/JA3 idénticos a Chrome/Windows. Los intervalos entre requests deben seguir la distribución $\mathcal{LN}(\mu = 2,5, \sigma = 0,7)$ (mediana ≈ 12 s). El sistema debe respetar las directivas <code>robots.txt</code> de cada dominio.
RF-03	Circuit Breaker por Dominio	Ante 3 fallos HTTP consecutivos sobre un mismo dominio (códigos 403, 429, 5xx), el sistema debe abrir el Circuit Breaker y suspender requests a ese dominio por 300 s. El estado (abierto/cerrado/semi-abierto) debe persistirse en memoria de proceso para sobrevivir fallos de red transitorios.
RF-04	Recolección Histórica (Google News API)	El sistema debe ejecutar consultas a Google News mediante 14 queries de dominio predefinidas (ej. <i>"feminicidio hijos huérfanos México"</i>) para recuperar noticias históricas con antigüedad de hasta 90 días. Los resultados deben integrarse al mismo pipeline de deduplicación y análisis que las noticias RSS.

2.2.2. RF — Subsistema de Deduplicación en Cascada

Tabla 2.3: Requerimientos Funcionales: Subsistema de Deduplicación

ID	Requerimiento	Descripción Técnica
RF-05	Hash Exacto MD5	Antes de insertar cualquier noticia, el sistema debe calcular el hash MD5 del contenido textual normalizado (minúsculas, sin stopwords) y verificar su ausencia en la tabla <code>noticias.hash_md5</code> . Las colisiones exactas se descartan en $O(1)$ sin procesamiento adicional.
RF-06	Detección de Cuasi-duplicados (SimHash)	Para noticias que superan la barrera MD5, el sistema debe calcular un SimHash de 64 bits basado en pesos TF-IDF de los tokens. Dos noticias con distancia de Hamming ≤ 6 bits se consideran cuasi-duplicadas; la más reciente se descarta y la más antigua se conserva.
RF-07	Similitud de Jaccard sobre Títulos	El sistema debe tokenizar el título de cada noticia nueva y calcular el coeficiente de Jaccard contra los títulos del corpus reciente (ventana de 48 h). Un valor $J \geq 0,70$ clasifica el par como redundante; la nueva noticia se descarta.
RF-08	Similitud Coseno TF-IDF sobre Contenido	Como última barrera, el sistema debe vectorizar el contenido de noticias candidatas con TF-IDF y calcular la similitud coseno. Un valor $\cos \geq 0,85$ confirma la duplicación semántica; solo se retiene el documento con mayor score BETO.

2.2.3. RF — Subsistema de Análisis Semántico Neuro-Simbólico

Tabla 2.4: Requerimientos Funcionales: Subsistema de Análisis Semántico (Motor BETO)

ID	Requerimiento	Descripción Técnica
RF-09	Preprocesamiento de Texto	El sistema debe normalizar cada noticia: eliminación de HTML residual, normalización Unicode NFC, colapso de espacios y reducción a 512 tokens mediante truncación centrada (primeros 256 + últimos 256 tokens WordPiece) para respetar el límite de secuencia de BETO.
RF-10	Bypass de Oro (Capa Simbólica Afirmativa)	Antes de invocar BETO, el sistema debe evaluar el texto contra el diccionario de “Palabras de Oro” (expresiones de alta precisión: “ <i>hijos quedaron huérfanos</i> ”, “ <i>menores al cuidado del DIF</i> ”, etc.). Si se activa al menos un patrón, la noticia recibe prioridad Alta directamente sin inferencia neuronal, reduciendo la carga computacional.
RF-11	Bozal de Penalización (Capa Simbólica Restrictiva)	El sistema debe evaluar patrones de penalización antes de la inferencia BETO (e.g., “ <i>menor detenido</i> ”, “ <i>estadística de feminicidios</i> ”, “ <i>feminicidio de una menor</i> ” [víctima directa menor de edad]). Cada patrón activado aplica una penalización $\delta \in [0,1,0,4]$ al score final. La suma de penalizaciones no puede exceder 0.8 (límite de descarte).
RF-12	Clasificación Zero-Shot BETO	El sistema debe calcular el embedding BETO ([CLS] token, última capa) del texto preprocesado y su similitud coseno contra los embeddings precomputados de las descripciones de las clases “relevante” y “no relevante”. La similitud debe amplificarse con factor $\alpha = 5$ (temperature scaling) antes de la función softmax para polarizar distribuciones sub-confiadas.
RF-13	Evaluación de 4 Ejes Semánticos	La clasificación final debe desagregarse en 4 ejes independientes: (1) Feminicidio confirmado, (2) Presencia de NNA en la narrativa, (3) Indicador de orfandad/resguardo institucional, (4) Violencia de género contextual. Cada eje genera un score $\in [0,1]$ que contribuye al score compuesto mediante el Factor Alpha Dinámico: $S_{final} = \alpha_{ctx} \cdot S_{BETO} + (1 - \alpha_{ctx}) \cdot S_h$.
RF-14	Asignación de Prioridad	El sistema debe asignar nivel de prioridad según umbrales calibrados: Alta : $S_{final} \geq 0,75$ o Bypass de Oro activado; Media : $0,50 \leq S_{final} < 0,75$; Baja : $S_{final} < 0,50$ (registrada pero no alertada). Las noticias con Bozal acumulado $\geq 0,8$ se descartan y se registran en el log de descarte para auditoría.
RF-15	Extracción de Entidades Nombradas	El sistema debe identificar entidades nombradas en el texto clasificado como relevante: (a) Entidades geográficas (estado, municipio) mediante patrones georreferenciados; (b) Víctimas adultas (nombre propio de la madre feminicida); (c) Indicadores de resguardo institucional (DIF, Casa Hogar, tutor). Los nombres de menores nunca deben ser extraídos ni almacenados (RNF-04).

2.2.4. RF — Subsistema de Agrupamiento Semántico (BERTopic)

Tabla 2.5: Requerimientos Funcionales: Subsistema de Agrupamiento BERTopic

ID	Requerimiento	Descripción Técnica
RF-16	Reducción de Dimensionalidad UMAP	El sistema debe reducir los embeddings BETO de 768 a 5 dimensiones mediante UMAP con parámetros: <code>n_neighbors=15</code> , <code>min_dist=0.0</code> , <code>metric='cosine'</code> , <code>random_state=42</code> . La proyección debe ejecutarse sobre el corpus completo del ciclo antes de la clasificación individual.
RF-17	Clustering HDBSCAN	El sistema debe ejecutar HDBSCAN sobre el espacio UMAP con parámetros: <code>min_cluster_size=8</code> , <code>min_samples=5</code> , <code>cluster_selection_method='eom'</code> , <code>prediction_data=True</code> . Los documentos con <code>topic_id=-1</code> (outliers) deben ser procesados por la reducción multi-etapa (probabilidades → distribuciones → embeddings) con objetivo de outliers $\leq 55\%$.
RF-18	Representación c-TF-IDF de Tópicos	Para cada clúster identificado, el sistema debe calcular el c-TF-IDF con <code>ngram_range=(1,3)</code> y stop words en español, generando los 10 términos más representativos. La representación final debe refinarse con KeyBERTInspired (similitud coseno embedding del n-grama vs. centroide del clúster).
RF-19	Contexto de Outlier para Clasificación	Las noticias con <code>topic_id=-1</code> tras la reducción de outliers deben recibir una penalización contextual en la lógica neuro-simbólica: el umbral de BETO se eleva de 0.50 a 0.65 para estas noticias, requiriendo mayor certeza semántica para clasificarlas como relevantes.

2.2.5. RF — Subsistema de Persistencia Relacional

Tabla 2.6: Requerimientos Funcionales: Subsistema de Persistencia

ID	Requerimiento	Descripción Técnica
RF-20	Persistencia Transaccional ACID	Toda inserción de resultados del pipeline (noticia + detección + cluster) debe ejecutarse dentro de una transacción SQLAlchemy. En caso de excepción en cualquier operación, se debe ejecutar <code>session.rollback()</code> automático para prevenir registros huérfanos o parcialmente procesados.
RF-21	Índice GIN para Full-Text Search	La columna <code>noticias.search_vector(tsvector)</code> debe mantenerse actualizada mediante un trigger SQL que se ejecuta en cada INSERT y UPDATE, concatenando título (peso A) y contenido (peso B) con el diccionario Snowball español. El índice GIN debe garantizar consultas FTS en $O(\log n)$.
RF-22	API REST de Consulta	El sistema debe exponer los endpoints GET <code>/api/v1/noticias</code> , GET <code>/api/v1/clusters</code> , GET <code>/api/v1/detecciones</code> con soporte de paginación (<code>page/per_page</code>), filtros combinados y respuesta en <code>application/json</code> . El tiempo de respuesta máximo es de 500 ms para consultas sobre el índice GIN.

2.3. Requerimientos No Funcionales

Tabla 2.7: Requerimientos No Funcionales: Métricas de Calidad y Restricciones

ID	Atributo	Descripción Técnica y Métrica
RNF-01	Rendimiento: Procesamiento por Lote	El pipeline completo (recolección + deduplicación + BETO + BERTopic + persistencia) debe procesar un lote de 600–1,000 noticias en un tiempo máximo de 45 minutos sobre CPU de propósito general (Intel Core i5, 8 GB RAM, sin GPU), garantizando que el ciclo de 6 horas sea holgadamente completable. La inferencia BETO sobre lotes de 100 noticias no debe exceder 3 minutos.
RNF-02	Rendimiento: Consultas en Tiempo Real	Las consultas FTS desde el dashboard (filtros por eje semántico, rango de fechas, prioridad) deben retornar resultados en < 200 ms sobre una tabla con $\leq 100,000$ registros, garantizado mediante el índice GIN. Las respuestas de la API REST deben cumplir el SLA de 500 ms al percentil 95.
RNF-03	Integridad Transaccional (ACID)	La base de datos PostgreSQL debe operar bajo el modelo ACID con MVCC. Ante fallo del contenedor nna-analyzer durante un batch, el Write-Ahead Log debe garantizar que los registros confirmados (COMMIT) persistan y los no confirmados no corrompan el esquema. El <i>Rollback</i> automático debe ejecutarse en < 1 s ante excepción Python.
RNF-04	Privacidad y Ética (LGDNNA)	El sistema tiene prohibición absoluta de almacenar, indexar, exportar o renderizar los nombres propios de los menores afectados. El módulo de extracción de entidades debe aplicar una lista de exclusión de roles menores (“hijo(s)”, “hija(s)”, “menor(es)”) que impide la asociación nombre-menor en cualquier capa del pipeline. Esta restricción opera como constraint a nivel de código, no como configuración.
RNF-05	Seguridad: Autenticación (OWASP A07)	Las contraseñas de acceso al dashboard deben almacenarse exclusivamente como hashes Argon2id (parámetros: memory=65536 KB, iterations=3, parallelism=4), resistente a ataques de GPU y side-channel. Las sesiones Flask deben gestionarse mediante tokens firmados con HMAC-SHA256 (secret.key de 256 bits, rotación trimestral). Tras 5 intentos fallidos se bloquea la cuenta por 15 minutos (OWASP A07:2021 — Identification and Authentication Failures).
RNF-06	Seguridad: Protección de API (OWASP A01)	Todos los endpoints <code>/api/v1/*</code> deben requerir autenticación mediante token de sesión válido. Las respuestas deben incluir las cabeceras de seguridad: <code>X-Content-Type-Options: nosniff</code> , <code>X-Frame-Options: DENY</code> , <code>Content-Security-Policy</code> . Las entradas de filtro de consulta deben ser parametrizadas vía SQLAlchemy ORM (prevención de SQL Injection, OWASP A03).
RNF-07	Resiliencia: Exponencial Backoff	Ante errores HTTP 429 (Rate Limit) o 503 (Service Unavailable) durante la recolección, el sistema debe reintentar con espera exponencial: $t_k = t_0 \cdot 2^k$ con $t_0 = 5$ s y máximo 5 reintentos ($t_{max} = 160$ s). Si el quinto reintento falla, se registra el error en el log y se continúa con la siguiente fuente sin

Justificación y Alcance del Proyecto

En este capítulo se presenta la justificación social, tecnológica y ética que sustenta el desarrollo del *Sistema Inteligente para la Identificación y Seguimiento de NNA* y se delimita el alcance del sistema, sus limitaciones y la alineación con el protocolo de Trabajo Terminal 2026-A135.

3.1. Justificación Social

Entre 2010 y 2023 más de 8,000 mujeres fueron víctimas de feminicidio en México, según datos de la Secretaría de Gobernación [?]. Detrás de estas cifras se encuentran miles de niñas, niños y adolescentes (NNA) que quedaron en condición de orfandad. La Red por los Derechos de la Infancia en México (REDIM) estima que al menos 3,500 NNA perdieron a su madre por feminicidio entre 2012 y 2022 [?], sin embargo no existe un censo oficial ni un sistema de seguimiento que permita dimensionar con precisión el alcance de esta crisis.

La información sobre los hijos e hijas de las víctimas se encuentra fragmentada y dispersa pues puede aparecer en una nota periodística local, en el comunicado de una fiscalía estatal o en los archivos internos de alguna organización civil. Sin un mecanismo que conecte estos fragmentos de información resulta prácticamente imposible rastrear qué ha sucedido con esos menores y de si recibieron atención psicológica, si mantienen acceso a educación, si se les garantizó reparación del daño o si fueron canalizados a instituciones como en el DIF.

Algunas de las consecuencias de esta dispersión son:

- **Para las organizaciones civiles:** Organizaciones como *Futuro con Derechos* dedican varias horas semanales a revisar manualmente decenas de sitios de noticias buscando casos donde se mencione a hijos de víctimas de feminicidio. Reconocen que muchos casos pasan desapercibidos porque es imposible revisar todas las fuentes disponibles con recursos humanos limitados.
- **Para las autoridades:** Sin datos estructurados ni trazables las instituciones gubernamentales carecen de información para evaluar la efectividad de sus programas de atención a víctimas indirectas y para diseñar políticas públicas basadas en evidencia.
- **Para las familias:** Los familiares de las víctimas frecuentemente desconocen sus derechos, las instituciones de apoyo disponibles y los mecanismos de reparación del daño. La falta de un sistema de seguimiento dificulta la coordinación interinstitucional.

Un sistema automatizado que actúe como filtro inicial que procese cientos de noticias, identificando así las potencialmente relevantes y presentándolas estructuradas, permite que las organizaciones dediquen su tiempo al seguimiento de casos concretos en lugar de a la búsqueda manual de información.

3.2. Justificación Tecnológica

La revisión manual de medios de comunicación no es viable a escala nacional pues México cuenta con cientos de medios digitales (nacionales, estatales y locales) que publican diariamente noticias relacionadas con feminicidios. La cobertura periodística de cada caso varía significativamente pues algunos eventos son cubiertos por múltiples medios con redacciones diferentes, mientras que otros aparecen exclusivamente en medios regionales de bajo alcance.

Durante el desarrollo del Trabajo Terminal I, se probaron tres enfoques de recolección que evidenciaron la complejidad técnica del problema:

1. **Scraping directo (Prototipo 0):** Fracasó completamente. Los medios modernos emplean protecciones como cloudflare, contenido renderizado con JavaScript y bloqueos HTTP 403, haciendo complicada la extracción directa del HTML.
2. **RSS básico (Prototipo 1):** Funcionó parcialmente con 8 fuentes RSS, recolectando aproximadamente 56 noticias en dos semanas. La cuestión era que la cobertura se limitaba a medios nacionales con feeds públicos.
3. **Triple fuente (Prototipo 2):** Combinó 10 RSS, Google News y scraping histórico, alcanzando 250 noticias únicas. Este enfoque nos hizo ver que la viabilidad de la recolección multi-fuente existía, pero aún mantenía limitaciones en la detección semántica (Mas del 80 % de falsos positivos con expresiones regulares).

Trabajo Terminal II representa una evolución significativa de estas estrategias mediante la integración de tecnologías de procesamiento de lenguaje natural (PLN):

BETO (BERT en español): Modelo de lenguaje preentrenado con 110 millones de parámetros que permite comprender el contexto semántico de las noticias, distinguiendo entre casos concretos de feminicidio con NNA afectados y noticias de legislación, campañas o estadísticas que mencionan las mismas palabras clave.

BERTopic: Sistema de clustering semántico que combina embeddings contextuales (BETO), reducción de dimensionalidad (UMAP) y clustering basado en densidad (HDBSCAN) para agrupar noticias por similitud de significado, no solo de vocabulario.

Deduplicación: Sistema de cuatro algoritmos (Hash MD5, Jaccard, SimHash, TF-IDF coseno) que elimina automáticamente noticias duplicadas o cuasi-duplicadas provenientes de diferentes medios.

PostgreSQL: Base de datos relacional que reemplaza el almacenamiento en archivos CSV lo que habilita consultas complejas, integridad referencial y acceso concurrente.

Gracias a estas tecnologías se transforma texto no estructurado en datos consultables, permitiendo análisis cuantitativos (tendencias temporales, distribución geográfica) y cualitativos (agrupación temática, seguimiento de casos) que serían imposibles mediante revisión manual.

3.3. Justificación ética y moral: Protección de la privacidad de los NNA

3.3.1. El interés superior del niño

El desarrollo de este sistema se enmarca en un principio ético fundamental: **el interés superior del niño**, establecido en el artículo 3 de la Convención sobre los Derechos del Niño de las Naciones Unidas [?] y en el artículo 2 de la Ley General de los Derechos de Niñas, Niños y Adolescentes de México [?]. Este principio establece que cualquier acción que involucre a menores de edad debe priorizar su bienestar, protección y dignidad por encima de cualquier otro interés.

En base a este principio, el sistema ha sido diseñado desde su inicio con una restricción no negociable: **priorizar el manejo cuidadoso y confidencial de la información obtenida de los NNA.**

3.3.2. Naturaleza de la información procesada

Es importante aclarar la naturaleza de los datos que el sistema procesa y la distinción entre lo que el sistema *identifica* y lo que *no identifica*:

Tabla 3.1: Distinción entre información procesada y excluida

El sistema SÍ identifica	El sistema NO identifica
Noticias que mencionan feminicidios	Nombres completos de los NNA afectados
Menciones genéricas a NNA como víctimas indirectas (ej. "dejó 3 hijos menores")	Datos personales de los menores (edad exacta, CURP, domicilio)
Contexto del caso: ubicación geográfica, fecha, instituciones involucradas	Identidad verificada de ningún menor
Nombres de víctimas adultas (cuando aparecen en la nota periodística)	Fotografías ni datos biométricos de NNA
Patrones y tendencias estadísticas	Información no publicada en medios

3.3.3. ¿Por qué el sistema no proporciona nombres de NNA?

La ausencia de nombres e identidades de los NNA en los resultados del sistema **no es una limitación técnica, sino una decisión ética respaldada por un marco normativo y periodístico sólido:**

1. **Los medios de comunicación protegen la identidad de los menores.** El Código de Ética Periodística de la UNESCO y los códigos editoriales de los principales medios mexicanos establecen que la identidad de los NNA víctimas —directas o indirectas— debe ser resguardada. Por esta razón, las notas periodísticas que constituyen la fuente primaria del sistema rara vez incluyen los nombres completos de los menores. En su lugar, utilizan referencias genéricas: "sus tres hijos menores de edad", "una niña de 5 años", "los menores quedaron bajo custodia de la abuela". Esta práctica periodística responsable se refleja necesariamente en los datos que el sistema puede extraer.
2. **La Ley General de los Derechos de Niñas, Niños y Adolescentes (LGDNNA).** El artículo 76 de la LGDNNA prohíbe la difusión de datos personales de NNA que permitan su identificación cuando estos se encuentran en situación de vulnerabilidad. Los NNA que han perdido a su madre por feminicidio se encuentran, por definición, en una de las situaciones de mayor vulnerabilidad contempladas por la ley. Cualquier sistema que pretendiera identificarlos nominalmente estaría en violación directa de esta disposición legal.

3. **El Protocolo de Palermo y la normativa internacional.** Los instrumentos internacionales de protección a la infancia, incluido el Protocolo Facultativo de la Convención sobre los Derechos del Niño, establecen que los Estados deben garantizar la privacidad de los menores víctimas en todos los procedimientos, incluidos los de documentación e investigación. Nuestro sistema respeta este marco al limitarse a identificar *la existencia* de NNA afectados, sin revelar *quiénes son*.
4. **Principio de minimización de datos (RGPD/LFPDPPP).** Siguiendo las mejores prácticas internacionales de protección de datos —reflejadas en el Reglamento General de Protección de Datos de la Unión Europea y en la Ley Federal de Protección de Datos Personales en Posesión de Particulares de México— el sistema recolecta y almacena únicamente los datos estrictamente necesarios para cumplir su propósito: identificar *la existencia de noticias* sobre NNA afectados, no la identidad de los NNA mismos.

3.3.4. Fortaleza ética del enfoque adoptado

Lejos de ser una debilidad, esta restricción constituye una **fortaleza ética fundamental** del sistema:

- **El sistema identifica el fenómeno, no a las personas.** Su valor radica en hacer visible la dimensión de la crisis de orfandad por feminicidio —cuántos casos, dónde, con qué frecuencia— sin comprometer la dignidad ni la privacidad de los menores involucrados.
- **Herramienta de apoyo, no sustituto de intervención.** El sistema está concebido como un instrumento de alerta temprana y documentación que facilita el trabajo de organizaciones especializadas. La intervención social, la verificación de datos y el contacto con las familias corresponden exclusivamente a profesionales capacitados en trabajo social, psicología y derecho, quienes operan bajo protocolos estrictos de confidencialidad.
- **Alineación con IA ética.** El diseño del sistema se adhiere a los principios de Inteligencia Artificial ética establecidos por la OECD [?]: transparencia en el procesamiento, responsabilidad en el uso de datos, y priorización del bienestar humano sobre la capacidad técnica.

3.3.5. Compromiso de privacidad

El equipo de desarrollo establece el siguiente compromiso formal:

El Sistema Inteligente para la Identificación y Seguimiento de NNA se compromete a no recolectar, almacenar, procesar ni difundir datos personales de niñas, niños y adolescentes. Toda la información procesada proviene exclusivamente de fuentes periodísticas públicas, y los resultados del sistema se limitan a identificar la existencia de noticias relevantes, patrones estadísticos y tendencias temporales, sin revelar la identidad de ningún menor de edad.

3.4. Alcance del Sistema

3.4.1. Alcance funcional

El sistema desarrollado abarca las siguientes capacidades, implementadas progresivamente a lo largo de cinco prototipos (P0–P4):

- **Recolección automatizada multi-fuente:** Extracción de noticias desde aproximadamente 45 fuentes RSS, 14 queries de Google News, scraping dinámico de HTML/Sitemap y búsquedas en Google Search con StealthSession.
- **Detección semántica de relevancia:** Clasificación de noticias mediante un scoring de 4 ejes (feminicidio, NNA, caso individual, víctima indirecta) utilizando el modelo BETO (BERT en español) con inferencia por lotes (batch inference) en PyTorch.

- **Deduplicación cross-site:** Eliminación automática de noticias duplicadas o cuasi-duplicadas mediante cascada de 4 algoritmos (Hash MD5, Jaccard, SimHash, TF-IDF coseno).
- **Clustering semántico:** Agrupación de noticias por similitud de significado mediante BERTopic (BETO embeddings + UMAP + HDBSCAN + c-TF-IDF).
- **Almacenamiento relacional:** Persistencia en PostgreSQL con esquema normalizado, Full-Text Search e índices optimizados.
- **Dashboard interactivo:** Interfaz web con autenticación (Argon2id), gestión de fuentes, filtros avanzados, visualización de estadísticas con Chart.js y exportación de datos.
- **Gestión de fuentes:** Módulo para agregar, editar, probar, sondear y activar/desactivar fuentes de noticias directamente desde la interfaz web.

3.4.2. Alcance geográfico y temporal

Geográfico: Cobertura nacional con énfasis en medios mexicanos. Incluye medios nacionales (La Jornada, Proceso, Animal Político, El Universal, Milenio, entre otros), medios especializados en género y derechos humanos (CIMAC Noticias, Luchadoras) y medios regionales (El Sol de Toluca, Diario de Xalapa, Noroeste, entre otros).

Temporal: El sistema procesa noticias desde enero de 2025 hasta la fecha actual (mayo 2026), con capacidad de extensión retrospectiva mediante el módulo de scraping histórico.

3.5. Limitaciones y exclusiones

3.5.1. Exclusiones explícitas del alcance

El sistema **no** contempla las siguientes funcionalidades:

- No identifica ni almacena nombres ni datos personales de NNA reales (justificación ética detallada en la Sección 3.3).
- No realiza intervención social directa. Es una herramienta de documentación y alerta, no un sistema de gestión de casos.
- No accede a bases de datos gubernamentales cerradas (fiscalías, DIF, registros civiles). Toda la información proviene de fuentes periodísticas públicas.
- No valida la veracidad de las noticias. El sistema asume que las fuentes periodísticas monitoreadas mantienen estándares editoriales mínimos pero no verifica la veracidad de cada nota.
- No implementa Named Entity Recognition (NER) completo con fine-tuning. Esta funcionalidad se identifica como trabajo futuro.

3.5.2. Limitaciones técnicas

1. **Dependencia de fuentes periodísticas:** La cobertura del sistema está limitada a lo que los medios publican. Feminicidios no cubiertos por la prensa o que ocurren en zonas con escasa cobertura mediática no serán detectados.
2. **Precisión del modelo semántico:** Aunque BETO mejora sustancialmente la detección respecto a los patrones regex del TT1, el modelo de zero-shot classification tiene limitaciones inherentes al no estar fine-tuned específicamente para el dominio. Se estima una tasa de falsos positivos $\leq 5\%$.
3. **Protecciones anti-scraping:** Algunos medios implementan protecciones agresivas (CAPTCHAs, rate limiting estricto, paywalls) que pueden impedir la recolección de sus contenidos.

4. **Latencia en tiempo real:** El sistema opera con ciclos de recolección programados (cada 6–24 horas), no en tiempo real. Existe un desfase entre la publicación de una noticia y su procesamiento.
5. **Idioma:** El sistema está optimizado exclusivamente para noticias en español. Noticias en lenguas indígenas o en inglés no son procesadas.

3.6. Alineación con el protocolo

El desarrollo del trabajo terminal se alinea con las metas y entregables definidos en el protocolo no. 2026-A135, aprobado por la comisión de trabajos terminales. La siguiente tabla muestra la correspondencia entre los objetivos del protocolo y los componentes implementados:

Tabla 3.2: Correspondencia entre objetivos del protocolo y componentes implementados

Meta del Protocolo	Componente Implementado	Estado
Migrar detección de regex a modelos semánticos	SemanticDetector con BETO (zero-shot + 4 ejes)	✓
Implementar base de datos relacional	PostgreSQL con SQLAlchemy ORM	✓
Ampliar cobertura de fuentes	45+ fuentes RSS + Google Search + scraping dinámico	✓
Implementar clustering semántico	BERTopic (BETO + UMAP + HDBSCAN)	✓
Desarrollar interfaz web completa	Dashboard con autenticación, gestión de fuentes, filtros	✓
Deduplicación avanzada	Cascada de 4 fases (Hash, Jaccard, SimHash, TF-IDF)	✓
Implementar NER completo	Parcial: extracción contextual básica	~

Nota: La implementación de Named Entity Recognition (NER) con fine-tuning de spaCy, originalmente contemplada en el protocolo, se implementó de forma parcial mediante extracción contextual basada en patrones. La versión completa con modelos fine-tuned se identifica como trabajo futuro, justificado por la priorización de la precisión del detector semántico y la estabilización de la arquitectura de producción.

En este capítulo se establece el fundamento matemático y conceptual que sustenta la arquitectura neuro-simbólica del Sistema Inteligente para la Identificación y Seguimiento de NNA. Cada sección describe una tecnología implementada en el sistema y justifica su adopción frente a las alternativas disponibles, trazando así una línea directa entre los principios teóricos formales y las decisiones de implementación documentadas.

4.1. Procesamiento de lenguaje natural y representación lingüística

El Procesamiento de lenguaje natural (PLN) comprende el conjunto de técnicas computacionales orientadas a la comprensión, generación y manipulación del lenguaje humano en formato textual. El dominio específico de este proyecto; que son noticias periodísticas mexicanas en español sobre violencia feminicida, exige herramientas de PLN que capturen la semántica contextual del lenguaje, trascendiendo la mera relación de palabras.

4.1.1. Tokenización y el algoritmo WordPiece

La tokenización es el proceso mediante el cual una cadena de texto se divide en unidades elementales de representación (*tokens*) que el modelo puede procesar. Los enfoques clásicos segmentan el texto a nivel de palabra completa lo que genera vocabularios de tamaño inmanejable (más de 500,000 tipos) y deja fuera de vocabulario cualquier término no visto durante el entrenamiento.

El modelo BETO al igual que toda la familia BERT, emplea el algoritmo **WordPiece** [?], el cual es un esquema de segmentación sub-léxica que descompone las palabras en secuencias de sub-unidades frecuentes. El algoritmo construye el vocabulario de forma incremental: inicializa el conjunto con todos los caracteres individuales del corpus y fusiona iterativamente los pares de sub-unidades que maximizan la verosimilitud del corpus de entrenamiento bajo un modelo de lenguaje:

$$\text{Puntuación}(u_1, u_2) = \frac{P(u_1 u_2)}{P(u_1) \cdot P(u_2)} \quad (4.1)$$

Donde u_1 y u_2 son sub-unidades adyacentes y $P(\cdot)$ denota la probabilidad del sub-token en el corpus. Las fusiones con mayor puntuación se aplican repetidamente hasta alcanzar el tamaño de vocabulario objetivo (30,000 tokens para

BETO). Los sub-tokens que continúan una palabra se prefijan con ## para distinguirlos de tokens iniciales, por ejemplo: "feminicidio" se tokeniza como fem##ini##cid##io.

Este esquema tiene dos consecuencias técnicas que son fundamentales para el dominio del sistema. Primero, las palabras desconocidas como neologismos o nombres propios se descomponen en sub-tokens conocidos en lugar de ser descartadas, para así preservar parcialmente su información. Segundo, el entrenamiento con *Whole Word Masking* (WWM) garantiza que todos los sub-tokens de una misma palabra se enmascaren conjuntamente, forzando al modelo a aprender representaciones semánticamente coherentes de términos especializados de múltiples sub-unidades.

Además BETO utiliza dos tokens especiales de estructura: [CLS] (primer token de toda secuencia, cuyo vector de salida representa a la secuencia completa para tareas como clasificación) y [SEP] (que es mas como un separador entre dos segmentos de texto distintos).

4.1.2. Lematización y normalización lexicológica

La lematización es el proceso de reducir una forma flexionada de una palabra a su lema canónico (forma base del diccionario), considerando el contexto morfosintáctico. Se distingue de la *stemming* en que produce formas lingüísticamente válidas: "feminicidios" → "feminicidio" (lematización), no "feminicid" (stemming).

En el sistema, la lematización se emplea en la capa de preprocesamiento del módulo de búsqueda por sinónimos (SynonymDictionary) y en el vectorizador TF-IDF de deduplicación, donde la normalización morfológica reduce la dispersión léxica del vocabulario y mejora la robustez de las métricas de similitud ante variaciones de tiempo verbal, número y género gramaticales comunes en el periodismo mexicano. PostgreSQL aplica su propio proceso de lematización para español (diccionario Snowball) al momento de construir el *tsvector* para la búsqueda de texto completo, cubriendo el caso de recuperación de información en el dashboard.

4.1.3. Modelo de espacio vectorial: TF-IDF

La representación vectorial clásica de documentos de texto se articula mediante el modelo *Term Frequency - Inverse Document Frequency* (TF-IDF) [?]. El peso asignado a un término t en un documento d dentro de una colección D se calcula como el producto de dos factores:

$$\text{TF-IDF}(t, d, D) = \text{TF}(t, d) \times \text{IDF}(t, D) \quad (4.2)$$

Donde la frecuencia de término $\text{TF}(t, d)$ mide la proporción de ocurrencias del término en el documento:

$$\text{TF}(t, d) = \frac{f_{t,d}}{\sum_{t' \in d} f_{t',d}} \quad (4.3)$$

Y la frecuencia inversa de documento $\text{IDF}(t, D)$ penaliza los términos ubicuos en la colección (que aportan poca información discriminativa) y premia los términos raros:

$$\text{IDF}(t, D) = \log \frac{|D|}{|\{d \in D : t \in d\}| + 1} \quad (4.4)$$

Este sistema implementa una variante de TF-IDF que multiplica el peso de términos del glosario de dominio (por ejemplo: "orfandad", "DIF", "resguardo") por un factor amplificador $\beta > 1$ que incrementa artificialmente su IDF efectivo. Esta modificación operacionaliza el conocimiento experto del dominio en el espacio vectorial sin requerir reentrenamiento. TF-IDF se emplea en el sistema exclusivamente para las fases de deduplicación y el módulo de sinónimos; la clasificación de relevancia utiliza exclusivamente los embeddings BETO.

4.1.4. Arquitectura Transformer y mecanismo de auto-atención

La arquitectura *Transformer* [?] constituye el fundamento de todos los modelos de lenguaje de última generación. A diferencia de las Redes Neuronales Recurrentes (RNN) y las LSTM, que procesan la secuencia de tokens de forma estrictamente lineal, generando un estado oculto h_t en función del estado h_{t-1} y el token actual, el Transformer prescinde de la recurrencia. Todas las posiciones de la secuencia se procesan en paralelo mediante el mecanismo de auto-atención multi-cabeza (*Multi-Head Self-Attention*).

Para cada token x_i de la secuencia, el mecanismo de atención computa tres vectores: una consulta $Q_i = x_i W^Q$, una clave $K_i = x_i W^K$ y un valor $V_i = x_i W^V$, donde $W^Q, W^K, W^V \in \mathbb{R}^{d_{model} \times d_k}$ son matrices de proyección aprendidas. La relevancia del token j para el token i se calcula como el producto punto de sus vectores de consulta y clave, escalado para evitar saturación del gradiente en la función softmax:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (4.5)$$

Donde d_k es la dimensión de las claves. La salida para el token i es una suma ponderada de todos los vectores V_j de la secuencia, con pesos determinados por la similitud de atención. Esto permite que "menor.^{en} la posición i reciba contribuciones directas de resguardo del DIF.^{en} la posición j , sin importar la distancia lineal entre ambas posiciones.

La auto-atención multi-cabeza ejecuta h instancias paralelas del mecanismo de atención, cada una con sus propias proyecciones W_i^Q, W_i^K, W_i^V , y concatena sus salidas.

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O \quad (4.6)$$

Donde cada cabeza captura un tipo diferente de relación semántica o sintáctica. BERT-base emplea $h = 12$ cabezas en cada una de sus 12 capas de transformación.

4.1.5. BETO: representaciones bidireccionales para el español

BERT (*Bidirectional Encoder Representations from Transformers*) [?] extiende la arquitectura Transformer original mediante el preentrenamiento bidireccional: en lugar de predecir el siguiente token (modelado de lenguaje causal como GPT) BERT se entrena con el objetivo de **Modelado de Lenguaje Enmascarado** (MLM). En cada secuencia de entrenamiento el 15 % de los tokens se enmascara aleatoriamente y el modelo debe predecir el token original usando el contexto *bidireccional completo* (los tokens a la izquierda y a la derecha de la máscara). Este objetivo fuerza al modelo a desarrollar representaciones profundamente contextuales.

BETO [?] (*bert-base-spanish-wwm-cased*) es la instancia monolingüe de BERT preentrenada exclusivamente en español, con la siguiente arquitectura base:

- 12 capas Transformer (encoders)
- 12 cabezas de atención por capa
- Dimensión del espacio oculto: $d_{model} = 768$
- 110 millones de parámetros entrenables
- Vocabulario WordPiece de 30,000 tokens en español

El corpus de preentrenamiento incluye wikipedia en español (aproximadamente 3 GB), OpenSubtitles, ParaCrawl, MultiUN (corpus OPUS) y fuentes de prensa latinoamericana. Esta composición es crítica para el dominio del sistema pues el periodismo latinoamericano posee un estilo de redacción y un léxico que difieren del español peninsular. Los corpus de prensa incluidos en el preentrenamiento de BETO sesgan sus representaciones hacia el vocabulario y las

construcciones sintácticas empleadas por los medios de comunicación mexicanos, lo cual mejora la calidad de los embeddings para el dominio específico del sistema.

La representación semántica de una noticia se extrae del *hidden state* del token especial [CLS] en la última capa del encoder que es un vector de 768 dimensiones que condensa el significado global de la secuencia completa. Este vector se normaliza mediante norma L2 para habilitar la comparación por similitud coseno:

$$\hat{e} = \frac{e}{\|e\|_2}, \quad e = \text{BETO}(\text{texto})[0, :] \quad (4.7)$$

Donde $e \in \mathbb{R}^{768}$ es el embedding crudo del token [CLS] y $\hat{e}$ es su versión normalizada empleada en la clasificación zero-shot.

4.2. Paradigmas de inferencia y clasificación semántica

4.2.1. Clasificación zero-shot por similitud coseno

El paradigma de **clasificación zero-shot** [?] permite categorizar documentos en clases definidas en lenguaje natural sin que disponga de ejemplos etiquetados de entrenamiento para dichas clases. Esta implementación adoptada en el sistema es la clasificación por similitud coseno entre embeddings. Se precomputan representaciones BETO para descripciones textuales de las categorías de clasificación ("*noticia que reporta un caso concreto de feminicidio donde los hijos de la víctima quedaron en orfandad o bajo resguardo institucional*" para la clase *relevante*"; "*notas estadísticas, políticas públicas, reporte donde el menor es el agresor o feminicidio de una menor de edad*" para la clase *"no relevante"*).

En tiempo de inferencia, el embedding del texto $\hat{e}_{\text{texto}}$ se compara contra los embeddings de cada categoría $\hat{e}_c$ mediante el producto punto (lo que equivale a la similitud coseno):

$$s_c = \hat{e}_{\text{texto}} \cdot \hat{e}_c = \cos(\hat{e}_{\text{texto}}, \hat{e}_c) \quad (4.8)$$

La mayor ventaja de este paradigma sobre el fine-tuning supervisado es que el conocimiento experto del dominio se codifica directamente en las descripciones de categorías en lenguaje natural, lo cual hace que sean auditables y modificables por cualquier miembro del equipo sin necesidad de reentrenar el modelo. Por otro lado, el modelo neuronal aporta la capacidad de la generalización semántica aprendida durante el preentrenamiento.

4.3. Agrupamiento semántico y reducción de dimensionalidad

El agrupamiento semántico de documentos periodísticos tiene como objetivo identificar grupos de noticias que pertenecen al mismo tema independientemente del vocabulario empleado por cada medio. El sistema adopta **BERTopic** [?] como motor de agrupamiento, el cual su arquitectura modular encadena tres algoritmos independientes: UMAP para reducción de dimensionalidad, HDBSCAN para detección de clústeres de densidad variable y c-TF-IDF para la representación léxica de cada tópico descubierto.

4.3.1. UMAP: Proyección Topológica Preservadora de Estructura

Los *embeddings* generados por BETO están en $\mathbb{R}^{768}$. Si se aplica directamente algoritmos de agrupamiento sobre espacios de esta dimensionalidad, se produce resultados de baja calidad debido a la **maldición de la dimensionalidad** [?]: en espacios de alta dimensión, la razón entre la distancia al vecino más lejano y al vecino más cercano tiende a 1 asintóticamente, haciendo que las distancias euclidianas pierdan poder discriminatorio. En el límite, todos los puntos son aproximadamente equidistantes entre sí, privando a los algoritmos de agrupamiento de la señal de proximidad.

UMAP (*Uniform Manifold Approximation and Projection*) [?] proyecta los datos de alta dimensión a un espacio de dimensión reducida ($\mathbb{R}^5$ en el sistema) conservando la estructura topológica local y global. El algoritmo se fundamenta en tres principios de geometría Riemanniana y topología algebraica:

1. **Construcción del grafo topológico en alta dimensión.** Para cada punto x_i , se construye un grafo de vecindad ponderado G^{HD} donde el peso de la arista (x_i, x_j) representa la probabilidad de que x_j sea un vecino de x_i bajo una métrica Riemanniana local calibrada por la distancia al k -ésimo vecino más cercano de x_i . El parámetro $n_neighbors=15$ controla este radio de vecindad local.
2. **Construcción del grafo en baja dimensión.** Se inicializa un grafo G^{LD} análogo en $\mathbb{R}^5$, donde las aristas se ponderan mediante una función de distribución de densidad de probabilidad diferente (familia t -Student para evitar el crowding problem de t-SNE).
3. **Optimización por entropía cruzada.** Los pesos de G^{LD} se optimizan para minimizar la entropía cruzada difusa respecto a G^{HD} :

$$\mathcal{L} = \sum_{(i,j)} \left[w_{ij}^{HD} \log \frac{w_{ij}^{HD}}{w_{ij}^{LD}} + (1 - w_{ij}^{HD}) \log \frac{1 - w_{ij}^{HD}}{1 - w_{ij}^{LD}} \right] \quad (4.9)$$

La minimización de $\mathcal{L}$ mediante descenso de gradiente estocástico garantiza que la disposición en el espacio reducido preserve las relaciones de vecindad del espacio original.

La configuración `metric='cosine'` es crítica para el dominio de texto: los embeddings de lenguaje tienen magnitudes variables, y la similitud semántica se mide por el ángulo entre vectores, no por su distancia euclidiana. El parámetro `min_dist=0.0` comprime al máximo los clústeres, aumentando la densidad local y facilitando la separación de fronteras por HDBSCAN.

4.3.2. HDBSCAN: Agrupamiento Jerárquico por Densidad Variable

HDBSCAN (*Hierarchical Density-Based Spatial Clustering of Applications with Noise*) [?] extiende DBSCAN mediante la construcción de una jerarquía completa de clústeres, eliminando la dependencia de un parámetro global de densidad ϵ . El algoritmo opera en cuatro etapas:

1. **Distancia de alcanzabilidad mutua.** Para un parámetro `min_samples = m`, la distancia de alcanzabilidad mutua entre dos puntos x_i y x_j se define como:

$$d_{mreach}(x_i, x_j) = \max(\text{core}_m(x_i), \text{core}_m(x_j), d(x_i, x_j)) \quad (4.10)$$

donde $\text{core}_m(x_i)$ es la distancia del punto x_i a su m -ésimo vecino más cercano. Esta transformación suaviza regiones de baja densidad, separando los clústeres reales del ruido.

2. **Árbol de expansión mínima (MST).** Se construye el MST del grafo ponderado por distancias de alcanzabilidad mutua entre todos los pares de puntos.
3. **Jerarquía de clústeres.** El MST se convierte en una jerarquía de clústeres eliminando aristas en orden decreciente de peso (equivalente a reducir el umbral de densidad progresivamente). El dendrograma resultante codifica la estructura de clústeres a todas las escalas de densidad.
4. **Selección por Exceso de Masa (EoM).** El método *Excess of Mass* selecciona el subconjunto de clústeres en la jerarquía que maximiza la “persistencia” (estabilidad topológica medida como la diferencia entre el nivel de densidad de aparición y desaparición del clúster). Los puntos que no pertenecen a ningún clúster persistente reciben la etiqueta de ruido: `topic_id = -1`.

La etiqueta de ruido es semánticamente valiosa para el sistema: las noticias *outlier* que no comparten coherencia temática con ningún clúster del corpus son tratadas con mayor escepticismo en la lógica de decisión neuro-simbólica, elevando su umbral de clasificación en BETO de 0.50 a 0.65.

4.3.3. c-TF-IDF: Relevancia de Términos por Clúster

Una vez agrupados los documentos, BERTopic extrae la representación léxica de cada tópico mediante *Class-based TF-IDF* (c-TF-IDF) [?]. El algoritmo trata cada clúster como un “mega-documento de clase” formado por la concatenación de todos sus documentos miembro, y calcula la importancia de cada término t en la clase c frente al corpus completo:

$$W_{t,c} = TF_{t,c} \times \log\left(1 + \frac{A}{TF_t}\right) \quad (4.11)$$

Donde $TF_{t,c}$ es la frecuencia del término t en el mega-documento del clúster c , TF_t es la frecuencia total del término en todos los clústeres, y A es el número promedio de palabras por clúster (factor de normalización de escala). Los términos con $W_{t,c}$ más alto son frecuentes en el clúster pero infrecuentes en el resto del corpus: son los que mejor caracterizan semánticamente ese tópico.

El vectorizador configurado con `ngram_range=(1, 3)` permite que las representaciones incluyan bigramas y trigramas, capturando expresiones compuestas de alta especificidad como “*hijos resguardados DIF*” o “*víctima de feminicidio*” que los unigramas individuales no pueden representar. La representación final por tópico mediante KeyBERTInspired refina los términos seleccionados usando similitud coseno entre el embedding del n-grama y el embedding promedio del clúster, garantizando representatividad semántica en lugar de meramente estadística.

4.4. Técnicas de Deduplicación Cross-Site

La arquitectura multi-fuente del sistema (45 RSS + Google News + scraping HTML) genera redundancia mediática: distintos medios cubren el mismo evento con redacciones parcialmente distintas. Sin deduplicación, el corpus infla artificialmente las estadísticas y puede generar alertas duplicadas en el dashboard. El sistema implementa una cascada de cuatro algoritmos de complejidad creciente, donde los casos más obvios se resuelven con el método más barato.

4.4.1. Hash Exacto MD5

La primera barrera es la detección de copias exactas. Se emplea MD5 (*Message-Digest Algorithm 5*) [?], una función de hash criptográfico que proyecta una cadena de longitud arbitraria a un valor de 128 bits. El efecto avalancha garantiza que cualquier diferencia mínima en el texto de entrada altera completamente el hash resultante. La comparación de hashes tiene complejidad $O(1)$ por par, haciendo de esta fase la más eficiente de la cascada.

4.4.2. Similitud de Jaccard sobre Conjuntos de Tokens

Para detectar reescrituras con sustituciones léxicas simples (“*fue asesinada*” $\leftrightarrow$ “*perdió la vida*”), se emplea el coeficiente de Jaccard [?]. Dado que los títulos de las noticias se tokenizan en conjuntos de palabras A y B , la similitud se define como:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|} \in [0, 1] \quad (4.12)$$

Un umbral $J \geq 0,70$ marca a los pares como cuasi-duplicados. La complejidad por par es $O(|A| + |B|)$, lineal en el tamaño del vocabulario de los títulos.

4.4.3. SimHash: Huellas Digitales Localmente Sensibles

SimHash [?] es un *Locality-Sensitive Hash* (LSH) que genera una huella digital de 64 bits por documento tal que documentos similares producen hashes con **distancia de Hamming** baja (número de bits diferentes). El algoritmo proyecta los pesos TF-IDF de los tokens del documento en $\{+1, -1\}^{64}$ mediante 64 funciones de hash independientes, y el bit b_k del SimHash se determina por el signo del promedio ponderado de las proyecciones:

$$b_k = \text{sgn}\left(\sum_{t \in d} w_t \cdot h_k(t)\right), \quad k = 1, \dots, 64 \quad (4.13)$$

Dos documentos con distancia de Hamming ≤ 6 bits se consideran cuasi-duplicados. SimHash escala a millones de documentos en $O(n)$ sin comparaciones par-a-par, siendo el algoritmo adecuado para la fase de detección de paráfrasis en corpora de gran volumen.

4.4.4. Similitud Coseno sobre Vectores TF-IDF

La fase final de la cascada aplica similitud coseno sobre los vectores TF-IDF completos del contenido de las noticias, capturando casos donde la redacción difiere sustancialmente pero el contenido fáctico es el mismo. Dado que los vectores TF-IDF $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{|V|}$ son inherentemente normalizados en ℓ_2 , la similitud coseno se reduce al producto punto:

$$\cos(\mathbf{A}, \mathbf{B}) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\|_2 \|\mathbf{B}\|_2} = \sum_{i=1}^{|V|} \hat{A}_i \hat{B}_i \in [-1, 1] \quad (4.14)$$

Un umbral $\cos \geq 0,85$ marca el par como duplicado. Este paso es $O(n^2)$ en el peor caso pero, gracias al pre-filtrado de las fases anteriores, solo se aplica a un subconjunto pequeño de pares candidatos.

4.5. Tecnologías de Extracción de Datos y Persistencia

4.5.1. Protocolos de Sindicación: RSS y Atom

RSS (*Really Simple Syndication*) [?] y Atom son estándares de sindicación web basados en XML que permiten a los sitios publicar resúmenes estructurados de su contenido más reciente para su consumo por agentes automatizados. Un feed RSS 2.0 típico encapsula 20–50 artículos con sus metadatos (título, enlace, resumen, fecha, autor) en un documento XML de < 50 KB, en contraste con los 500 KB–2 MB de una página HTML completa con recursos estáticos.

La estructura del elemento raíz `<channel>` y sus `<item>` hijos es un estándar inmutable: el esquema XML no cambia ante actualizaciones del diseño del portal, eliminando la fragilidad de los selectores CSS del HTML scraping. Los endpoints RSS son recursos públicos destinados explícitamente a la ingestión automatizada; los WAF no aplican *fingerprinting* TLS sobre ellos, reduciendo la fricción de recolección a prácticamente cero para las 45 fuentes RSS del sistema.

4.5.2. Evasión de WAF: StealthSession y TLS/JA3 Fingerprinting

Los *Web Application Firewalls* (WAF) de grado empresarial —Cloudflare, Akamai, PerimeterX— identifican y bloquean scrapers mediante **TLS/JA3 fingerprinting**: durante el saludo TLS (*TLS handshake*), el cliente anuncia sus capacidades de cifrado (cipher suites, extensiones TLS, curvas elípticas) en un orden determinístico que identifica unívocamente la librería SSL utilizada. El hash JA3 de este saludo es diferente para Python/requests versus Chrome/Windows, aunque ambos declaren el mismo User-Agent. Un WAF moderno detecta la asimetría y emite HTTP 403 sin revelar el motivo.

StealthSession v7.0 resuelve este problema mediante `cloudscraper`, una librería que reemplaza la pila TLS de Python con una que genera hashes JA3 idénticos a los de Chrome/Windows, haciendo el handshake criptográficamente indistinguible de un navegador real. Complementariamente, el sistema implementa:

- **Delays log-normales.** Los intervalos entre requests siguen una distribución log-normal $\mathcal{LN}(\mu = 2,5, \sigma = 0,7)$ con mediana $\approx 12,2$ s y cola derecha larga, imitando los patrones de lectura humana (distribución asimétrica con pausas ocasionales largas) frente a la distribución uniforme trivialmente detectable.
- **Circuit Breaker por dominio.** Después de 3 fallos consecutivos sobre un dominio, el circuito se “abre” y rechaza requests por 300 s, evitando el ban permanente de IP al no presionar repetidamente un sitio que está bloqueando activamente la sesión.
- **Protocolo robots.txt.** El sistema respeta las directivas del estándar [?], consultando el archivo antes de cada dominio nuevo y omitiendo los paths restringidos para mantener la extracción dentro del marco ético del OSINT.

4.5.3. Propiedades ACID de postgresql

PostgreSQL [?] implementa el modelo transaccional ACID (*Atomicity, Consistency, Isolation, Durability*) mediante el protocolo de Control de Concurrencia Multiversión (MVCC):

Atomicidad. Toda transacción se ejecuta de forma atómica: o se aplican todas las operaciones que la componen (INSERT, UPDATE, DELETE) o ninguna. Una falla en mitad de una inserción por lote no corrompe los datos previamente persistidos.

Consistencia. La base de datos transiciona de un estado válido a otro estado válido. Las restricciones de integridad referencial (FOREIGN KEY) y las restricciones de dominio (NOT NULL, UNIQUE) se verifican al completar cada transacción.

Aislamiento. MVCC permite que múltiples transacciones concurrentes operen sin bloquearse mutuamente: cada transacción opera sobre su propia instantánea (*snapshot*) consistente de la base de datos. El pipeline analítico y el dashboard Flask pueden leer y escribir simultáneamente sin condiciones de carrera.

Durabilidad. Una vez que una transacción es confirmada (COMMIT), los cambios se persisten en el *Write-Ahead Log* (WAL) antes de retornar al cliente, garantizando la persistencia ante fallos de sistema o reinicio del servidor.

4.5.4. Índices GIN y Full-Text Search en Español

La búsqueda de texto completo (FTS) en PostgreSQL opera mediante dos tipos de datos especializados: `tsvector` (representación preprocesada del documento) y `tsquery` (representación preprocesada de la consulta del usuario). El proceso de conversión a `tsvector` aplica, en orden:

1. **Tokenización** del texto en lexemas (unidades léxicas significativas).
2. **Eliminación de stop words** en español (artículos, preposiciones, conjunciones frecuentes).
3. **Stemming** mediante el algoritmo Snowball para español: reduce “feminicidios”, “feminicida” y “feminicidio” a la misma raíz “feminicid”, garantizando que una búsqueda por cualquiera de las formas recupere documentos con las demás.
4. **Asignación de posición léxica** a cada lexema para el cálculo posterior de `ts_rank` (relevancia por proximidad de términos).

Los índices de tipo **GIN** (*Generalized Inverted Index*) [?] almacenan un índice invertido de los lexemas: para cada lexema único en el corpus, el índice GIN mantiene una lista de punteros directos a todas las filas que contienen ese lexema. Una consulta FTS de la forma `to_tsvector('spanish', titulo) @@ to_tsquery('spanish', 'feminicidio')` es resuelta en $O(\log n)$ (búsqueda en el árbol B del índice GIN) en lugar del $O(n)$ de un escaneo secuencial con `LIKE '%feminicidio%'`, donde n es el número de registros en la tabla.

El sistema crea automáticamente el `tsvector` de cada noticia mediante un *trigger* SQL que se activa en cada `INSERT` y `UPDATE` sobre la tabla `noticias`, concatenando título (peso A, mayor relevancia) y contenido (peso B, menor relevancia) para el ranking de resultados.

4.6. Sistemas Neuro-Simbólicos: Fundamentos Teóricos

La arquitectura neuro-simbólica [?] es un paradigma de inteligencia artificial que combina dos tradiciones complementarias: el razonamiento **neuronal** (aprendizaje de representaciones probabilísticas a partir de datos, generalización por interpolación en espacios de embeddings) y el razonamiento **simbólico** (manipulación explícita de reglas lógicas formales, conocimiento estructurado del dominio, razonamiento determinista y auditable).

Los sistemas neuro-simbólicos surgen como respuesta a las limitaciones individuales de cada paradigma. Los sistemas puramente neuronales son poderosos en generalización pero producen *alucinaciones* (predicciones erróneas con alta confianza) en distribuciones fuera del rango de entrenamiento. Los sistemas puramente simbólicos son auditables y correctos por construcción, pero no escalan ante vocabulario abierto y lenguaje natural no estructurado.

En el contexto del sistema desarrollado, el componente neuronal (BETO) provee comprensión semántica del lenguaje periodístico, mientras que el componente simbólico (árbol de decisión con Bypass de Oro, Bozal de Penalización y Factor Alpha Dinámico) garantiza que ninguna predicción viole el conocimiento experto del dominio: que un menor agresor no sea clasificado como víctima, que una nota estadística sin caso concreto no genere una alerta, y que el grado de confianza del componente neuronal module de forma auditablemente correcta su peso en la decisión final.

Esta arquitectura opera bajo el principio de *corrección por capas*: primero los filtros simbólicos de certeza máxima (Bypass de Oro) tienen prioridad absoluta sobre el componente neuronal; luego los filtros simbólicos de corrección actúan como restricciones; y solo en los casos genuinamente ambiguos —donde ninguna regla simbólica ofrece certeza suficiente— el sistema delega la decisión al componente neuronal ponderado por su propio grado de confianza (Factor Alpha Dinámico).

En este capítulo se exponen las plataformas, metodologías y proyectos de investigación contemporáneos orientados a la recolección, sistematización y análisis de datos en el contexto de la violencia de género y sus externalidades. Su análisis permite identificar la brecha tecnológica actual y fundamentar el carácter innovador de la arquitectura propuesta en este Trabajo Terminal.

5.1. Sistemas de monitoreo de medios tradicionales

En el ámbito de la inteligencia de fuentes abiertas (OSINT) y el monitoreo mediático comercial, existen plataformas con infraestructuras para la ingestión de datos en tiempo real (por ejemplo Google Alerts, Meltwater, Mention). Estas herramientas funcionan principalmente sobre arquitecturas de agregación RSS y rastreadores web de propósito general [?].

No obstante, la debilidad fundamental de estos sistemas radica en su dependencia de cadenas de texto y expresiones regulares (RegEx). Al carecer de capacidades de inferencia semántica la búsqueda de heurísticas combinadas como "feminicidio", "NNA", "menores" produce un volumen estadísticamente inmanejable de ruido informativo y falsos positivos. Por ejemplo, estos sistemas son incapaces de discernir sintácticamente entre un reporte donde el agresor resultó ser menor de edad, una noticia puramente estadística o un caso donde un menor quedó en orfandad como víctima indirecta. Esta incapacidad de inferencia contextual hace que las herramientas tradicionales resulten operativamente ineficaces para el dominio específico de este proyecto.

5.2. NLP Aplicado a la Detección de Violencia de Género

Desde la perspectiva académica, la intersección entre el Procesamiento de Lenguaje Natural (PLN) y la sociología forense ha ganado tracción empírica en los últimos años. La literatura documenta la transición de modelos de aprendizaje automático superficial (como *Support Vector Machines* o *Random Forests*) hacia arquitecturas de aprendizaje profundo (Deep Learning) para la clasificación de discursos de odio, misoginia en redes sociales y categorización automática de reportes policiales por violencia doméstica [?, ?].

Recientemente se han implementado modelos basados en Transformers (como RoBERTa y BERT) para extraer relaciones de causalidad en narrativas de violencia armada y feminicidios documentados en la prensa [?]. Sin embargo

al realizar una revisión bibliográfica exhaustiva se nota una carencia de investigación computacional enfocada en las víctimas indirectas. La inmensa mayoría de los clasificadores binarios se detienen en la categorización del evento fáctico (feminicidio vs. homicidio culposo) lo que omite por completo la extracción de entidades relacionadas con los NNA afectados.

5.3. Herramientas y Esfuerzos Existentes en México

En México ante la insuficiencia de datos gubernamentales en tiempo real, la sociedad civil ha asumido tareas de investigación en la documentación de la violencia feminicida, desarrollando iniciativas fundamentales que si bien son invaluable, presentan limitaciones de escalabilidad computacional.

5.3.1. Red por los Derechos de la Infancia en México (REDIM)

La REDIM es la entidad sociopolítica más prominente en la articulación de datos macroeconómicos y demográficos sobre la niñez mexicana. Sus informes sobre las infancias vulneradas son fundamentales para el diseño de políticas públicas [?]. No obstante, a nivel metodológico la organización depende fuertemente de la agregación estadística derivada de solicitudes formales de transparencia, bases de datos gubernamentales que frecuentemente están desfasadas o censos esporádicos. En consecuencia la REDIM carece de una plataforma tecnológica de trazabilidad *per-caso* que opere en tiempo real mediante ingestión automatizada de medios de comunicación masiva.

5.3.2. El Mapa de los Feminicidios en México

El proyecto cartográfico desarrollado por la investigadora María Salguero constituye un esfuerzo pionero e históricamente vital para la visibilización geográfica de la crisis [?]. El sistema geolocaliza y documenta variables sociodemográficas complejas. Sin embargo su principal cuello de botella es arquitectónico en cuanto a que la ingesta, lectura, extracción de características y captura en base de datos de cada caso reportado en prensa que debido a la falta de una metodología bien definida obedece a un flujo de trabajo manual y artesanal. Esta dependencia absoluta de la intervención humana imposibilita el análisis retrospectivo masivo de fuentes hemerográficas a velocidad computacional.

5.3.3. Fundación Futuro con Derechos

Organizaciones civiles dedicadas a la intervención directa como la Fundación Futuro con Derechos, ilustran el problema operativo mas claramente. En su intento por identificar casos emergentes de orfandad para ofrecer resguardo institucional o asesoría legal expedita, el personal de estas organizaciones invierte rutinariamente decenas de horas-hombre semanales realizando búsquedas manuales exhaustivas en portales de noticias [?]. Este proceso es no determinista, propenso a sesgos de fatiga y económicamente insostenible para asociaciones sin fines de lucro.

5.4. Análisis comparativo y brecha identificada

El análisis del estado actual del arte revela una brecha tecnológica interesante bajo los paradigmas vigentes que es **la desconexión entre la recolección masiva de datos no estructurados y la comprensión semántica profunda de las víctimas colaterales**. Las herramientas comerciales recolectan sin comprender, mientras que los esfuerzos civiles comprenden profundamente pero no logran recolectar ni escalar la información de forma automatizada.

La aportación fundamental de este Trabajo Terminal yace precisamente en la solución de esta brecha. El sistema propuesto no es un simple buscador de palabras clave ni un mapa de captura manual. Su innovación radica en la orquestación integral de un flujo de trabajo automatizado que suprime la intervención humana en las etapas de descubrimiento y filtrado:

1. **Recolección:** Ingesta concurrente y evasiva de fuentes RSS y motores de búsqueda.
2. **Deduplicación Cross-Site:** Colapso de redundancia mediática mediante hashing geométrico y algebraico.
3. **Agrupación Temática:** Modelado latente no supervisado mediante reducción topológica de dimensionalidad y clústering de densidad (BERTopic).
4. **Clasificación Semántica:** Inferencia computacional del contexto exacto de orfandad utilizando modelos fundacionales de atención profunda en español (BETO).

En suma, no existe en el ecosistema civil mexicano una herramienta de software que ejecute este ciclo completo (recolección, limpieza, deduplicación y clasificación neuro-simbólica) de forma unificada y específicamente calibrada para el problema social de los NNA víctimas indirectas de feminicidio. Este proyecto trasciende la estadística descriptiva para instaurar una plataforma de inteligencia y de respuesta rápida.

5.5. Técnicas de extracción de datos

La recolección de datos periodísticos en fuentes abiertas es un problema técnico pues los medios de comunicación digitales han desplegado capas de defensa perimetral cuyo objetivo primario es la protección contra el scraping masivo. La selección de la técnica de extracción adecuada determina directamente la cobertura alcanzable del sistema, su tasa de éxito sostenida y su consumo de recursos computacionales. En la literatura de recuperación de información y OSINT se identifican tres vertientes metodológicas principales, que se evaluaron en función de su efectividad y eficiencia para la recolección de datos periodísticos en México.

5.5.1. Extracción Estática (HTML Parsing con BeautifulSoup)

La aproximación más elemental al *web scraping* consiste en emitir una petición HTTP directa al servidor objetivo y analizar sintácticamente el documento HTML retornado mediante librerías de *parsing* como BeautifulSoup (Python) o Cheerio (Node.js). Esta técnica, fundamentada en el isomorfismo entre la estructura del DOM y un árbol XML, permite la extracción puntual de elementos textuales mediante selectores CSS o XPath.

Su principal limitación estructural es doble. En primer lugar, los portales informativos modernos contruidos sobre *frameworks* reactivos (React, Vue, Angular) generan el DOM de forma dinámica en el cliente mediante JavaScript; el HTML servido por el servidor carece del contenido visible, que solo existe tras la ejecución de decenas de *bundles* de JavaScript [?]. En segundo lugar, los *Web Application Firewalls* (WAF) de grado empresarial —en particular Cloudflare, Akamai y PerimeterX— detectan las sesiones de scraping estático mediante **TLS/JA3 fingerprinting**: comparan el hash criptográfico del saludo TLS (que identifica unívocamente la librería SSL del cliente, por ejemplo Python/requests) contra el User-Agent declarado. Una asimetría entre ambos activa el bloqueo con código HTTP 403 Forbidden, independientemente de los headers declarados por el scraper.

Esta fue la causa primaria del fracaso del Prototipo 0 (P0) durante el TT1, donde el 100 % de los intentos de extracción directa sobre portales nacionales de alto tráfico (La Jornada, El Universal, Milenio) resultaron en bloqueos sistemáticos, sin recuperar ningún artículo útil.

5.5.2. Automatización de Navegador (Selenium / Playwright)

Para superar la barrera de los sitios con renderizado dinámico, la alternativa más empleada en la literatura es la automatización de navegadores reales mediante herramientas como Selenium WebDriver o Playwright [?]. Estos *frameworks* controlan una instancia headless de Chrome o Firefox, ejecutando JavaScript en el entorno real del navegador y resolviendo los desafíos JavaScript de Cloudflare de forma transparente.

Sin embargo, esta aproximación introduce costos operativos prohibitivos para el dominio de este proyecto:

- **Consumo de recursos:** Cada instancia del navegador requiere aproximadamente 150–300 MB de RAM y entre 5–15 segundos para cargar una página completa. Con un corpus objetivo de 45 fuentes y ciclos de recolección cada 6 horas, el costo computacional acumulado supera los recursos disponibles en infraestructura de desarrollo universitaria.
- **Fragilidad estructural:** Los selectores CSS y XPath codificados en los scripts de extracción son inherentemente frágiles ante actualizaciones del diseño del portal. En entornos de despliegue continuo (CI/CD), los identificadores de elementos HTML pueden cambiar en cualquier ciclo de publicación, requiriendo mantenimiento constante.
- **Detección avanzada por comportamiento:** Los sistemas anti-bot de última generación (DataDome, Kasada) analizan patrones de interacción (movimientos de ratón, secuencias de clicks, tiempos entre eventos) que los navegadores headless sin instrumentación adicional no reproducen fielmente, resultando igualmente en bloqueos.

Por estas razones, Selenium y Playwright se evaluaron pero descartaron como técnica primaria de recolección, quedando reservados como último recurso para fuentes sin alternativa RSS disponible.

5.5.3. Agregación Estructurada (RSS/Atom) y Stealth Sessions

El protocolo **RSS** (*Really Simple Syndication*) y su sucesor **Atom** representan la alternativa técnicamente superior para la monitorización continua de medios periodísticos. Ambos estándares definen un formato XML normalizado que los medios publican voluntariamente para syndicar su contenido, eliminando la necesidad de parsear HTML no estructurado [?]. Las ventajas operativas son determinantes:

1. **Eficiencia de banda ancha:** Un feed RSS típico contiene los titulares, resúmenes y metadatos (fecha, autor, categoría) de los últimos 20–50 artículos en un documento XML de < 50 KB, frente a los 500 KB–2 MB de una página HTML completa con recursos estáticos. La reducción en consumo de ancho de banda es de aproximadamente 40:1.
2. **Estabilidad del formato:** El esquema XML de RSS 2.0 es un estándar inmutable; los feeds no cambian su estructura ante actualizaciones de diseño del portal, eliminando la fragilidad de los selectores CSS.
3. **Ausencia de barreras WAF:** Los endpoints RSS son recursos públicos destinados explícitamente a la ingestión automatizada; los WAF no aplican *fingerprinting* TLS sobre ellos. El sistema los consume con su identificador de bot legítimo (NNA-Analyzer-Bot/4.0), sin técnicas de evasión.

Para las fuentes que no exponen feeds RSS (aproximadamente el 35 % del corpus objetivo), el TT2 implementa *StealthSession* v7.0, una capa de sesión HTTP que resuelve los tres problemas identificados en el scraping estático: (a) emulación de fingerprint TLS mediante *cloudscraper*, (b) delays con distribución log-normal ($\mu = 2,5$, $\sigma = 0,7$) que imitan patrones de lectura humana, y (c) un *Circuit Breaker* por dominio que evita el bloqueo permanente de IP ante fallos consecutivos. Esta arquitectura híbrida RSS+StealthSession logra cubrir la totalidad del corpus objetivo con una tasa de éxito de recolección superior al 85 % en condiciones de producción.

5.5.4. Tabla Comparativa de Técnicas de Extracción

La Tabla 5.1 sintetiza la evaluación cuantitativa y cualitativa de las tres vertientes analizadas en función de los criterios operativos críticos para el sistema desarrollado.

Tabla 5.1: Comparativa de técnicas de extracción de datos para monitoreo de medios

Criterio	HTML Estático (BeautifulSoup)	Navegador (Selenium)	RSS + StealthSession (Implementado)
Velocidad de extracción	Alta (0.5–2 s/req)	Baja (5–15 s/req)	Muy alta (0.3–1 s/req RSS; 8–20 s/req stealth)
Resiliencia ante WAF	Muy baja (bloqueado por JA3 fingerprint)	Media (bloqueado por análisis de comportamiento)	Alta (RSS exento; stealth emula fingerprint TLS real)
Estructura de datos	No estructurada (HTML variable)	No estructurada (DOM dinámico)	Estructurada (XML/RSS normalizado)
Consumo de RAM	Bajo (~5 MB/req)	Muy alto (150–300 MB/instancia)	Bajo (~3 MB/req RSS)
Mantenimiento	Alto (selectores CSS frágiles)	Muy alto (selectores + browser updates)	Bajo (esquema RSS inmutable)
Cobertura de fuentes	Alta (cualquier sitio)	Alta (cualquier sitio)	Media (solo fuentes con RSS o stealth-compatible)
Resultado en TT1/TT2	Descartado (P0: 0 % éxito)	Descartado (recursos prohibitivos)	Seleccionado (P2–P4: 85 %+ éxito)

5.6. Evolución del Almacenamiento: de Archivos Planos a PostgreSQL

La decisión de migrar el sistema de persistencia constituye uno de los hitos arquitectónicos de mayor impacto en el TT2. El análisis del estado del arte en almacenamiento de datos para sistemas de monitoreo de medios revela una dicotomía clara entre dos paradigmas: los archivos planos (CSV/JSON) y los gestores de bases de datos relacionales (RDBMS).

5.6.1. Archivos Planos (CSV): Ventajas, Limitaciones y el Techo del TT1

Los archivos en formato *Comma-Separated Values* (CSV) constituyeron el mecanismo de persistencia del TT1 por razones pragmáticas: instalación cero, compatibilidad universal con Pandas y ausencia de dependencias de infraestructura. En el contexto de un prototipo inicial con corpus de ~281 registros, estas ventajas superaban sus limitaciones.

No obstante, el análisis de capacidad hacia el final del TT1 evidenció tres limitaciones estructurales que establecen el techo operativo del paradigma CSV:

- **Complejidad de consulta** $O(n)$: Cualquier operación de filtrado (ej. “todas las noticias de Alta relevancia en Veracruz desde enero”) requiere cargar el archivo completo en memoria RAM y aplicar filtros en Python, con

complejidad lineal sobre el corpus. Proyectado a escala nacional con miles de noticias mensuales, esta operación agota los recursos de un servidor de desarrollo en segundos.

- **Ausencia de integridad referencial:** El esquema plano impide establecer relaciones entre entidades (noticias, fuentes, clusters, detecciones) con garantías de consistencia. Una noticia eliminada puede dejar registros de detección huérfanos sin mecanismo alguno de detección.
- **Concurrencia insegura:** La escritura simultánea desde el pipeline analítico y la lectura desde el dashboard Flask sobre el mismo archivo CSV generan condiciones de carrera que pueden corromper los datos, requiriendo implementación manual de locks.

5.6.2. PostgreSQL 16: Justificación de la Selección

PostgreSQL 16 fue seleccionado como motor de base de datos del TT2 frente a alternativas como MySQL 8, SQLite y bases de datos NoSQL (MongoDB, Elasticsearch) por un conjunto de características técnicas específicamente necesarias para el dominio del sistema, implementadas en `src/database/models_noticias.py`.

Modelo ACID y concurrencia segura. PostgreSQL implementa el estándar *Atomicity, Consistency, Isolation, Durability* (ACID) con el protocolo de control de concurrencia multiversión (MVCC), que permite que múltiples lectores y un escritor operen simultáneamente sobre las mismas tablas sin bloqueos ni corrupción de datos. Esta propiedad es imprescindible en el sistema dado que el pipeline analítico y el dashboard Flask ejecutan transacciones concurrentes sobre la tabla `noticias`.

Integridad referencial con FOREIGN KEY. El esquema relacional implementado en `models_noticias.py` define cuatro tablas con relaciones explícitas:

Listing 5.1: Relaciones del esquema relacional en `models_noticias.py`

```
class Noticia(db.Model):
    # Clave foránea hacia clusters_semanticos
    cluster_id = db.Column(
        db.Integer, db.ForeignKey("clusters_semanticos.id"), nullable=True
    )

class Deteccion(db.Model):
    # Relacion 1:1 con CASCADE DELETE
    noticia_id = db.Column(
        db.Integer, db.ForeignKey("noticias.id", ondelete="CASCADE"),
        nullable=False, unique=True,
    )

class Entidad(db.Model):
    # Relacion N:1 con CASCADE DELETE
    noticia_id = db.Column(
        db.Integer, db.ForeignKey("noticias.id", ondelete="CASCADE"),
        nullable=False,
    )
```

La restricción `ondelete="CASCADE"` garantiza que la eliminación de una noticia propague automáticamente la eliminación de sus detecciones y entidades asociadas, manteniendo la consistencia referencial sin lógica adicional en la aplicación.

Full-Text Search nativo con índices GIN. La característica más determinante para la selección de PostgreSQL frente a MySQL o SQLite es su soporte nativo de búsqueda de texto completo (FTS) en español. PostgreSQL implementa FTS mediante el tipo de dato `tsvector`, que almacena un vector léxico preprocesado (con *stemming*, eliminación de *stop words* y normalización de acentos) del texto de cada documento. Los índices de tipo **GIN** (*Generalized Inverted Index*) sobre columnas `tsvector` permiten resolver consultas FTS complejas en $O(\log n)$ mediante una búsqueda de intersección de listas de postings invertidas, en lugar del escaneo lineal $O(n)$ que impone cualquier búsqueda LIKE `'%. . %'` en MySQL o SQLite.

El modelo implementado documenta explícitamente los índices requeridos:

Listing 5.2: Índices definidos en `models_noticias.py` para rendimiento < 100 ms

```
# Documentados en el docstring de models_noticias.py:
# idx_noticias_fts : GIN sobre tsvector (FTS en  $O(\log n)$ )
# idx_noticias_fecha : B-tree sobre fecha (filtros temporales)
# idx_noticias_score : B-tree sobre score_compuesto DESC (ranking)
# idx_noticias_cluster : B-tree sobre cluster_id (joins semánticos)
# idx_detecciones_nna : B-tree filtrado sobre menores_identificados
# idx_entidades_tipo : B-tree sobre tipo de entidad (NER queries)
```

La configuración `'spanish'` del `tsvector` de PostgreSQL aplica el diccionario de *stemming* Snowball para español, reduciendo “*feminicidios*”, “*feminicida*” y “*feminicidio*” a la misma raíz léxica, lo que hace que una búsqueda por “*feminicidio*” recupere documentos que contienen cualquiera de sus variantes morfológicas.

Contraste con alternativas NoSQL. Sistemas como MongoDB o Elasticsearch podrían ofrecer capacidades de búsqueda de texto completo, pero a costa de las garantías ACID y la integridad referencial. En un sistema de monitoreo de derechos humanos donde la consistencia de los datos es un requisito ético y operativo no negociable, la ausencia de transacciones ACID en bases de datos NoSQL representa un riesgo inaceptable. Elasticsearch, aunque ofrece FTS de calidad comparable, requiere un stack de infraestructura adicional (JVM, configuración de cluster) incompatible con las restricciones de recursos del entorno de despliegue universitario.

5.7. Evolución de los Modelos de Representación Lingüística para NLP

La selección del motor de clasificación semántica constituye la decisión de mayor impacto técnico en la arquitectura del TT2. La evolución histórica del campo del Procesamiento de Lenguaje Natural (PLN) describe una trayectoria en la que cada generación de modelos supera las limitaciones fundamentales de la anterior, no solo en precisión medida sobre benchmarks estándar, sino en la profundidad del fenómeno lingüístico que es capaz de capturar. Esta sección examina las tres generaciones de representaciones lingüísticas evaluadas durante el diseño del sistema.

5.7.1. Representaciones Vectoriales Estáticas: Word2Vec y GloVe

Los modelos de incrustación de palabras (*word embeddings*) de primera generación —Word2Vec [?] y GloVe [?]
representaron un salto cualitativo respecto al paradigma de vectores dispersos de TF-IDF, al proyectar el vocabulario en un espacio vectorial denso de dimensión reducida (100–300 dimensiones) donde la proximidad geométrica captura similitud semántica.

Sin embargo, ambos modelos comparten una limitación estructural determinante: la **asignación de un único vector por palabra**, independientemente del contexto. El token “menor” recibe la misma representación vectorial en “*un menor infractor detenido*” que en “*sus menores hijos quedaron huérfanos*”. Esta polisemia no resuelta es exactamente el mecanismo de falla que generó el 10 % de falsos positivos en el motor heurístico del TT1: la co-ocurrencia de tokens de dominio sin discriminación de rol semántico era el método de clasificación.

5.7.2. Modelos Recurrentes: LSTM y GRU

Las redes de memoria a largo y corto plazo (LSTM) [?] introdujeron la modelización del contexto *secuencial*: la representación de un token se calcula en función de todos los tokens precedentes. No obstante, presentan tres limitaciones técnicas inadecuadas para el dominio de este sistema:

1. **Contexto unidireccional.** El modelo no puede leer “hacia adelante” para resolver ambigüedades de rol semántico. En “*la mujer asesinada dejó tres hijos menores*”, “menores” solo recibe contexto izquierdo, sin considerar que “resguardo del DIF” (derecha) confirma el rol de víctima indirecta.
2. **Degradación del gradiente a largo alcance.** Las dependencias semánticas que abarcan más de 40–50 tokens presentan degradación en la retropropagación, limitando la correlación sujeto-predicado en oraciones compuestas.
3. **Paralelización imposible.** La naturaleza secuencial impide el procesamiento paralelo en GPU: el token t no puede ser procesado hasta que el estado oculto del token $t - 1$ esté disponible.

5.7.3. Arquitectura Transformer y Atención Bidireccional: BERT

La arquitectura *Transformer* [?] resuelve simultáneamente las tres limitaciones anteriores mediante el mecanismo de **autoatención multi-cabeza**: para cada token de la secuencia se calcula un vector de atención ponderada sobre todos los demás tokens de forma simultánea. BERT [?] extiende este paradigma mediante el preentrenamiento bidireccional con Modelado de Lenguaje Enmascarado (MLM), forzando representaciones que consideran simultáneamente el contexto izquierdo y derecho de cada token.

Para el dominio de este proyecto, la bidireccionalidad es la propiedad técnicamente decisiva: la representación de “menor” en “*sus hijos menores quedaron en resguardo del DIF*” se calcula considerando tanto “hijos” (izquierda) como “resguardo del DIF” (derecha), produciendo un embedding que captura inequívocamente el rol de víctima indirecta. Esta es la capacidad que el motor RegEx del TT1 era estructuralmente incapaz de aproximar.

5.7.4. Justificación de BETO frente a Modelos Multilingües (mBERT)

En el ecosistema de modelos preentrenados en español, la alternativa más inmediata a BETO es **mBERT** (*multilingual BERT*), el modelo de Google entrenado sobre Wikipedia en 104 idiomas. Sin embargo, la cobertura multilingüe introduce un compromiso técnico significativo: al distribuir la capacidad representacional de sus 110 millones de parámetros entre 104 lenguas, la calidad de representación del español es inherentemente inferior a la de un modelo monolingüe del mismo tamaño. Estudios de evaluación comparativa reportan que BETO supera a mBERT en un 3–8 % de F1 en tareas de clasificación de texto en español [?].

BETO (*dccuchile/bert-base-spanish-wwm-cased*) [?], desarrollado por la Universidad de Chile, se entrenó exclusivamente en español a partir de: Wikipedia en español (~3 GB, 42 millones de oraciones), corpus OPUS (OpenSubtitles, ParaCrawl, MultiUN) y fuentes de prensa latinoamericana. La inclusión de este último componente es particularmente relevante: sesga positivamente las representaciones hacia el vocabulario y estilo redaccional de los medios de comunicación mexicanos, que es exactamente el tipo de texto que el sistema procesa. El entrenamiento con *Whole Word Masking* (WWM) garantiza además que los términos especializados de múltiples sub-tokens (como *femi##ni##cid##io*) se aprendan como unidades semánticas coherentes.

La Tabla 5.2 presenta la evaluación comparativa de los modelos considerados.

Tabla 5.2: Comparativa de modelos de representación lingüística para clasificación semántica

Modelo	Comprensión Contextual	Idioma Nativo	Hardware Requerido	Resultado
TF-IDF (TT1)	Ninguna (co-ocurrencia léxica)	N/A (estadístico)	CPU, RAM <1 GB	Descartado (10 % FP)
Word2Vec / GloVe	Estática (sin contexto)	Español limitado	CPU, RAM <2 GB	Descartado (polisemia)
LSTM / GRU	Secuencial unidireccional	Requiere reentrenamiento	GPU recomendada	Descartado (gradiente, velocidad)
mBERT	Bidireccional (104 idiomas)	Multilingüe (sesgo reducido en ES)	8 GB RAM (CPU viable)	Evaluado (superado por BETO en ES)
BETO	Bidireccional plena	Español monolingüe nativo	8 GB RAM (CPU viable)	Seleccionado
GPT-4 / Claude	LLM (máxima capacidad)	Multilingüe alta calidad	API externa / sin GPU local	Descartado (soberanía)

5.7.5. Clasificación Zero-Shot frente al Fine-Tuning Supervisado

La estrategia de clasificación adoptada —*zero-shot* mediante similitud coseno entre embeddings BETO del texto y descripciones de categorías en lenguaje natural— requiere justificación frente al paradigma estándar de fine-tuning supervisado, que predomina en la literatura de clasificación de texto con BERT.

El fine-tuning supervisado requiere un corpus etiquetado de volumen suficiente ($\geq 1,000$ ejemplos por clase) para evitar sobre-ajuste en modelos de 110 M parámetros. Este requisito es exactamente la restricción que enfrentó el TT2 en sus fases iniciales: el corpus de noticias etiquetadas manualmente era insuficiente. La clasificación zero-shot ofrece tres ventajas operativas decisivas:

1. **Independencia de datos etiquetados.** Las descripciones de categorías codifican el conocimiento experto del dominio directamente en el espacio de embeddings, sin ningún ejemplo de entrenamiento.
2. **Auditabilidad y corrección de sesgos.** Cuando el sistema produce un falso positivo sistemático, la corrección consiste en refinar la descripción de la categoría en lenguaje natural, sin reentrenar el modelo. Esta propiedad es esencial en un sistema de monitoreo de derechos humanos.
3. **Trayectoria hacia fine-tuning incremental.** La clase `SemanticDetector` prevé la coexistencia de ambos modos mediante `mode= 'auto'` : cuando el volumen de datos etiquetados supere el umbral mínimo, el sistema cargará automáticamente el modelo fine-tuned de `models/finetuned/model.pt`, manteniendo zero-shot como fallback.

5.7.6. Soberanía de Datos y Rechazo de APIs Privativas

La decisión de ejecutar BETO localmente mediante PyTorch, en lugar de delegar la inferencia a APIs privativas (GPT-4, Claude, Gemini), se fundamenta en cuatro argumentos no negociables:

1. **Privacidad de los datos.** El sistema procesa información sobre feminicidios y víctimas menores de edad. La transmisión de este contenido a servidores corporativos externos implica riesgos de privacidad incompatibles con la LGDNNA y el principio de minimización de datos de la LFPDPPP.

2. **Costo operativo sostenible.** La inferencia de GPT-4 para 600–1,000 documentos por ciclo costaría \$15–\$40 USD por ejecución, proyectando \$450–\$1,200 USD mensuales en ciclos de 6 horas. BETO en CPU tiene costo variable cero.
3. **Reproducibilidad científica.** Los modelos propietarios modifican silenciosamente sus pesos entre versiones, imposibilitando la reproducción exacta de los resultados reportados. BETO es un modelo de pesos abiertos cuya revisión exacta queda fijada en el registro del proyecto.
4. **Viabilidad en hardware universitario.** BETO-base (110 M parámetros, float32) requiere ≈ 440 MB de VRAM o 2.2 GB de RAM en CPU, compatible con laptops de desarrollo estándar de 8 GB RAM.

5.8. Técnicas de Agrupamiento Semántico y Organización Temática

El agrupamiento automático de documentos periodísticos constituye el mecanismo que permite al sistema trascender la clasificación individual de noticias y obtener una comprensión del *paisaje informativo* del periodo analizado. En lugar de clasificar cada noticia en aislamiento, el agrupamiento semántico revela qué noticias relatan el mismo evento criminal desde múltiples medios, qué clústeres temáticos dominan el corpus en un periodo dado, y qué documentos son *outliers* sin coherencia temática con el resto. Esta perspectiva global es imposible mediante clasificación individual; es una propiedad emergente del corpus completo.

5.8.1. Métodos Tradicionales: K-Means y su Inadecuación para Datos de Alta Dimensionalidad

El algoritmo K-Means [?] es el método de agrupamiento por centroides más extendido en la literatura de recuperación de información. Su principio de funcionamiento consiste en minimizar la suma de distancias euclidianas al cuadrado entre cada punto y el centroide de su clúster asignado, mediante una convergencia iterativa de asignación y actualización de centroides.

Sin embargo, K-Means presenta dos limitaciones estructurales que lo hacen inadecuado para el dominio de este sistema:

1. **La maldición de la dimensionalidad (*curse of dimensionality*).** Los embeddings de texto generados por BETO son vectores de 768 dimensiones. En espacios de alta dimensionalidad, la distancia euclidiana pierde su poder discriminatorio: la diferencia entre la distancia al punto más cercano y al más lejano tiende a cero a medida que la dimensionalidad crece [?]. Este fenómeno hace que la noción de “centroide más cercano” sea geoméricamente inestable, generando asignaciones de clúster arbitrarias. Esta fue la causa del bajo rendimiento de K-Means en el TT1, donde los clústeres resultantes no correspondían a grupos temáticamente coherentes sino a particiones geoméricamente arbitrarias del espacio vectorial.
2. **Requerimiento de k fijo.** K-Means exige que el número de clústeres sea especificado *a priori*. En un sistema de monitoreo de medios donde el número de temas activos varía semanalmente en función de los eventos noticiosos, esta rigidez es operativamente insostenible. Fijar $k = 10$ en un periodo con solo 3 temas activos fragmenta artificialmente los clústeres reales; fijar $k = 10$ en un periodo con 25 temas activos los colapsa en grupos heterogéneos.

5.8.2. DBSCAN: Ventajas y Limitaciones Residuales

El algoritmo DBSCAN [?] (*Density-Based Spatial Clustering of Applications with Noise*) supera la limitación del k fijo al definir los clústeres como regiones de alta densidad en el espacio métrico, separadas por regiones de baja densidad.

Los puntos que no pertenecen a ninguna región densa son clasificados como *ruido* (`topic_id = -1`), una propiedad fundamental para el dominio de este proyecto donde las noticias genéricas no relacionadas con el tema central deben ser identificadas y filtradas.

Sin embargo, DBSCAN presenta una limitación crítica ante datos reales: requiere que la densidad de los clústeres sea *uniforme*. El parámetro global de radio de vecindad ϵ define la densidad mínima de toda la solución; un único valor de ϵ no puede capturar simultáneamente clústeres de alta densidad (eventos con cobertura mediática masiva de muchos medios) y clústeres de baja densidad (casos locales cubiertos por pocos medios regionales). Esta limitación genera segmentaciones inconsistentes en corpus periodísticos donde la cobertura mediática de los eventos es inherentemente heterogénea.

5.8.3. BERTopic: Arquitectura Modular para Descubrimiento de Tópicos Semánticos

BERTopic [?] supera las limitaciones de K-Means y DBSCAN mediante una arquitectura modular de cinco etapas que separa la *representación*, la *reducción de dimensionalidad*, el *clustering* y la *representación de tópicos* en componentes independientes y sustituibles. La implementación en `src/analysis/bertopic_clustering.py` instancia esta arquitectura con parámetros calibrados específicamente para el corpus periodístico en español:

Listing 5.3: Construcción del pipeline BERTopic en `bertopic_clustering.py`

```
# 1. Embeddings: sentence-transformers (multilingue, liviano)
embedding_model = SentenceTransformer("paraphrase-multilingual-MiniLM-L12-v2")

# 2. UMAP: 768D -> 5D, métrica coseno, clusters compactos
umap_model = UMAP(
    n_components=5,          # 5D: balance informacion/ruido
    n_neighbors=15,         # balance local/global
    min_dist=0.0,           # clusters compactos (optimo para HDBSCAN)
    metric="cosine",        # apropiado para embeddings de texto
    random_state=42,
)

# 3. HDBSCAN: densidad variable, sin k fijo, genera outliers
hdbscan_model = HDBSCAN(
    min_cluster_size=8,      # agresivo: menos outliers que 15+
    min_samples=5,          # densidad requerida por punto core
    cluster_selection_method="eom", # Excess of Mass: mas estable
    prediction_data=True,   # necesario para reduce_outliers()
)

# 4. c-TF-IDF: n-grams 1-3, stop words en español
vectorizer = CountVectorizer(
    stop_words=SPANISH_STOP_WORDS,
    ngram_range=(1, 3),
    min_df=2,
)
```


UMAP: Reducción de Dimensionalidad Preservadora de Topología

UMAP (*Uniform Manifold Approximation and Projection*) [?] proyecta los vectores de 768 dimensiones generados por BETO hacia un espacio de 5 dimensiones, resolviendo la maldición de la dimensionalidad de K-Means. A diferencia de PCA (que preserva únicamente varianza global lineal) y t-SNE (que preserva solo estructura local y no escala a más de ~50,000 puntos), UMAP preserva simultáneamente la **estructura topológica local y global**: documentos semánticamente similares permanecen adyacentes en el espacio reducido, y grupos de documentos semánticamente distintos permanecen separados.

La configuración `metric='cosine'` es determinante: los embeddings de texto tienen magnitudes variables y la similitud semántica se mide por el ángulo entre vectores (similitud coseno), no por su distancia euclidiana. Usar UMAP con métrica coseno garantiza que la estructura topológica preservada sea semánticamente significativa. El parámetro `min_dist=0.0` fuerza que los puntos dentro de cada clúster se compriman máximamente, aumentando la densidad local y facilitando la detección de fronteras por HDBSCAN.

HDBSCAN: Clustering de Densidad Variable con Detección de Ruido

HDBSCAN [?] (*Hierarchical DBSCAN*) extiende DBSCAN construyendo una jerarquía de clústeres en función de la densidad local de cada punto, sin requerir un ϵ global. La selección de clústeres mediante el método *Excess of Mass* (EoM) identifica automáticamente las particiones óptimas en la jerarquía, generando clústeres de densidades heterogéneas. Los puntos que no pertenecen a ningún clúster de densidad suficiente reciben la etiqueta de ruido (`topic_id = -1`).

Esta propiedad de detección de ruido es semánticamente valiosa en el dominio del sistema: las noticias *outlier* (sin coherencia temática con el corpus) son exactamente las que el sistema debe tratar con mayor escepticismo en la clasificación semántica, elevando su umbral de exigencia de BETO de 0.50 a 0.65. El código de `bertopic_clustering.py` documenta que los datos reales de producción presentaron inicialmente **81.4 % de outliers**, resueltos mediante una reducción multi-etapa de tres estrategias progresivas:

1. **Probabilidades soft** (`strategy='probabilities'`): reasigna outliers al clúster con mayor probabilidad blanda de HDBSCAN.
2. **Distribuciones c-TF-IDF** (`strategy='distributions'`): reasigna outliers al clúster cuya distribución léxica es más similar al documento.
3. **Cercanía de embeddings** (`strategy='embeddings', threshold=0.3`): reasigna outliers al clúster cuyo centroid de embedding es más cercano, con umbral de similitud mínima para evitar asignaciones erróneas.

El objetivo declarado en el código es reducir los outliers de 81.4 % a un máximo de **55 %** (`OUTLIER_TARGET_PERCENT = 0.55`), manteniendo suficiente cantidad de noticias sin clasificar para que la señal de “outlier” conserve su poder discriminatorio en la lógica neuro-simbólica.

c-TF-IDF: Representación Léxica de Tópicos

La representación de cada tópico se obtiene mediante *Class-based TF-IDF* (c-TF-IDF) [?]: el algoritmo concatena todos los documentos de un mismo clúster en un “mega-documento de clase” y aplica TF-IDF comparando cada clase contra el corpus completo. Esto identifica los términos que son frecuentes dentro del clúster pero infrecuentes en el resto del corpus, generando representaciones léxicas interpretables que caracterizan semánticamente cada tópico.

El vectorizador configurado con `ngram_range=(1, 3)` permite que las representaciones incluyan frases de hasta tres palabras, capturando expresiones compuestas de alta especificidad para el dominio (e.g., “*víctima de feminicidio*”, “*hijos resguardados DIF*”). La representación final por tópico mediante KeyBERTInspired refina adicionalmente los

términos seleccionados usando similitud coseno entre el embedding del n-grama y el embedding promedio de los documentos del clúster, garantizando que las palabras clave seleccionadas sean semánticamente representativas y no solo estadísticamente frecuentes.

5.8.4. Evolución Comparativa TT1 → TT2: de Léxico a Semántica

La Tabla 5.3 sintetiza la evaluación de los tres algoritmos de agrupamiento en función de los criterios operativos del sistema.

Tabla 5.3: Comparativa de algoritmos de agrupamiento semántico para corpus periodístico

Criterio	K-Means (TT1)	DBSCAN	BERTopic (UMAP+HDBSCAN, TT2)
Manejo de ruido	Ninguno (todos los puntos asignados a un clúster)	Sí (puntos en baja densidad = ruido)	Sí (HDBSCAN con reducción multi-etapa 81.4 %→55 %)
Escalabilidad	Alta ($O(n \cdot k \cdot i)$)	Media ($O(n^2)$ sin índice espacial)	Alta (UMAP+HDBSCAN: $O(n \log n)$ aproximado)
Interpretación de tópicos	Baja (centroides en espacio de alta dimensión sin interpretabilidad)	Ninguna (solo densidad geométrica)	Alta (c-TF-IDF genera top n-grams interpretables por tópico)
Dependencia de parámetros	Crítica (k fijo requerido)	Alta (ε global uniforme)	Baja (<code>min_cluster_size=8</code> adaptativo; k automático)
Alta dimensionalidad	Muy baja (maldición de la dimensionalidad)	Baja (distancias euclidianas en alta dimensión)	Alta (UMAP reduce a 5D preservando topología)
Resultado en TT1/TT2	<i>Descartado en TT2</i> (clústeres no coherentes)	<i>Evaluado</i> (inadecuado por ε global)	Seleccionado (OE-4, P4)

La diferencia conceptual más significativa entre el TT1 y el TT2 en materia de agrupamiento no es algorítmica sino epistemológica: en el TT1, el agrupamiento K-Means operaba sobre **vectores TF-IDF léxicos**, donde dos documentos son similares si comparten los mismos tokens literales. En el TT2, BERTopic opera sobre **embeddings semánticos de BETO**, donde dos documentos son similares si expresan el mismo *significado*, independientemente del vocabulario utilizado.

Esta distinción tiene una consecuencia operativa directa: en el TT2, noticias publicadas por La Jornada, El Universal y Milenio sobre el *mismo caso criminal* de feminicidio —aunque redactadas con vocabularios completamente distintos, diferentes tiempos verbales y enfoques editoriales— “gravitarán” hacia el mismo clúster BERTopic, pues sus embeddings BETO convergen en la misma región del espacio semántico. En el TT1, estas tres noticias podían dispersarse en tres clústeres K-Means distintos por la mínima varianza léxica entre medios.

5.9. Conclusión del Capítulo: La Convergencia Tecnológica al Servicio de los Derechos de la Infancia

El análisis del estado del arte desarrollado en este capítulo revela que ninguna de las tecnologías examinadas de forma aislada es suficiente para resolver el problema social planteado. La recolección mediante RSS provee eficiencia pero no comprensión; TF-IDF provee velocidad pero no contexto; K-Means provee estructura pero no semántica; BETO provee comprensión pero puede alucinar sin reglas simbólicas.

La innovación fundamental de este Trabajo Terminal no radica en la invención de ningún algoritmo nuevo, sino en la **orquestación arquitectónica** de seis tecnologías maduras —RSS+StealthSession, PostgreSQL FTS, BETO, BER-Topic (UMAP+HDBSCAN+c-TF-IDF), clasificación zero-shot y lógica neuro-simbólica— en un pipeline coherente, auditablemente correcto y específicamente calibrado para un dominio donde el error de clasificación tiene consecuencias humanas reales.

Cada decisión tecnológica documentada en este capítulo puede trazarse directamente a una necesidad social concreta. La elección de RSS sobre scraping estático garantiza cobertura sostenida sin saturar los servidores de medios independientes con recursos limitados. La migración a PostgreSQL con FTS garantiza que los trabajadores sociales del DIF puedan consultar el sistema en tiempo real sin esperar escaneos lineales de CSV. La elección de BETO sobre mBERT garantiza que el sistema comprende el español coloquial y periodístico mexicano con la misma precisión que el español académico. La lógica neuro-simbólica garantiza que el sistema nunca clasificará a un menor agresor como víctima indirecta, ni descartará un caso real de orfandad por la ambigüedad redaccional de un periodista local.

En suma, el ecosistema tecnológico seleccionado en el TT2 está diseñado para una sola misión: **garantizar que ningún caso de niña, niño o adolescente que quedó en orfandad por feminicidio sea invisible para las instituciones del Estado que tienen la obligación legal de protegerlo.**

El presente capítulo detalla el marco metodológico utilizado para la concepción, ingeniería y despliegue del Sistema Inteligente para la Identificación y Seguimiento de NNA. Debido a la alta complejidad algorítmica y la inherente incertidumbre tecnológica del proyecto —particularmente en las fases de validación de modelos de lenguaje y calibración de umbrales de clasificación— se adoptó un enfoque de **Desarrollo Evolutivo Incremental basado en Prototipos** que garantizara la convergencia hacia una solución correcta y de calidad de producción mediante retroalimentación empírica continua.

6.1. Metodología de desarrollo evolutivo

Se seleccionó el Modelo de Desarrollo evolutivo basado en Prototipos como marco de proceso fundamental por dos razones técnicas no negociables:

1. **Incertidumbre en la ingesta de datos.** El ecosistema web actual emplea infraestructuras de seguridad perimetral (WAF, *bot detection*, TLS fingerprinting) que cambian impredeciblemente. Era imposible predecir *a priori* qué mecanismos de recolección tendrían éxito sin desplegarlos en entornos de producción reales y medir su tasa de éxito.
2. **Experimentación algorítmica en IA.** La transición de clasificadores sintácticos rígidos (RegEx) hacia modelos fundacionales (BETO) requería calibración empírica de umbrales de temperatura ($\alpha = 5$), configuración de hiperparámetros de HDBSCAN (`min_cluster_size=8`), y verificación experimental de la tasa de falsos positivos.

El modelo mitiga ambos riesgos al dividir el desarrollo en iteraciones cíclicas donde cada ciclo produce un prototipo funcional que refina las capacidades del anterior. Cada iteración comprende cuatro fases estrictas:

Análisis. Definición cuantitativa del problema a resolver en el ciclo (e.g., “reducir la tasa de falsos positivos del 10 % al 5 %”).

Diseño. Especificación de la solución algorítmica y arquitectónica (e.g., introducción de Zero-Shot Classification con temperature scaling).

Implementación. Codificación del módulo e integración en el pipeline existente, garantizando retro-compatibilidad.

Evaluación. Pruebas de integración, medición de métricas de precisión y *benchmarking* de rendimiento que dictan las metas del siguiente ciclo.

6.1.1. Cronograma General del Proyecto

El ciclo de vida completo del proyecto abarca dos semestres académicos:

Fase TT-1 (Sep–Dic 2025). Validación de viabilidad técnica mediante prototipos exploratorios (P0–P2). El énfasis fue demostrar que un sistema automatizado puede extraer noticias relevantes de medios mexicanos a escala, y que la clasificación heurística es insuficiente para el dominio. Entregable: corpus anotado de ~1,500 noticias y diagnóstico cuantitativo de las limitaciones del clasificador RegEx.

Fase TT-2 (Feb–Jun 2026). Maduración neuro-simbólica mediante prototipos de nivel producción (P3–P4). El énfasis fue superar las limitaciones identificadas en TT-1 mediante la migración arquitectónica completa. Entregable: sistema en contenedores Docker con SLA de >85 % de tasa de éxito en recolección y <5 % de falsos positivos en clasificación.

6.2. Evolución de los Prototipos (P0 al P4)

6.2.1. Fase TT-1: Prototipos Exploratorios (P0–P2)

Prototipo 0 (P0): Prueba de Concepto y Fracaso Rápido (Sep 2025). Implementación de scraping directo mediante análisis del DOM HTML con BeautifulSoup. Resultado: bloqueos sistemáticos por Cloudflare (HTTP 403) en el 78 % de los medios objetivo. Conclusión: el fingerprinting TLS de la librería requests es identificable por WAF modernos. Decisión: abandonar el scraping HTML directo como estrategia primaria.

Prototipo 1 (P1): Recolección Pasiva y Persistencia Plana (Oct 2025). Transición hacia feeds RSS de 10 medios periodísticos nacionales; persistencia en CSV mediante Pandas. Resultado: 847 noticias recolectadas en el primer mes con 0 % de bloqueos. Limitación crítica identificada: cobertura insuficiente (solo medios con RSS público) y ausencia de cualquier mecanismo de clasificación semántica.

Prototipo 2 (P2): Clasificación Heurística y Clustering Estadístico (Nov–Dic 2025). Introducción de un clasificador de expresiones regulares con 47 patrones y vectorización TF-IDF con K-Means ($k = 8$). Resultado: 10 % de falsos positivos en tres escenarios recurrentes: menor agresor clasificado como víctima, notas estadísticas sin caso concreto identificado, y feminicidios de menores de edad (víctima directa $\neq$ víctima indirecta). Diagnóstico: el clasificador es sintáctico, no semántico; no comprende el rol de los actores en la oración.

6.2.2. Fase TT-2: Arquitectura Neuro-Simbólica (P3–P4)

Prototipo 3 (P3): Inferencia Semántica y Persistencia Relacional (Feb–Mar 2026). Migración del clasificador RegEx a BETO (*zero-shot* por similitud coseno con $\alpha = 5$) mediante PyTorch. Migración del almacenamiento CSV a PostgreSQL 16 con índices GIN para FTS. Implementación de la deduplicación en cascada (MD5 $\rightarrow$ SimHash $\rightarrow$ Jaccard $\rightarrow$ coseno TF-IDF). Integración de StealthSession v7.0 con delays log-normales y Circuit Breaker. Resultado: tasa de falsos positivos reducida al 4.2 %; cobertura elevada a 45 fuentes RSS activas.

Prototipo 4 (P4): Agrupamiento Semántico Global y Dashboard (Abr–Jun 2026). Integración de BERTopic como etapa previa a la clasificación individual, proveyendo contexto global del corpus. Implementación de la lógica neuro-simbólica completa: Bypass de Oro, Bozal de Penalización y Factor Alpha Dinámico. Desarrollo del Dashboard Flask con API REST y contenerización completa mediante Docker Compose (tres servicios: `nna-postgres`, `nna-analyzer`, `nna-webapp`). Resultado: sistema de calidad de producción listo para adopción por organizaciones civiles.

6.3. Stack Tecnológico: Evolución TT-1 → TT-2

La maduración iterativa forzó una refactorización integral de las dependencias de software: cada limitación medida en TT-1 motivó directamente una decisión arquitectónica en TT-2. La Tabla 6.1 sistematiza esta evolución por capa arquitectónica, documentando el cuello de botella superado en cada caso.

Tabla 6.1: Evolución del Stack Tecnológico (TT-1 vs TT-2)

Capa	TT-1 (Prototipo 2)	TT-2 (Prototipo 4)
Lenguaje base	Python 3.10, scripts secuenciales en CLI	Python 3.11, pipeline modular con Repository Pattern
Recolección	10 fuentes RSS + requests (bloqueado en HTML)	45 fuentes RSS + Google News API + StealthSession v7.0 (cloudscraper, JA3)
Persistencia	Archivos CSV con Pandas; sin acceso concurrente; sin integridad referencial	PostgreSQL 16 + SQLAlchemy ORM; ACID/MVCC; índices GIN para FTS en español
Clasificación NLP	RegEx (47 patrones); TF-IDF; 10 % falsos positivos	BETO + Zero-Shot coseno + Temperature Scaling ($\alpha = 5$); <5 % FP
Agrupamiento	K-Means (k fijo) sobre vectores TF-IDF; clústeres no coherentes	BERTopic (UMAP 768D→5D + HDBSCAN EoM + c-TF-IDF); k automático
Deduplicación	Solo URLs exactas (conjunto de enlaces)	Cascada de 4 capas: MD5 → SimHash → Jaccard → coseno TF-IDF (umbral 0.85)
Lógica de decisión	Binaria (RegEx: match/no match)	Neuro-simbólica: Bypass de Oro + Bozal de Penalización + Factor α Dinámico
Despliegue	Scripts CLI; dependencia del entorno local del desarrollador	Docker Compose (3 contenedores); Gunicorn; red bridge <code>nna-network</code>
Interfaz	Ninguna (salida en CSV y consola)	Dashboard Flask + API REST; fichas de caso; exportación CSV; gestión CRUD de fuentes

6.4. Arquitectura de Microservicios y Contenerización

La culminación del Prototipo 4 es un ecosistema distribuido definido mediante `docker-compose.yml` y regido por el principio de separación de responsabilidades (*Separation of Concerns*). El sistema se organiza en tres contenedores

independientes que se comunican sobre una red bridge privada (nna-network), asegurando aislamiento de fallos y escalabilidad horizontal independiente por capa.

6.4.1. Contenedor de Base de Datos: nna-postgres

El contenedor nna-postgres ejecuta **PostgreSQL 16 Alpine** (postgres:16-alpine), una imagen minimizada de 78 MB sin dependencias de sistema no esenciales. Su configuración incluye:

- **Volumen persistente** pgdata montado en /var/lib/postgresql/data: garantiza la supervivencia de los datos ante reinicios del contenedor.
- **Healthcheck** mediante pg_isready: los contenedores dependientes (nna-analyzer y nna-webapp) no inician hasta que la base de datos responde correctamente, evitando race conditions de inicialización.
- **Puerto 5432** expuesto únicamente a la red interna nna-network; no expuesto al host de producción para reducir la superficie de ataque.

6.4.2. Contenedor del Motor de Análisis: nna-analyzer

El contenedor nna-analyzer ejecuta el pipeline completo de recolección y análisis mediante el proceso python scheduler.py schedule, que orquesta la ejecución periódica del pipeline en ciclos de 6 horas. Sus características arquitectónicas más relevantes son:

- **Volumen compartido** models_cache montado en /app/models/cache: los pesos de BETO (~440 MB) se descargan una sola vez y persisten entre reinicios, eliminando la latencia de descarga en cada arranque.
- **Variables de entorno Hugging Face**: TRANSFORMERS_CACHE y HF_HOME apuntan al volumen compartido, garantizando que la caché de modelos sea determinista y no dependa del directorio home del usuario del sistema.
- **Dependencia condicional**: depends_on: nna-postgres: condition: service_healthy garantiza que el analizador no intenta conectarse a PostgreSQL hasta que el healthcheck confirma disponibilidad.
- **Zona horaria**: TZ=America/Mexico_City garantiza que los timestamps de las noticias recolectadas se registran en hora local del dominio de operación.

6.4.3. Contenedor de la Aplicación Web: nna-webapp

El contenedor nna-webapp sirve la aplicación Flask mediante **Gunicorn** (gunicorn --bind 0.0.0.0:5000 --workers 2 --timeout 300 wsgi:app), un servidor WSGI de producción que gestiona concurrencia mediante múltiples workers pre-forked:

- **2 workers** Gunicorn: permite atender hasta 2 peticiones HTTP concurrentes sin bloqueo, adecuado para el perfil de uso de una organización civil con ≤ 10 usuarios simultáneos.
- **Timeout de 300 s**: justificado por las operaciones de inferencia BETO en CPU que pueden tardar hasta 180 s en lotes grandes; sin este timeout, Gunicorn terminaría prematuramente las solicitudes de análisis on-demand desde el dashboard.
- **Puerto 5000** expuesto al host: único punto de entrada externo al sistema, servido en producción mediante un proxy inverso Nginx.
- **Dependencia de inicio**: depends_on: nna-analyzer: condition: service_started garantiza que el analizador ha completado su inicialización antes de que el dashboard empiece a atender consultas.

6.5. Matriz de Trazabilidad: Requerimientos por Prototipo

La Tabla 6.2 establece la cobertura de cada requerimiento funcional y no funcional a lo largo de los cinco prototipos del ciclo de vida del proyecto, documentando en qué iteración cada requerimiento fue satisfecho por primera vez (✓) o parcialmente cubierto (~). Esta matriz de trazabilidad evidencia que el alcance del protocolo 2026-A135 fue completado íntegramente al cierre del Prototipo 4.

Tabla 6.2: Matriz de Trazabilidad: Requerimientos vs. Prototipos de Implementación

ID	Requerimiento	P0	P1	P2	P3	P4
RF-01	Extracción multi-fuente (Stealth-Session + RSS + Google News)	~	~	~	✓	✓
RF-02	Deduplicación en cascada (MD5, SimHash, Jaccard, co-seno)	—	—	~	✓	✓
RF-03	Filtrado simbólico (Bypass de Oro, Bozal de Penalización)	—	—	~	✓	✓
RF-04	Clasificación semántica BETO (zero-shot + temperature scaling)	—	—	—	✓	✓
RF-05	Agrupamiento BERTopic (UMAP + HDBSCAN + c-TF-IDF)	—	—	—	—	✓
RF-06	Persistencia relacional PostgreSQL (FTS, GIN, ACID)	—	~	~	✓	✓
RF-07	Gestión CRUD de orígenes de datos (Dashboard)	—	—	—	—	✓
RF-08	Visualización interactiva y fichas de caso (Flask)	—	—	—	—	✓
RNF-01	Rendimiento: lote de 100 noticias en <3 min en CPU	—	—	✓	✓	✓
RNF-02	Resiliencia: Exponential Backoff + Circuit Breaker	—	—	—	✓	✓
RNF-03	Seguridad: sesiones Flask con tokens criptográficos (Bcrypt)	—	—	—	—	✓
RNF-04	Privacidad ética: anonimización de menores (LGDNNA)	—	—	~	✓	✓
RNF-05	Integridad transaccional: ACID Rollback ante fallos de lote	—	—	—	✓	✓

Leyenda: ✓ = satisfecho; ~ = parcialmente

satisfecho; — = no implementado

La tabla evidencia que el Prototipo 3 constituyó el punto de inflexión crítico del proyecto: en él se satisfacen por primera vez los requerimientos de mayor peso técnico (RF-04, RF-06, RNF-02, RNF-05). El Prototipo 4 completa la cobertura cerrando los requerimientos de interfaz (RF-05, RF-07, RF-08) y seguridad operacional (RNF-03), alcanzando el 100 % de cobertura del protocolo 2026-A135.

Desarrollo del Trabajo Terminal I

En este capítulo se presenta una síntesis de los tres prototipos desarrollados durante el Trabajo Terminal I (agosto - diciembre 2025). El propósito no es poner la misma documentación técnica sino extraer las métricas clave, documentar las decisiones más relevantes y sobretodo argumentar las limitaciones identificadas que justifican la migración del enfoque utilizado. Cada prototipo es presentado como un experimento pues su valor radica tanto en lo que logró como en lo que demostró no ser viable.

7.1. Prototipo 0: Scraping directo sobre HTML

7.1.1. Premisa y Enfoque

El Prototipo 0 se planteó como una prueba de concepto que fue verificar si era posible extraer noticias directamente del HTML de los sitios de noticias mexicanas, utilizando BeautifulSoup y la librería requests. El supuesto inicial era que los sitios de noticias de acceso público serían accesibles de forma programática sin fricción alguna.

7.1.2. Resultado: Inviabilidad por seguridad perimetral

La premisa fue invalidada en su totalidad pues el sistema se encontró con dos barreras técnicas alarmantes:

1. **WAF y Cloudflare (HTTP 403/503).** Cerca del 78 % de los medios objetivo (incluyendo portales como *Reforma*, *El Universal* y *Milenio*) operaban detrás de un WAF de grado empresarial. Lo que hacia la librería requests era generar un hash TLS/JA3 determinístico que los sistemas de detección identificaban como un cliente automatizado, recibiendo como respuesta HTTP 403 (Forbidden).
2. **Contenido dinámico renderizado en cliente.** Múltiples sitios entregan el marcado HTML del artículo mediante llamadas AJAX en JavaScript ejecutadas en el navegador. BeautifulSoup al trabajar sobre el HTML estático descargado solo encontraba el esqueleto de la página sin el contenido informativo lo que hacia imposible la extracción.

7.1.3. Decisión Técnica

El fallo del prototipo 0 hizo evidente que el scraping al HTML directo no era una estrategia viable para el monitoreo de medios de noticias modernos. Por lo que se decidió abandonar el scraping directo y migrar hacia fuentes diseñadas para la ingestión automatizada, como lo son los feeds RSS y las APIs.

7.2. Prototipo 1: RSS + K-Means

7.2.1. Arquitectura implementada

El Prototipo 1 estableció la primera iteración funcional del sistema. La migración hacia feeds RSS eliminó la fricción de acceso, pues los feeds son recursos XML diseñados explícitamente para el consumo automatizado y no están sujetos a los mecanismos WAF que bloquearon el P0.

El flujo implementado consistió en las siguientes etapas:

1. **Recolección.** Ingestión de 8 fuentes RSS nacionales mediante `feedparser`, extrayendo por cada `<item>` el título, descripción, enlace y fecha de publicación.
2. **Detección rudimentaria de NNA.** Función `detect_children_mentions` con 15 palabras clave aisladas (“hijo”, “menor”, “niño”, “huérfano”, etc.).
3. **Vectorización TF-IDF.** Representación de documentos en $\mathbb{R}^{1000}$ mediante `TfidfVectorizer` con `max_features=1000`, `ngram_range=(1, 1)`.
4. **Agrupamiento K-Means.** Clustering con $k = 4$ fijo y métrica euclidiana sobre la matriz TF-IDF.
5. **Persistencia.** Exportación a CSV mediante `Pandas`.

Volumen de datos: 96 noticias únicas por ejecución; persistencia en archivos planos CSV.

7.2.2. Limitaciones Identificadas

Las limitaciones del P1 fueron de tres órdenes:

Techo semántico del detector. La detección por palabras clave aisladas generó una tasa de falsos positivos del **80 %**: noticias sobre legislación (“aprobación de ley de protección al menor”), campañas de prevención y estadísticas de incidencia activaban el detector sin representar casos concretos de orfandad.

Dimensionalidad escasa en K-Means. El algoritmo asume clústeres globulares de tamaño similar y requiere especificar k *a priori*. Con 96 documentos y $k = 4$ el sistema forzaba eventos periodísticos distintos en el mismo clúster para balancear tamaños, generando grupos sin coherencia semántica real. El *Silhouette Score* resultante fue de **0.23** (baja calidad de agrupamiento). El vocabulario limitado a 1,000 características también excluía términos especializados del dominio como “custodia”, “DIF” y “tutor legal”.

Cobertura. El sistema cubría solo medios nacionales con feed RSS público, excluyendo la prensa regional donde suelen aparecer los casos más específicos de feminicidios con NNA identificados.

7.3. Prototipo 2: Triple Fuente + DBSCAN + FeminicideDetector

7.3.1. Evolución del sistema

El Prototipo 2 que fue la culminación del TT1 reestructuró el sistema en respuesta directa a las limitaciones del P1. Los cambios fueron sustanciales en las tres capas del flujo de procesamiento:

Recolección: Arquitectura de Triple Fuente. Se amplió la estrategia de ingesta a tres mecanismos complementarios: (a) **10 feeds RSS** nacionales y de género (incorporando CIMAC Noticias y Milenio, especializadas en violencia de género); (b) **Google News** con 5 consultas de dominio ("*feminicidio México*", "*asesinato mujer*", "*violencia género*"), (c) **Historical Scraper** mediante paginación mensual de Google News, cubriendo el período mayo–noviembre 2025 (6 meses de retrospectiva).

Detección: Clase FeminicideDetector (72 patrones RegEx). Se reemplazó la función rudimentaria por una clase especializada con **tres categorías de patrones**: 40 patrones de feminicidio (incluyendo patrones contextuales como *r'mujer.*asesinada'* y *r'cadáver.*femenino'*), 15 patrones de NNA (patrones relacionales como *r'hijo.*huérfano'* y *r'adolescente.*perdió.*madre'*) y **17 patrones de exclusión**. Esta última categoría fue un cambio importante en el P2 pues al detectar términos como *r'ley.*protección'*, *r'estadística'* o *r'campaña.*prevención'*, la noticia era descartada automáticamente. Además el sistema asignaba un *score* de confianza continuo y una prioridad discreta (Alta/Media/Baja/Irrelevante).

Agrupamiento: DBSCAN en lugar de K-Means. El cambio de K-Means a DBSCAN respondía a las propiedades de la distribución de noticias periodísticas: la mayoría de los feminicidios son eventos únicos con cobertura mínima (1 o 2 noticias), mientras que un evento mediáticamente relevante (como el caso de Ángela Birkenbach) genera una densidad local de 5 a 10 noticias. DBSCAN identificaba naturalmente estas densidades sin requerir un valor de *a priori* para el número de clústeres, asignando como ruido los eventos que si son únicos y que precisamente son los más valiosos para el sistema pues representan casos individuales.

7.4. Limitaciones identificadas

7.4.1. Falsos positivos: Insuficiencia de la Sintaxis

El módulo de detección FeminicideDetector redujo los falsos positivos del 80 % (P1) al 60 % (P2) que si fue un avance significativo. Sin embargo el análisis de los falsos positivos revela un patrón que no puede resolverse únicamente con expresiones regulares:

- "*Durango aprueba la Ley Nicole para prohibir cirugías estéticas en menores de edad*": esta noticia activa el patrón de NNA ("*menores de edad*") sin que los patrones de exclusión capturaran el término *.aprueba* en ese contexto legislativo específico.
- *REDIM reporta: 1 de cada 4 NNA vive en situación de violencia familiar*: El término "*NNA*" y "*violencia*" activan el detector en una nota estadística sin ningún caso concreto identificado.

El problema de fondo no es la cantidad de patrones pues el sistema ya tenía 72, sino la **naturaleza sintáctica** del enfoque, la co-ocurrencia de términos no implica la co-ocurrencia de los *roles semánticos* que esos términos desempeñan en la oración. Una expresión regular no puede distinguir si "*menor*" en una noticia es la víctima directa (una menor asesinada), la víctima indirecta (el hijo huérfano de la madre asesinada) o el sujeto de una campaña legislativa. Esta distinción es esencial para el dominio del sistema y fue exactamente el tipo de comprensión que los modelos de lenguaje bidireccionales como BETO proveen a través de sus mecanismos de atención, en donde la representación de cada token es función del contexto completo de la oración.

7.4.2. Clustering Léxico: DBSCAN sobre TF-IDF

Los 3 clústeres identificados por DBSCAN son semánticamente coherentes, pero cerca del 80 % de outliers que aunque eran correctos para eventos únicos ocultaban un problema más profundo y es que las noticias sobre el *mismo evento* que eran redactadas con vocabulario diferente por distintos medios no eran agrupadas.

Ejemplo documentado: "Madre es asesinada y deja 2 hijos huérfanos en Ecatepec" (nota policiaca de El Sol de México) y "Feminicidio en el Estado de México: dos menores quedan sin madre" (nota de derechos humanos de CIMAC Noticias) reportaban el mismo caso con vocabularios distintos. Los vectores TF-IDF de ambas noticias tenían una similitud coseno de 0.18 (muy por debajo del umbral $\epsilon=0.8$) por lo que DBSCAN los clasificaba como documentos independientes. En el espacio semántico de BETO, los documentos tendrían embeddings con similitud coseno superior a 0.85 siendo correctamente agrupados como instancias del mismo evento.

7.4.3. La poca escalabilidad del almacenamiento en CSV

La persistencia en archivos CSV impone restricciones estructurales:

- **Ausencia de integridad referencial.** No existe mecanismo que garantice que una detección apunte a una noticia existente.
- **Sin acceso concurrente.** La escritura por el worker y la lectura por el dashboard desde el mismo archivo CSV generaban condiciones de carrera, en el P2 el problema se "solucionó" temporalmente mediante escritura atómica por renombrado pero el problema no se eliminó.

7.4.4. Síntesis: La necesidad de comprensión semántica

Las limitaciones anteriores nos llevan a la conclusión de que el problema de la identificación de NNA en situación de orfandad por feminicidio **requiere comprensión semántica del lenguaje natural** no solo reconocimiento de patrones léxicos. El texto de una noticia periodística es un artefacto pragmático donde el significado emerge de la interacción entre entidades, roles semánticos, modalidades y contexto narrativo, dimensiones que están fuera del alcance de las expresiones regulares.

La tabla 7.1 muestra los objetivos cuantitativos que el Trabajo Terminal II debe alcanzar para superar lo establecido en el Trabajo Terminal I.

Tabla 7.1: Comparativa de métricas: TT1 vs. metas del TT2

Métrica	TT1 (P2)	Meta TT2 (P4)	Mejora
Falsos positivos	60 %	≤ 30 %	-50 %
Fuentes monitoreadas	10 RSS + Google News	45 RSS + Google News + Stealth	+350 %
Cobertura temporal	6 meses	Continua	Operacional
Persistencia	CSV (plano)	PostgreSQL 16 (ACID)	Estructural
Latencia de consulta	$O(n)$ scan CSV	$O(\log n)$ índice GIN	Órdenes de magnitud
Motor de clasificación	RegEx (72 patrones)	BETO + Neuro-Simbólico	Paradigma distinto

Las metas de la tabla 7.1 son los objetivos mínimos que hacen del sistema una herramienta operativamente confiable para organizaciones civiles que trabajan con casos reales de NNA en situación de vulnerabilidad.

7.5. Arquitectura del Sistema

El diseño arquitectónico del *Sistema Inteligente para la Identificación y Seguimiento de NNA* sigue un paradigma orientado a microservicios altamente desacoplados. Esta decisión metodológica permite que el procesamiento intensivo (*Machine Learning*) opere en hilos o contenedores aislados sin degradar el tiempo de respuesta de la interfaz de usuario. A continuación, se detallan los diagramas estructurales y de comportamiento que definen el flujo de la información.

7.5.1. Diagrama de Componentes (Arquitectura en Capas)

El sistema está dividido lógicamente en tres estratos principales: la **Capa de Presentación**, la **Capa de Procesamiento Neuro-Simbólico** (donde reside el núcleo de la investigación) y la **Capa de Datos**.

Como se observa en la Figura 7.1, el flujo comienza en la capa de procesamiento. El Scraper obtiene el HTML en bruto desde los portales web y lo transfiere al Deduplicator. Éste actúa como una barrera de contención computacional, evitando que textos redundantes consuman ciclos de CPU en la inferencia neuronal. Posteriormente, el Heuristic Analyzer y el Semantic Detector operan en tándem (fusión neuro-simbólica) para clasificar la relevancia de la noticia. Finalmente, las agrupaciones son delegadas a BERTopic antes de descender a la **Capa de Datos** (PostgreSQL). La **Capa de Presentación** jamás interactúa con el NLP de forma síncrona; se limita a consumir los resultados ya computados a través de la API.

7.5.2. Diagrama de Secuencia (Ciclo de Vida de la Noticia)

Para comprender la orquestación temporal y los mensajes intercambiados de manera asíncrona entre los contenedores, se presenta el Diagrama de Secuencia del proceso de análisis diario (Cronjob).

La Figura 7.2 demuestra el carácter *Pipeline-Driven* (guiado por tuberías) de la arquitectura. En el Paso 4, el deduplicador hace una consulta de verificación rápida contra PostgreSQL para descartar copias exactas. El trabajo más pesado (Pasos 9 al 11) se aísla dentro del SemanticDetector, donde BETO evalúa el texto y calcula el factor de ponderación α para aplicar el Bozal de Penalización si es necesario. Es de vital importancia notar que la actualización de BERTopic (Paso 13) se dispara *a posteriori*, ya que los algoritmos de reducción de dimensionalidad (UMAP) requieren el volumen de datos de todo el lote completo para mapear correctamente el espacio topológico. Por último, la aplicación Web lee los resultados en la base de datos de manera ininterrumpida.

```

graph TD
    %% Capa de Presentación
    subgraph CapaPresentacion [Capa de Presentación Web]
        Dashboard[Flask Dashboard]
        API[API RESTful]
        Forms[Gestión de Fuentes]
    end

    %% Capa de Procesamiento NLP
    subgraph CapaProcesamiento [Capa de Procesamiento Neuro-Simbólico]
        Scraper[Scraper / Collector\n(StealthSessions)]
        Dedup[Deduplicator\n(MD5, SimHash, Jaccard)]
        Analyzer[Heuristic Analyzer\n(RegEx Bypass)]
        Semantic[Semantic Detector\n(BETO Zero-Shot)]
        Cluster[BERTopic Clustering\n(UMAP + HDBSCAN)]
        Investigator[Case Investigator\n(Fichas Consolidadas)]

        Scraper --> Dedup
        Dedup --> Analyzer
        Analyzer --> Semantic
        Semantic --> Cluster
        Cluster --> Investigator
    end

    %% Capa de Datos
    subgraph CapaDatos [Capa de Persistencia]
        DB[(PostgreSQL 16\nRelacional + FTS)]
    end

    %% Interacciones inter-capa
    API <--> |Query ORM| DB
    Dashboard --> Forms
    Forms --> DB
    Investigator --> DB
    Semantic --> DB
    Scraper -. -> |Peticiones HTTP| Internet

```

Figura 7.1: Diagrama de Componentes de la Arquitectura del Sistema.

```
sequenceDiagram
    autonumber
    actor Admin as Cronjob / Sistema
    participant S as Scraper (Collector)
    participant D as Deduplicador (dedup.py)
    participant BETO as SemanticDetector (BETO)
    participant BT as BERTopic (Clustering)
    participant DB as PostgreSQL
    participant W as Dashboard Web

    Admin->>S: trigger_recoleccion()
    S->>S: Extrae HTML/RSS (StealthSessions)
    S->>D: Envía lote bruto de textos
    D->>DB: Consulta hashes existentes (MD5/SimHash)
    DB-->>D: Retorna firmas registradas
    D->>D: Filtra duplicados cruzados
    D-->>S: Retorna lote de textos únicos

    S->>BETO: process_semantics(clean_articles)
    BETO->>BETO: Tokenización (WordPiece 512 max)
    BETO->>BETO: Inferencia Zero-Shot + Temperature Scaling
    BETO->>BETO: Fusión Neuro-Simbólica (Cálculo factor Alpha)
    BETO->>DB: INSERT (noticias, detecciones)

    Admin->>BT: trigger_clustering()
    BT->>DB: SELECT noticias recientes
    BT->>BT: Reducción UMAP y densidad HDBSCAN
    BT->>DB: UPDATE (cluster_id, topics)

    W->>DB: GET /api/clusters
    DB-->>W: Retorna JSON estructurado
    W->>Admin: Renderiza tarjetas en Interfaz Gráfica
```

Figura 7.2: Diagrama de Secuencia ilustrando el ciclo de vida de una noticia.

7.6. Diseño de Datos

La arquitectura del sistema requiere un mecanismo de persistencia capaz de manejar inserciones masivas concurrentes y resolver búsquedas complejas sobre grandes volúmenes de texto no estructurado. Por este motivo, se seleccionó **PostgreSQL** como el Sistema Gestor de Bases de Datos Relacional-Objeto (ORDBMS) principal. La estructura relacional garantiza la integridad referencial de la información recolectada cumpliendo estrictamente con el modelo ACID (Atomicidad, Consistencia, Aislamiento y Durabilidad).

Un pilar fundamental de este diseño es el soporte nativo para *Full-Text Search* (FTS). El campo `busqueda_fts` de tipo `tsvector` almacena el corpus periodístico procesado (aplicando *stemming* y eliminando *stop words* en español). Para consultar este vector de forma instantánea, se configuró un Índice Invertido Generalizado (GIN). Mientras que los índices tradicionales (B-Tree) son ineficientes para buscar palabras dentro de textos largos, el índice GIN mapea cada lexema a los IDs de los registros que lo contienen, reduciendo la latencia de las consultas analíticas del Dashboard a un rango sub-milisegundo, incluso al iterar sobre millones de palabras.

7.6.1. Modelo de Dominio

A continuación, se presenta el Modelo de Dominio que formaliza no solo las relaciones de cardinalidad, sino los tipos de datos nativos proyectados en la base de datos y la capa de inferencia de Inteligencia Artificial (ej. `tsvector` y `Float` para tensores).

7.6.2. Diccionario de Datos Extendido

Las siguientes tablas formalizan la especificación de los modelos SQLAlchemy de la aplicación, definiendo reglas de integridad (*Null*, *Defaults*) y estrategias de indexación.

Campo	Tipo	Llave	Nulo	Default	Índices	Descripción
<code>id</code>	Integer	PK	NO	Auto	B-Tree (PK)	Identificador único de la noticia.
<code>cluster_id</code>	Integer	FK	SÍ	NULL	B-Tree	Referencia al clúster (<code>clusters_semanticos.id</code>).
<code>titulo</code>	Varchar(500)	-	NO	-	B-Tree	Titular principal extraído de la nota.
<code>contenido</code>	Text	-	NO	-	-	Cuerpo completo de la noticia.
<code>enlace</code>	Varchar(2000)	-	SÍ	NULL	UNIQUE	URL original de la noticia.
<code>score_compuesto</code>	Float	-	NO	0.0	B-Tree	Puntuación ponderada final (BETO + Heurística).
<code>content_hash</code>	Varchar(64)	-	SÍ	NULL	B-Tree	Hash MD5 para deduplicación cruzada.
<code>busqueda_fts</code>	tsvector	-	SÍ	NULL	GIN	Vector semántico actualizado vía Trigger SQL.

Tabla 7.2: Diccionario de Datos: Entidad noticias.


```

classDiagram
    class NOTICIAS {
        +Integer id [PK]
        +Integer cluster_id [FK]
        +Varchar(500) titulo
        +Text contenido
        +Varchar(2000) enlace
        +Float score_compuesto
        +Varchar(64) content_hash
        +tsvector busqueda_fts
    }

    class DETECCIONES {
        +Integer id [PK]
        +Integer noticia_id [FK]
        +Float score_heuristico
        +Float score_semantico
        +Float score_hibrido
        +Varchar(20) clasificacion_hibrida
        +Boolean menores_identificados
    }

    class CLUSTERS_SEMANTICOS {
        +Integer id [PK]
        +Varchar(200) etiqueta
        +JSON terminos_principales
        +Integer num_documentos
        +Float cohesion
    }

    class FUENTES {
        +Integer id [PK]
        +Varchar(200) nombre
        +Varchar(1000) url
        +Varchar(20) tipo
        +Boolean activo
    }

    class USUARIOS {
        +Integer id [PK]
        +Varchar(100) username
        +Varchar(256) password_hash
        +Varchar(50) rol
        +Timestamp created_at
    }

    FUENTES "1" -- "*" NOTICIAS : alimenta
    NOTICIAS "*" -- "1" CLUSTERS_SEMANTICOS : pertenece
    NOTICIAS "1" -- "1" DETECCIONES : genera

```

Figura 7.3: Diagrama de Clases / Dominio detallando Tipos de Datos y Relaciones.

Campo	Tipo	Llave	Nulo	Default	Índices	Descripción
id	Integer	PK	NO	Auto	B-Tree (PK)	Identificador de la detección.
noticia_id	Integer	FK	NO	-	UNIQUE	Enlace al artículo (noticias.id).
score_heuristico	Float	-	SÍ	NULL	-	Puntuación de reglas RegEx (By-pass).
score_semantico	Float	-	SÍ	NULL	-	Certeza matemática inferida por BETO.
score_hibrido	Float	-	SÍ	NULL	-	Puntuación tras aplicar el Bozal de Penalización.
clasificacion_hibrida	Varchar(20)	-	SÍ	NULL	-	Etiqueta de severidad (Alta/Media/Baja).
menores_identificados	Boolean	-	NO	False	-	Flag de existencia de un NNA en orfandad.

Tabla 7.3: Diccionario de Datos: Entidad detecciones.

Campo	Tipo	Llave	Nulo	Default	Índices	Descripción
id	Integer	PK	NO	Auto	B-Tree (PK)	Identificador único del clúster.
etiqueta	Varchar(200)	-	SÍ	NULL	-	Etiqueta semántica sugerida por BERTopic.
terminos_principales	JSON	-	SÍ	NULL	-	Vector de palabras clave (c-TF-IDF).
num_documentos	Integer	-	NO	0	-	Cantidad de noticias condensadas.
cohesion	Float	-	SÍ	NULL	-	Nivel de densidad topológica (HDBSCAN).

Tabla 7.4: Diccionario de Datos: Entidad clusters_semanticos.

Campo	Tipo	Llave	Nulo	Default	Índices	Descripción
id	Integer	PK	NO	Auto	B-Tree (PK)	Identificador único de la fuente.
nombre	Varchar(200)	-	NO	-	-	Nombre público del medio de comunicación.
url	Varchar(1000)	-	NO	-	UNIQUE	Endpoint de origen (RSS/Search).
tipo	Varchar(20)	-	NO	-	-	Clasificador (RSS", "HTML Search").
activo	Boolean	-	NO	True	-	Bandera para ejecución en el Cron-job.

Tabla 7.5: Diccionario de Datos: Entidad fuentes.

Campo	Tipo	Llave	Nulo	Default	Índices	Descripción
id	Integer	PK	NO	Auto	B-Tree (PK)	Identificador único del analista.
username	Varchar(100)	-	NO	-	UNIQUE	Nombre de inicio de sesión.
password_hash	Varchar(256)	-	NO	-	-	Hash criptográfico (Bcrypt).
rol	Varchar(50)	-	NO	"Lector"	-	Nivel de privilegios (Admin/Lector).
created_at	Timestamp	-	NO	now()	-	Marca de tiempo de creación.

Tabla 7.6: Diccionario de Datos: Entidad usuarios.

Desarrollo de Trabajo Terminal II

Este capítulo constituye el desarrollo del Trabajo Terminal II. A diferencia del enfoque descriptivo empleado en el capítulo anterior, la narrativa aquí es evolutiva y autocrítica pues cada decisión de diseño se presenta como respuesta directa a una deficiencia medida y documentada de la iteración anterior. El Prototipo 3 y el Prototipo 4 no surgieron de una planificación inicial sino de un proceso de *diagnóstico, rediseño e integración incremental* que hizo posible transformar un clasificador heurístico basado en palabras clave en una plataforma robusta y escalable.

La arquitectura resultante opera sobre tres objetivos específicos derivados del protocolo 2026-A135: (OE-1) Identificar y seleccionar fuentes públicas confiables que contengan información relacionada con feminicidios y posibles víctimas indirectas, (OE-3) Implementar técnicas de Procesamiento de Lenguaje Natural para extraer y estructurar información clave a partir de textos no estructurados, y (OE-4) Diseñar una base de datos estructurada que permita almacenar la información recolectada de manera eficiente y segura. Estos tres ejes gestionan todas las decisiones técnicas documentadas en las siguientes secciones.

8.1. Contexto: Limitaciones del Prototipo 2

A finales del semestre pasado(2026-1) el sistema hasta el momento presentaba tres limitaciones estructurales que motivaron un rediseño del sistema.

Limitación 1 Semántica del motor RegEx. El módulo *FeminicideDetector* del prototipo 2 evaluaba la *co-ocurrencia espacial* de tokens léxicos sin comprender el rol gramatical de cada entidad. La tasa de falsos positivos vista manualmente alcanzó el **60 %** y notamos que se manifestaba principalmente en tres escenarios:

1. Titulares como "*Menor de edad detenido por feminicidio*" donde el modelo detectaba la co-ocurrencia de "menor" y "feminicidio" lo que activaba la alerta de orfandad cuando en realidad el menor era el agresor y no una víctima indirecta.
2. Noticias estadísticas gubernamentales ("*10 feminicidios mensuales, 5 huérfanos en promedio*") que activaban la alerta de orfandad al concentrar todos los tokens detonantes en un solo párrafo.
3. Noticias donde la víctima directa del feminicidio era una menor de edad y eran confundidas sistemáticamente con casos de orfandad colateral.

Limitación 2 Cuello de botella en persistencia plana. El almacenamiento en archivos CSV (`noticias.csv`) impedía la ejecución de consultas de filtrado sin cargar la totalidad del corpus en memoria RAM ($O(n)$ sobre el conjunto completo). Con un volumen de 250 registros en el prototipo 2 la latencia era tolerable pero proyectado a escala nacional (que son miles de noticias) esta arquitectura no lo soportaría y la ausencia de integridad referencial hace difícil mantener relaciones consistentes entre noticias, fuentes y resultados de análisis.

Limitación 3 Clustering K-Means desacoplado del clasificador. El agrupamiento temático se ejecutaba *después* de la clasificación individual lo que privaba al clasificador del contexto global. Una noticia genérica sobre política criminal podía obtener el mismo score heurístico que un caso concreto de feminicidio con NNA afectados y esto sin que el sistema supiera en que contexto se encontraba.

Estas tres limitaciones nos ayudaron a definir el alcance del sistema y el orden de implementación de las soluciones.

Limitación 4 Ausencia de investigación profunda por caso. El pipeline del TT1 producía clasificaciones de relevancia pero no extraía información estructurada sobre los casos específicos: quién era la víctima directa, cuántos menores quedaron huérfanos, en qué estado se encontraban o qué institución estaba a cargo. Esta limitación era especialmente crítica porque el propósito central del sistema no es solo detectar noticias relevantes sino construir fichas de caso para facilitar la intervención de los investigadores. La información estructurada disponible en el web abierto (notas complementarias, boletines del DIF, seguimientos periodísticos) no estaba siendo aprovechada en ninguna etapa del pipeline.

8.2. Patrones arquitectónicos del flujo analítico

Para garantizar la mantenibilidad y extensibilidad del sistema, el flujo analítico implementa dos patrones de diseño que desacoplan responsabilidades.

8.2.1. Patrón *Repository* para la capa de persistencia

El acceso a PostgreSQL se encapsula en la clase `NoticiasRepository` (`src/database/repository.py`), siguiendo el patrón *Repository* de Martin Fowler [?]. Esta decisión tiene dos objetivos: (a) aislar la lógica de negocio del motor de base de datos, permitiendo sustituir PostgreSQL por cualquier otro backend sin modificar el Flujo analítico; (b) centralizar la gestión de sesiones SQLAlchemy, evitando así fugas de conexiones (*connection leaks*) en un entorno Flask multi-hilo. El repositorio expone métodos tipados que internamente utilizan los índices invertidos de PostgreSQL sobre columnas `tsvector` lo que garantiza búsquedas en $O(\log n)$ frente al $O(n)$ del filtrado CSV.

8.2.2. Patrón *Pipeline* para el flujo analítico

El orquestador principal `SimplifiedNewsAnalyzer` materializa el patrón *pipeline* mediante diez pasos discretos y ordenados. Cada paso recibe el estado modificado por el anterior a través del atributo compartido `self.df_processed`, y puede activarse o desactivarse mediante *feature flags* booleanos en la llamada a `run_complete_analysis()`.

Este diseño permite por ejemplo desactivar la funcionalidad de `enable_bertopic` en entornos con memoria RAM limitada (debajo de 4 GB) sin comprometer la clasificación semántica ni la persistencia, preservando así el principio de responsabilidad única de cada módulo.

8.3. Prototipo 3 Motor semántico BETO y migración de persistencia

El Prototipo 3 introduce simultáneamente las dos soluciones de mayor impacto arquitectónico que por un lado es la sustitución del motor sintáctico por BETO y por el otro es la migración del almacenamiento plano a PostgreSQL. Ambas transformaciones son interdependientes pues PostgreSQL provee la infraestructura relacional que permite almacenar

los nuevos campos semánticos generados por BETO (`score_semantico`, `modo_deteccion`, `topic_id`) con integridad referencial.

8.3.1. Migración de CSV a PostgreSQL

La migración del sistema de persistencia es uno de los puntos de mayor impacto para el TT2. La justificación técnica de abandonar CSV en favor de PostgreSQL se basa en tres argumentos que se hicieron evidentes durante el TT1.

1. **Integridad referencial.** Una arquitectura multi-tabla (noticias, fuentes, clusters, batches de ejecución) requiere claves foráneas con restricciones `FOREIGN KEY` que garanticen la consistencia de los datos. Los archivos CSV no tienen mecanismo alguno de relación entre entidades; cualquier join debía realizarse en memoria con Pandas cosa que es costosa en términos de RAM.
2. **Búsqueda de texto completo (FTS).** PostgreSQL implementa FTS nativa mediante columnas `tsvector` e índices GIN. Una consulta como "niños huérfanos DIF Veracruz" se traduce a una intersección de vectores léxicos en $O(\log n)$. El equivalente en CSV exige iterar cada registro y aplicar expresiones regulares en $O(n)$.
3. **Concurrencia segura.** El dashboard en Flask y el flujo de extracción analítica pueden ejecutarse simultáneamente sin corrupción de datos, gracias al modelo ACID de PostgreSQL. La escritura concurrente en un mismo archivo CSV requeriría locks manuales propensos a condiciones de carrera.

El esquema de la tabla principal noticias almacena campos como `score_semantico` `FLOAT`, `topic_id` `INTEGER`, `clasificacion_final` `VARCHAR(20)` y `search_vector` `tsvector`. Este último campo se actualiza automáticamente por un *trigger* PostgreSQL que concatena título y contenido al momento de la inserción.

8.3.2. Arquitectura del motor BETO

Al inicio del TT2 se definió que el motor RegEx con expresiones regulares ya había alcanzado su límite de optimización por lo que se decidió migrar al modelo BETO (*bert-base-spanish-wwm-cased*) que responde a una necesidad de *comprensión contextual* que ningún sistema basado en patrones léxicos puede proveer. BETO es un modelo Transformer bidireccional con **110 millones de parámetros**, 12 capas de autoatención y embeddings de 768 dimensiones, preentrenado sobre Wikipedia en español y corpus OPUS mediante el objetivo de Modelado de Lenguaje Enmascarado (MLM).

La arquitectura interna del clasificador implementada en la clase `SemanticDetector` opera según el siguiente flujo:

1. **Tokenización WordPiece.** El texto de entrada (título concatenado con los primeros 1,500 caracteres del contenido separados por el token especial [SEP]) es fragmentado mediante el algoritmo WordPiece que descompone palabras fuera de vocabulario en sub-tokens reconocibles. Esto resuelve el problema de variantes ortográficas comunes en el periodismo mexicano.
2. **Forward pass a través de 12 capas Transformer.** Cada capa aplica mecanismos de *self-attention* multi-cabeza que recalculan el valor de cada token en función de su contexto bidireccional completo. El resultado es que el token "menor" adquiere representaciones vectoriales radicalmente diferentes dependiendo de si aparece como sujeto activo ("un menor agredió") o como objeto pasivo ("sus hijos menores quedaron huérfanos").
3. **Extracción del embedding [CLS].** El token especial [CLS] (primer token de toda secuencia BERT) acumula durante el *forward pass* una representación condensada del significado global del texto. Se extrae el *hidden state* de este token como un vector de 768 dimensiones que posteriormente se normaliza mediante norma L2 para habilitar la comparación por similitud coseno.

8.3.3. Clasificación Zero-Shot y Temperature Scaling

Dado que el proyecto no disponía de un corpus etiquetado de suficiente volumen para fine-tuning supervisado al inicio del TT2 se optó por el paradigma de clasificación **zero-shot** por similitud coseno. El sistema pre-calcula embeddings BETO para dos descripciones de categorías cuidadosamente redactadas (en `semantic_detector.py`) que especifican en lenguaje natural qué constituye una noticia relevante contra una "no relevante" para el dominio del sistema. La categoría relevante describe explícitamente *un caso concreto de feminicidio donde los hijos de la víctima quedaron en orfandad o resguardo institucional*, mientras que la categoría "no relevante" enumera explícitamente los falsos positivos que fueron recurrentes en TT1 como notas estadísticas, políticas públicas, feminicidios de menores y agresores menores de edad.

En tiempo de inferencia el embedding del texto de la noticia se compara contra ambas descripciones mediante producto punto el cual es equivalente a similitud coseno para vectores normalizados. Las similitudes crudas tienden a ser extremadamente cercanas con diferencias de 0.02-0.05 lo que genera incertidumbre en la clasificación. Para resolver este problema se aplica **Temperature Scaling** con factor térmico 5, que actúa como amplificador de la separación probabilística antes de la función Softmax.

Este mecanismo es análogo al *temperature scaling* utilizado en calibración de modelos de clasificación [?] solo que aplicado en dirección inversa pues en lugar de suavizar distribuciones sobre-confiadas, se *agudiza* una distribución cruda sub-confiada para forzar una toma de decisión clara.

8.3.4. Evolución del recolector

La recolección de noticias enfrentó durante TT1 una barrera que los prototipos iniciales no pudieron superar que fueron los *Web Application Firewalls* (WAF) de Cloudflare y Akamai que detectaban y bloqueaban las sesiones HTTP del scraper mediante **TLS/JA3 fingerprinting**. Este mecanismo compara el *hash* criptográfico del saludo TLS del cliente (que identifica sin error la librería SSL utilizada) contra el User-Agent declarado. Una sesión que declara ser Chrome/124 pero cuyo handshake TLS corresponde a Python/requests es inmediatamente bloqueada como bot.

En el Prototipo 3 se introduce *StealthSession* que resolvía este problema mediante tres técnicas complementarias:

1. **Emulación de fingerprint TLS via cloudscraper.** La librería *cloudscraper* reemplaza la pila TLS de Python con una que genera hashes JA3 idénticos a los de Chrome/Windows lo que hace que el handshake sea criptográficamente indistinguible de un navegador real. Además resuelve automáticamente los *JavaScript challenges* de Cloudflare (challengepage 403/503) que desde el Prototipo 0 no se habían podido superar.
2. **Delays con distribución.** En TT1 los delays entre requests eran uniformes $U(8, 20)$ segundos, lo que lo hacía un patrón detectable por cualquier WAF moderno que analice la distribución temporal de las solicitudes. La distribución uniforme tiene densidad constante en todo el intervalo pero los humanos reales tienen un patrón asimétrico con *cola larga* donde la mayoría de acciones son rápidas (como clicks o scrolls) y ocasionalmente hay pausas largas (como la lectura de un artículo). Este comportamiento es capturado por la distribución log-normal con parámetros $\mu = 2,5$, $\sigma = 0,7$, que genera una mediana de aproximada de 12.2 segundos y colas que alcanzan hasta 45 segundos.
3. **Circuit Breaker por dominio.** El patrón *Circuit Breaker* (Fowler, 2014) evita saturar dominios que fallan repetidamente. Lo que hace que después de 3 fallos consecutivos en un dominio este circuito se abra y rechace requests por 300 segundos, pasándolo a un estado semi-abierto para permitir un request de prueba y si este tiene éxito el circuito se cierra pero si falla el cooldown se extiende a 600 segundos. Este mecanismo reduce el riesgo de un bloqueo permanente de IP al evitar presionar un sitio que activamente está bloqueando las sesiones.




Figura 8.1: Arquitectura del motor BETO y clasificación *Zero-Shot* con *Temperature Scaling*.

8.3.5. Deduplicación en cascada de cuatro fases

Una consecuencia directa de esta arquitectura multi-fuente (45 RSS + Google News + scraping HTML) es la aparición de noticias cuasi-duplicadas pues el mismo evento es cubierto por diferentes medios con redacciones parcialmente distintas. Sin deduplicación el corpus infla artificialmente la estadística y puede generar alertas redundantes en el dashboard.

El módulo de deduplicación implementa una cascada de cuatro algoritmos de complejidad creciente que son aplicados en orden de coste computacional ascendente y de modo que los casos más obvios se resuelven con el método más barato y solo los casos ambiguos escalan al siguiente nivel.

1. **Hash MD5 exacto.** Detecta duplicados literalmente (mismo texto, misma fuente). Complejidad $O(1)$ por par. Elimina re-publicaciones idénticas.
2. **Similitud de Jaccard sobre conjuntos de tokens.** Mide la razón de intersección sobre unión de los conjuntos de palabras de dos títulos, con un umbral de $J \geq 0,70$ este captura reescrituras con sustituciones léxicas simples ("Niña de 11 años fue asesinada" $\leftrightarrow$ "Niña de 11 años perdió la vida").
3. **SimHash.** Genera una firma de 64 bits por cada documento mediante proyecciones aleatorias sobre el espacio TF-IDF. Dos documentos con distancia Hamming de 6 bits se consideran cuasi-duplicados. Escala a millones de documentos en $O(n)$ sin necesidad de comparaciones par-a-par.
4. **Similitud coseno TF-IDF.** Para los pares que superan las fases anteriores pero generan dudas se calcula la similitud coseno completa entre los vectores TF-IDF del contenido con un umbral de $\cos \geq 0,85$. En este paso el costo es $O(n^2)$ en el peor caso pero gracias al pre-filtrado de las fases anteriores solo se aplica a un subconjunto pequeño de pares.




Figura 8.2: Flujo de deduplicación en cascada.

En las pruebas de validación (corpus de 847 noticias recolectadas en un ciclo de 90 días), la cascada eliminó **213 duplicados** (25.1 % del total), con la siguiente distribución por fase: 89 por MD5 (exactos), 61 por Jaccard, 43 por SimHash y 20 por similitud coseno TF-IDF. El corpus resultante de 634 noticias únicas fue usado para la evaluación del Prototipo 4.

8.4. Prototipo 4 Arquitectura neuro-simbólica

El Prototipo 4 integra las capacidades del P3 con dos innovaciones arquitectónicas que definen la madurez del sistema: el agrupamiento semántico global con BERTopic como etapa *previa* a la clasificación, y la lógica de decisión neuro-simbólica que combina el razonamiento probabilístico de BETO con reglas simbólicas deterministas. La motivación central de este diseño es una premisa técnica que la experimentación del TT2 validó empíricamente: **la IA sola no es suficiente**.

8.4.1. Por qué la IA Sola No Basta: Alucinaciones de BETO

Durante las pruebas de integración del P3, se identificaron escenarios donde BETO en modo *zero-shot* producía clasificaciones erróneas con alta confianza (score > 0,70) en exactamente los casos más peligrosos para el sistema:

- **Notas estadísticas con narrativa emocional.** Artículos de opinión que describían la crisis de orfandad por feminicidio en términos generales y empáticos (“*miles de niños que perdieron a su madre*”) obtenían scores BETO de hasta 0.81, a pesar de no reportar ningún caso concreto ni identificable.
- **Notas donde el menor es el agresor.** Ante titulares como “*Hijo adolescente mata a su madre en Ecatepec*”, BETO asignaba scores de relevancia moderados (0.55–0.65) porque el embedding semántico capturaba la correlación superficial entre “hijo” + “madre” + “asesinato”, sin discernir que el rol del menor era el de agresor.
- **Reportes de políticas públicas con vocabulario de dominio.** Notas sobre programas de becas para hijos de víctimas de feminicidio activaban BETO con scores de 0.60–0.75 al concentrar exactamente los tokens de dominio más relevantes, sin relatar ningún caso específico.

Estos escenarios demuestran que un modelo de lenguaje, por sofisticado que sea, opera fundamentalmente sobre correlaciones estadísticas en el espacio de embeddings. La *comprensión* del rol semántico (quién es víctima, quién es agresor, si la nota relata un hecho o un análisis) requiere conocimiento estructurado del dominio que BETO no puede inferir exclusivamente de la distribución de tokens. La solución es la arquitectura neuro-simbólica: las reglas simbólicas (basadas en el conocimiento explícito del equipo de desarrollo sobre el dominio) **corrigen las alucinaciones** del componente neuronal.

8.4.2. BERTopic como Filtro de Contexto Global (OE-4)

Una innovación arquitectónica fundamental del P4 es la **inversión del orden** de ejecución respecto al TT1: el agrupamiento semántico (BERTopic, *step_10*) se ejecuta *antes* que la clasificación individual (BETO, *step_9*). Esta decisión de diseño responde a una necesidad de contexto: clasificar una noticia de forma aislada es inherentemente más impreciso que clasificarla sabiendo cómo se relaciona con el corpus completo del periodo.

BERTopic implementa una cadena de tres algoritmos: (1) BETO embeddings para representar cada documento en el espacio vectorial de 768 dimensiones; (2) UMAP para reducción de dimensionalidad no-lineal hacia 5 dimensiones preservando estructura topológica local; y (3) HDBSCAN para detección de clusters de densidad variable, que asigna *topic_id* = -1 a los documentos que no pertenecen a ningún clúster significativo (*outliers*). Esta etiqueta de *outlier* es la señal clave que utiliza la lógica simbólica posterior.

El criterio de umbral adaptativo basado en contexto de clúster opera así: una noticia en un **clúster válido** (*topic_id* ≥ 0) pertenece a un grupo temático identificado en el corpus; si BETO la considera relevante ($s_{sem} \geq 0,50$), la clasificación procede normalmente. Una noticia **outlier** (*topic_id* = -1) no comparte semántica con ningún grupo conocido: puede ser un caso genuinamente nuevo y urgente, o un falso positivo de BETO. Ante esta ambigüedad, el sistema simbólico *eleva el umbral de exigencia* de BETO a 0.65 para clasificarla como “Alta”, requiriendo mayor certeza del modelo neuronal antes de emitir una alerta:

Listing 8.1: Umbral adaptativo de BETO según contexto de clúster BERTopic

```
es_outlier_cluster = (topic_id_int == -1)

# Outlier: BETO debe ser mas seguro (0.65 vs. 0.50 en cluster valido)
umbral_beto_alta = 0.65 if es_outlier_cluster else 0.50
umbral_beto_rapida = 0.50 if es_outlier_cluster else 0.35
```

8.4.3. El Bypass de Oro: Decisión Simbólica Absoluta

El mecanismo de mayor prioridad en la arquitectura neuro-simbólica es el denominado **Bypass de Oro**. Su premisa es que, cuando el módulo de recolección (collector) detecta la presencia explícita de *keywords de oro* (expresiones que denotan inequívocamente orfandad por feminicidio, tales como “sus hijos quedaron huérfanos”, “resguardados por el DIF”, “bajo custodia del Sistema Nacional DIF”) y asigna un `score_victima_indirecta` ≥ 0.80 , no existe justificación técnica para someter esa noticia al juicio probabilístico de BETO. Una coincidencia de texto exacto con vocabulario de dominio es una verdad analítica más confiable que cualquier correlación vectorial en el espacio de embeddings.

El Bypass de Oro impone una clasificación de “Alta” relevancia de forma **incondicional**, ignorando completamente el score semántico:

Listing 8.2: Bypass de Oro: la regla simbólica anula la decisión de BETO

```
# Nivel 0: BYPASS DE ORO (independiente de BETO)
# score_v_ind >= 0.80 implica que _check_keywords_de_oro() fue True
# en el collector: presencia de vocabulario de orfandad explícita.
# BETO no tiene jurisdicción en este caso.
es_bypass_oro = (
    score_v_ind >= 0.80 and # Keywords de oro confirmadas
    score_fem > 0.10 # Contexto de feminicidio presente
)

if es_bypass_oro:
    clasificacion = "Alta"
    score_final = max(h_score, 0.85)
    logger.info(
        f"Bypass de Oro: v_ind={score_v_ind:.2f}, "
        f"fem={score_fem:.2f} -> Alta (BETO ignorado)"
    )
```

El Bypass de Oro resuelve directamente el escenario de falla más costoso: una noticia donde la redacción periodística es atípica o ambigua puede obtener un score BETO bajo (por ejemplo, 0.40), pero si el collector confirmó textualmente la orfandad, el sistema debe clasificarla como “Alta” de todas formas. La regla simbólica protege al sistema de rechazar casos reales por limitaciones del modelo neuronal ante estilos de escritura no canónicos.

8.4.4. El Bozal de Penalización: El Contexto de Clúster como Corrector

El mecanismo complementario al Bypass de Oro actúa en la dirección opuesta: el **Bozal de Penalización** suprime clasificaciones elevadas de BETO cuando el contexto semántico global (provisto por BERTopic) y los scores heurísticos del collector indican que la noticia es probablemente un falso positivo. Este mecanismo se activa cuando una nota es *outlier* de BERTopic (`topic_id = -1`) y el score heurístico de víctima indirecta es bajo ($s_{v_ind} \leq 0.25$), pero BETO asigna un score moderado (por ejemplo, 0.55). En ese caso, la lógica simbólica interpreta la señal combinada como ruido y eleva el umbral de BETO de 0.50 a 0.65 para clasificar como “Alta”, efectivamente *amordazando* la tendencia de BETO a sobre-clasificar.

La siguiente tabla resume los niveles de la lógica neuro-simbólica y sus condiciones de activación:

Tabla 8.1: Árbol de decisión neuro-simbólico del Prototipo 4

Nivel	Condición de activación	Acción	Tipo
0	$s_{v.ind} \geq 0,80$ y $s_{fem} > 0,10$	Clasificar “Alta” incondicionalmente	Simbólico
0.5	$h_{score} \geq 0,70$ y $s_{fem} > 0,15$ y $(s_{v.ind} > 0,25$ o $s_{nna} > 0,25)$	Respetar clasificación “Alta” del collector	Simbólico
1	$s_{fem} > 0,15$ y $s_{v.ind} > 0,25$ y $s_{caso} > 0,15$ y $s_{sem} > \theta_{alta}$	Clasificar “Alta” (ruta principal)	Híbrido
2	$s_{v.ind} > 0,40$ y $s_{fem} > 0,15$ y $s_{sem} > \theta_{rapida}$	Clasificar “Alta” (vía rápida)	Híbrido
3	Resto de casos	Clasificar por $score_final$ ponderado (α)	Neuronal

Donde $\theta_{alta} = 0,65$ si $topic_id = -1$, $0,50$ en caso contrario.

Donde $\theta_{rapida} = 0,50$ si $topic_id = -1$, $0,35$ en caso contrario.

8.4.5. El Factor Alpha Dinámico: Fusión Neuro-Simbólica para Casos Ambiguos

Para la mayoría estadística de noticias que no activan ninguno de los niveles simbólicos anteriores (casos genuinamente ambiguos), el sistema computa un **score final ponderado** que combina el veredicto probabilístico de BETO (s_{sem}) con el score heurístico del collector (h_{score}) mediante un coeficiente α determinado dinámicamente por la *distancia de BETO a la frontera de incertidumbre máxima* (0.50):

Listing 8.3: Factor α dinámico: BETO cede peso a la heurística cuando titubea

Distancia a la frontera de maxima incertidumbre (0.5)

distance = **abs**(s.score - 0.5)

if distance > 0.3:

alpha = 0.7 # BETO muy seguro (score<0.2 o >0.8): mayor peso semantico

elif distance > 0.15:

alpha = 0.5 # Confianza moderada: ponderacion equitativa

else:

alpha = 0.3 # BETO indeciso (score en 0.35–0.65): delegar a heuristica

Fusion ponderada

score_final = (alpha * s.score) + ((1 - alpha) * h.score)

La racionalidad de este diseño es la siguiente: cuando BETO produce un score de 0.90 (distance=0.40), el modelo tiene alta confianza en la clasificación positiva y se le asigna peso mayoritario ($\alpha = 0,7$). Cuando produce 0.52 (distance=0.02), BETO está esencialmente lanzando una moneda; en ese caso, el sistema otorga el peso mayoritario ($1 - \alpha = 0,7$) al score heurístico, que aunque menos sofisticado, es determinista y auditablemente correcto para los patrones de dominio conocidos. Esta transición suave entre “confiar en la IA” y “confiar en las reglas” es la esencia del paradigma neuro-simbólico.

8.4.6. Investigador Profundo: DuckDuckGo y Gemini Flash

Una de las decisiones de diseño más importantes del Prototipo 4 fue la de **no integrar la investigación profunda dentro del flujo recolector-analítico automático**. Esta decisión, que en un principio parecía una limitación, resultó ser la solución arquitectónicamente correcta después de intentar lo contrario.

El problema de integrar la investigación en el pipeline automático

Durante el desarrollo inicial del P4, la primera propuesta consistía en ejecutar una investigación profunda automáticamente sobre cada noticia clasificada como “Alta” al finalizar el paso 9. El módulo DeepInvestigator realizaría búsquedas web y sintetizaría la ficha de caso sin intervención del usuario. Sin embargo, al implementar un prototipo de esta integración se encontraron tres problemas inmediatos:

1. **Latencia no tolerable.** Cada investigación implica al menos dos llamadas a DuckDuckGo (búsqueda + extracción de contenido de las URLs retornadas), seguidas de dos llamadas a la API de Gemini Flash (generación de query y síntesis del JSON final). En pruebas con un corpus de 80 noticias de “Alta” relevancia, el pipeline tardaba entre 45 y 90 minutos adicionales, lo que hacía el ciclo de análisis inviable para uso cotidiano.
2. **Costo de API desproporcionado.** La API de Google Gemini tiene límites de cuota en el plan gratuito (por minuto y por día). Investigar automáticamente todas las noticias “Alta” saturaba la cuota en el primer tercio del corpus, dejando el resto sin investigación y generando errores silenciosos que corrompían los registros de la base de datos.
3. **Irrelevancia del 40 % de los casos.** Al revisar manualmente los resultados de la investigación automática, se determinó que aproximadamente el 40 % de las noticias clasificadas como “Alta” eran casos que el investigador ya conocía o que no requerían seguimiento activo. Investigar esos casos automáticamente era desperdicio de cómputo y cuota.

La solución: investigación interactiva bajo demanda

Ante estos problemas, se adoptó un diseño **reactivo e interactivo**: el DeepInvestigator se convierte en una herramienta que el investigador activa manualmente sobre una noticia específica desde el dashboard, una vez que ha revisado su score y decidido que merece profundización. Esta decisión corrige los tres problemas anteriores de forma directa: (a) la latencia pasa de ser un problema de pipeline a una operación asíncrona en segundo plano (background thread) que no bloquea la interfaz; (b) el costo de API queda acotado a los casos que el investigador considera prioritarios; (c) se elimina el desperdicio computacional de investigar casos ya conocidos.

El flujo de interacción implementado en el endpoint POST `/api/investigate/{noticia_id}` y su par de consulta de estado GET `/api/investigate/status/{noticia_id}` funciona así:

Listing 8.4: Flujo asíncrono del DeepInvestigator desde el dashboard

```
# El usuario hace clic en "Investigar" desde la ficha de la noticia
# El endpoint lanza el investigador en un hilo daemon
thread = threading.Thread(
    target=_run_investigation_bg ,
    args=(noticia_id , noticia.titulo , noticia.contenido , app),
    daemon=True ,
)
thread.start()
# Respuesta inmediata: {"status": "started"}
# El frontend consulta /api/investigate/status/{id}
# hasta recibir {"status": "done", "result": {...}}
```

Módulo de investigación profunda

Una vez activado el módulo DeepInvestigator (`src/analysis/investigator.py`) ejecutará cuatro pasos secuenciales:

1. **Generación de query (Gemini Flash).** El modelo recibe el título y los primeros párrafos de la noticia y genera una *frase de búsqueda de alta especificidad* (máximo 6 palabras) que incluya el nombre de la víctima y detalles únicos del caso. Esta query es preferible al título literal porque filtra resultados genéricos sobre la misma temática pero de distinto evento.
2. **Búsqueda en DuckDuckGo.** La query se envía tanto a la versión HTML de DuckDuckGo (`html.duckduckgo.com`) como a la versión Lite (`lite.duckduckgo.com`) para maximizar la cobertura ante bloqueos intermitentes. Las URLs retornadas se limpian para eliminar redirecciones internas de DDG (`uddg=` en los query strings).
3. **Scraping de contenido complementario.** Para cada URL retornada por DDG, `StealthSession` extrae el texto del artículo, filtrando ruido HTML (`<nav>`, `<footer>`, scripts y formularios). El texto de todas las fuentes se concatena en un bloque único (hasta 15,000 caracteres) que funciona como contexto enriquecido.
4. **Síntesis estructurada (Gemini Flash).** El bloque de texto multi-fuente se envía a Gemini con un prompt de analista criminal especializado en derechos de la infancia. La respuesta es un JSON estricto con siete campos: `ubicacion`, `victimas`, `nios_afectados`, `edades`, `situacion_actual`, `medios_contacto` y `resumen`. El campo `medios_contacto` es especialmente relevante pues Gemini infiere el DIF municipal o la Fiscalía del estado según la ubicación del caso, incluso cuando el texto no los menciona explícitamente.

Cuando DuckDuckGo no retorna URLs utilizables (por bloqueo o ausencia de resultados), el módulo activa un **fallback de búsqueda nativa de Gemini**: la API utiliza el herramienta `GoogleSearch` nativa del modelo (disponible en `gemini-2.5-flash`) para realizar la búsqueda internamente sin necesidad de scraping externo, representando el último recurso antes de retornar un error.

El módulo de identificación por enlace externo

El segundo caso de uso del `DeepInvestigator` resuelve una necesidad práctica identificada durante las pruebas de campo: ¿qué ocurre cuando el investigador encuentra una noticia relevante navegando en la web que el pipeline *no detectó*?

El endpoint `POST /api/identify-link` recibe una URL externa y ejecuta el siguiente flujo:

1. **Extracción de contenido.** `StealthSession` accede a la URL y extrae el texto del artículo con las mismas técnicas de limpieza que el scraper principal.
2. **Validación del contenido (Gemini Flash).** Antes de continuar, se le pide a Gemini que genere un título corto del artículo. Si Gemini devuelve `NOTICIA_INVALIDA` (porque la URL apunta a un aviso de cookies, un error 403 o una página de inicio sin contenido), el endpoint retorna un error descriptivo sin continuar. Este paso ahorra llamadas API innecesarias.
3. **Investigación completa.** Si el contenido es válido, se reutiliza directamente el método `investigate(title, content)`, ejecutando los cuatro pasos de generación de query, búsqueda DDG, scraping multi-fuente y síntesis Gemini.

Este módulo es técnicamente una **reutilización completa del pipeline de investigación** con un preprocesamiento adicional de validación. Su existencia resuelve la limitación 4 identificada en la sección anterior: el investigador puede incorporar al sistema cualquier noticia que el flujo automático no haya capturado, aprovechando la misma infraestructura de extracción estructurada.

La siguiente tabla resume los dos casos de uso del módulo y sus endpoints correspondientes:

Tabla 8.2: Casos de uso del módulo DeepInvestigator

Caso de uso	Endpoint	Descripción
Investigación bajo demanda	POST /api/investigate/{id}	El investigador selecciona una noticia del dashboard con score “Alta” y activa la ficha de caso estructurada.
Consulta de estado	GET /api/investigate/status/{id}	El frontend consulta el estado del hilo de investigación (running, done, error).
Identificación de enlace externo	POST /api/identify-link	El investigador pega la URL de una noticia no detectada por el pipeline; el sistema la investiga y devuelve la ficha estructurada.
Seguimiento de casos	POST /api/seguimiento/add/{id}	Agrega una noticia investigada a la lista de seguimiento activo.
Exportación de seguimiento	GET /api/seguimiento/export/{id}	Exporta todos los casos en seguimiento con sus fichas de investigación a un archivo CSV enriquecido.

8.5. Síntesis: El Pipeline v5.0 como Sistema de Doble Árbol

La arquitectura final del Prototipo 4 puede describirse como un **sistema de doble árbol**: un árbol neuronal (BETO + BERTopic) que provee razonamiento probabilístico sobre el lenguaje natural, y un árbol simbólico (Bypass de Oro + Bozal + umbrales adaptativos) que corrige las alucinaciones del árbol neuronal utilizando conocimiento estructurado del dominio. Ninguno de los dos árboles opera en aislamiento; su interacción es el mecanismo que permite al sistema superar las limitaciones individuales de cada paradigma.

La siguiente tabla sintetiza los once pasos del Pipeline v5.0 con su objetivo específico, componente implementado y tipo de operación:

Tabla 8.3: Pipeline v5.0: síntesis de los once pasos de análisis

Paso	Objetivo	Componente	Prototipo
1	Recolección multi-fuente	<code>collect_all_news()</code> (RSS+GNews+HTML)	P2/P3
2	Persistencia inicial	CSV intermedio <code>noticias_raw.csv</code>	P1
3	Vectorización TF-IDF	<code>TfidfVectorizer</code> (domain-boosted, n-grams)	P1
4	(Desactivado)	LDA — reemplazado por <code>BERTopic</code>	P1*
5	(Desactivado)	K-Means — reemplazado por <code>BERTopic</code>	P1*
6	Similitud + Deduplicación	<code>NewsDeduplicator</code> (4 fases en cascada)	P3
7	(Eliminado)	TF-IDF rescore — destruía clasificaciones “Alta”	P2†
8	Búsqueda con sinónimos	<code>SynonymDictionary</code>	P2
10	Contexto global <code>BERTopic</code>	BETO embeds + UMAP + HDBSCAN + c-TF-IDF	P4
9	Clasificación semántica	<code>SemanticDetector</code> + lógica neuro-simbólica	P3/P4
11	Persistencia relacional	<code>NoticiasRepository</code> (PostgreSQL + FTS GIN)	P3

* LDA y K-Means desactivados por redundancia con `BERTopic` (OE-4).

† El *TF-IDF rescore* del paso 7 fue eliminado durante el TT2 tras identificar que el blend 60/40 con el score heurístico sobreescribía las clasificaciones “Alta” genuinas con valores artificialmente atenuados, constituyendo un bug de precisión crítico documentado en los registros de depuración del batch 20260505_141233.

Nota sobre el orden de ejecución. El lector observará que el paso 10 (`BERTopic`) se ejecuta *antes* del paso 9 (BETO), a pesar de su numeración inversa. Este aparente desorden es intencional y documentado en el código fuente: la numeración original del pipeline reservaba el paso 9 para BETO y el paso 10 para clustering, pero la inversión de orden fue introducida en el P4 sin renumerar los pasos para preservar la compatibilidad con pruebas y logs previos. Esta decisión de ingeniería, aunque genera confusión inicial en la lectura del código, fue preservada deliberadamente como evidencia del proceso evolutivo del sistema.

8.6. Diagrama Conceptual del Sistema

La arquitectura completa del Pipeline v5.0 puede representarse mediante el siguiente flujo de datos, descrito para su posterior implementación en TikZ o Mermaid:

Nivel 1 — Recolección (P2/P3): Tres canales de entrada convergen en el collector: feeds RSS (45 fuentes), Google News API (14 queries), y scraping HTML con `StealthSession v7.0`. El módulo de deduplicación (4 fases) filtra el corpus antes de cualquier análisis.

-
- Nivel 2 — Vectorización Clásica (P1):** TF-IDF domain-boosted genera la matriz dispersa utilizada por la similitud coseno para detección de documentos relacionados.
- Nivel 3 — Contexto Global (P4):** BERTopic procesa **todo el corpus** y asigna `topic_id` a cada noticia. Las noticias sin clúster (`topic_id = -1`) reciben la etiqueta *outlier*.
- Nivel 4 — Clasificación Neuro-Simbólica (P3/P4):** El árbol de decisión evalúa cada noticia en secuencia: (1) Bypass de Oro → (2) Collector Alta → (3) Condición estricta con BETO+clúster → (4) Vía Rápida → (5) Fusión α dinámica.
- Nivel 5 — Persistencia (P3):** Los resultados se almacenan simultáneamente en CSV (compatibilidad) y PostgreSQL (FTS, integridad referencial, acceso concurrente desde el dashboard Flask).
- Nivel 6 — Dashboard e Investigación Profunda (P4):** El investigador accede al dashboard Flask que expone los resultados del pipeline. Sobre cualquier noticia clasificada como “Alta”, puede activar el DeepInvestigator que ejecuta en paralelo: (1) Gemini Flash genera una query específica del caso; (2) DuckDuckGo retorna URLs de fuentes complementarias; (3) StealthSession extrae el contenido de cada fuente; y (4) Gemini Flash sintetiza una ficha JSON estructurada. Adicionalmente, si el investigador detecta una noticia relevante no capturada por el pipeline, puede proporcionar su URL directamente al módulo de identificación por enlace externo, reutilizando el mismo pipeline de investigación. Los casos que requieren monitoreo continuo se agregan a la lista de seguimiento activo, exportable como CSV enriquecido.

8.7. Verificación, Validación y Pruebas (QA)

Para garantizar la fiabilidad, exactitud algorítmica y tolerancia a fallos del *Sistema Inteligente para la Identificación de NNA*, se diseñó una estrategia de Aseguramiento de Calidad (QA) exhaustiva. Esta estrategia combina pruebas de caja blanca para verificar la lógica interna de los componentes computacionales y pruebas de caja negra para validar el comportamiento del sistema ante datos de entrada adversarios o estadísticamente ruidosos.

8.7.1. Pruebas Unitarias y Aislamiento de Componentes

Se implementó el marco de trabajo `pytest` en conjunto con la biblioteca estándar `unittest.mock` para lograr un aislamiento completo de las unidades lógicas del sistema. La directriz arquitectónica de estas pruebas consistió en eliminar cualquier dependencia estocástica, de red o de hardware especializado, garantizando que el entorno de pruebas sea determinista, veloz y apto para flujos de Integración Continua (CI).

Mocking del Modelo BETO (Sin GPU):

Uno de los mayores desafíos técnicos consistió en auditar la lógica del módulo `SemanticDetector` sin obligar al servidor de pruebas a instanciar los tensores pre-entrenados de *PyTorch* (que exceden 1 GB de memoria) ni depender de aceleración por tarjeta gráfica (GPU). Para solventarlo, se aplicó la inyección de dependencias mediante el decorador `@patch`, simulando (*mockeando*) el comportamiento interno de las clases `AutoTokenizer` y `AutoModel`. Al interceptar la inicialización, se comprobó matemáticamente el comportamiento de funciones clave como el cálculo del *Temperature Scaling* y la asignación del nivel de confianza sin ejecutar una sola inferencia neuronal real.

Simulación de Tráfico de Red:

En los módulos `DeepInvestigator` y `Collector`, se sustituyeron las llamadas HTTP (`StealthSession`) y las peticiones externas a la API de Inteligencia Artificial (*Gemini*) por objetos `MagicMock`. Mediante el atributo `side_effect`, se indujeron intencionalmente escenarios de falla como `Timeout`, errores HTTP 404 o cuotas de API excedidas. Esto permitió validar que el sistema ejecuta correctamente los protocolos de recuperación (*Fallback*) sin interrumpir su ejecución.

8.7.2. Pruebas de Caja Negra: Validación del Bozal de Penalización

La arquitectura Neuro-Simbólica introdujo un mecanismo de lógica dura (RegEx heurístico) denominado "Bozal de Penalización". Su objetivo fundacional es mitigar las denominadas "Fugas de Confianza", es decir, falsos positivos causados porque la Inteligencia Artificial pura confunde contextos semánticos altamente similares.

Para comprobar su robustez, se diseñó un banco de pruebas de caja negra aislado (`test_golden_keywords.py`) donde se inyectaron Casos Negativos^a adversarios. El reto principal fue suministrar noticias reales sobre menores infractores (ej. "*Menor de edad asesina a su madre en Guadalajara*").

Una red neuronal basada en atención (*Transformers*) marcaría esta noticia con una relevancia altísima, ya que la similitud espacial de los vectores (*menor, madre, asesina*) es idéntica a la de un caso de orfandad real. Sin embargo, los tests demostraron que el motor heurístico evaluó la direccionalidad sintáctica de las "Palabras de Oro". Al identificar que el "menor" figuraba como el sujeto activo del delito (agresor) y no como el objeto directo (víctima indirecta), el sistema multiplicó el factor α de fusión por un valor casi nulo. El Bozal de Penalización operó con un **100 % de efectividad**, bloqueando el flujo semántico y clasificando correctamente los casos adversarios como irrelevantes.

8.7.3. Matriz de Casos de Prueba

A continuación, se resume una fracción representativa del reporte de pruebas automatizadas ejecutadas contra el núcleo del sistema, evidenciando los criterios de aceptación esperados y los resultados obtenidos.

ID	Descripción de la Prueba	Entrada Simulada / Esperada	Resultado Obtenido	Status
CP-01	Extracción segura de HTML (<i>Mock</i>)	Petición a URL devuelve HTTP 200 OK con texto ¿200 caracteres.	Retorna un <i>String</i> validado sin levantar excepciones.	PASS
CP-02	Resiliencia ante caída de conexión	Petición HTTP a URL inyecta un <code>Exception("Timeout")</code> .	Retorna <i>String</i> vacío, el flujo no colapsa.	PASS
CP-03	Mocking de Inferencia BETO	Carga de <code>SemanticDetector</code> en modo <code>zero_shot</code> .	Instancia en memoria RAM sin cargar tensores de GPU.	PASS
CP-04	Cálculo de Confianza Alta	Entrada simulada de predicción matricial (<code>score = 0.85</code>).	El método clasificador retorna la etiqueta <code>.alta</code> .	PASS
CP-05	Fallback de IA Limitada	<i>Gemini API</i> inyecta <code>Quota Exceeded Error</code> .	El sistema extrae <code>*keywords*</code> haciendo Fallback al título.	PASS
CP-06	Bozal: Falso Positivo (Agresor)	Entrada de texto adversario: <i>"Menor de edad asesina a su madre"</i> .	El Bozal descarta la activación de Keywords de Oro.	PASS
CP-07	Bozal: Falso Positivo (Estadística)	Texto genérico: <i>Cifras oficiales de feminicidio en México.</i>	El sistema descarta la noticia (No se detectan NNA).	PASS
CP-08	Bozal: Verdadero Positivo	Texto real: <i>"Doble feminicidio deja a dos niños en orfandad."</i>	La fusión heurística y neuronal clasifica como Alta.	PASS

Tabla 8.4: Matriz de Casos de Prueba Críticos y Resultados de Ejecución.

Resultados y Evaluación

Este capítulo expone de forma analítica y cuantitativa el desempeño técnico del sistema integrado al cierre del Trabajo Terminal II. Se demuestra empíricamente la superioridad de la arquitectura neuro-simbólica (Prototipo 4) frente a los resultados obtenidos mediante las heurísticas tradicionales del primer semestre. La evaluación se fundamenta en métricas extraídas directamente de una corrida de producción en el entorno de despliegue final.

9.1. Evaluación de la Recolección (Volumen de Ingesta)

La migración hacia un esquema de recolección dinámico apoyado por *StealthSessions* y consultas históricas programáticas detonó un incremento exponencial en la capacidad de ingesta del sistema.

Durante el ciclo de pruebas final, el módulo colector procesó y deduplicó exitosamente un lote masivo de **627 noticias únicas** en un solo bloque de ejecución continuo. Este hito operativo representa un aumento superior al 220 % en contraste directo con el rendimiento del TT1, el cual apenas logró compilar 281 noticias a lo largo de múltiples semanas de recolección pasiva. El éxito en la ingesta valida categóricamente la robustez de la arquitectura frente a los bloqueos de *Firewalls* comerciales y certifica la resiliencia de la deduplicación *cross-site* al mantener la base de datos libre de redundancia periodística.

9.2. Evaluación de la Detección Semántica (Filtro del Embudo)

El desafío principal del proyecto no radicaba únicamente en recolectar información, sino en discriminarla con alta precisión. De la muestra total de 627 noticias, la fase de filtrado preliminar determinó que **225 artículos** contenían menciones explícitas a "Niñas, Niños y Adolescentes"(NNA) en las proximidades semánticas de crímenes violentos (véase Figura 9.1).

Posteriormente, este subconjunto fue inyectado al motor de inferencia neuronal BETO bajo el esquema del "Árbol Inquebrantable". Los resultados del embudo analítico fueron sobresalientes:

- **75 noticias de Alta Relevancia:** Casos fácticos innegables de orfandad por feminicidio, validados por la IA y priorizados por el "Bypass Simbólico".




Figura 9.1: Métricas de filtrado preliminar en el Dashboard Web.

- **53 noticias de Media Relevancia:** Reportes donde el contexto sugiere vulnerabilidad infantil colateral o casos en desarrollo.

Es crítico destacar la efectividad del mecanismo denominado "Bozal de Penalización". Este estrato lógico descartó de forma autónoma casi un centenar de noticias basura y falsos positivos recurrentes del TT1 (como menores infractores o reportes macroestadísticos), protegiendo la carga cognitiva del usuario final y demostrando la asertividad matemática de la fusión neuro-simbólica.

9.3. Evaluación del Agrupamiento (BERTopic)

La inclusión del modelo topológico BERTopic resolvió de manera definitiva el problema histórico de fragmentación analítica. Al operar sobre la base de datos curada, el algoritmo logró comprimir el caos informativo en exactamente **15 Grupos Temáticos** altamente cohesivos.

A diferencia del ruido generado previamente por *K-Means*, estos 15 clústeres demostraron una congruencia humana excepcional. El sistema agrupó de manera autónoma narrativas periodísticas complejas, creando clústeres no solo basados en el nombre de la víctima o ubicación geográfica, sino en la semántica del evento, tales como: disputas legales por custodia, manifestaciones y exigencias de justicia colectiva, o crónicas sobre el impacto psicológico en las víctimas indirectas.

9.4. Análisis de la Interfaz (UI/UX) e Impacto Operativo

La evaluación final del sistema trasciende las métricas computacionales y se sitúa en la usabilidad operativa para los actores de la sociedad civil. La interfaz del *Dashboard Web* fue concebida bajo principios de jerarquía visual.

Como se observa en la Figura 9.2, la plataforma dota a cada registro de *tags* visuales distintivos (por ejemplo, etiquetas verdes brillantes para "NNAz "Feminicidio") junto con sus respectivos porcentajes probabilísticos de certidumbre calculados por BETO. Esta arquitectura de la información permite a los analistas de fundaciones, como *Futuro con Derechos*, realizar un barrido visual (*skimming*) inmediato sobre un clúster de noticias. Lo que históricamente representaba una inversión de docenas de horas-hombre navegando entre pestañas de navegadores, buscando manualmente

coincidencias textuales, ha sido optimizado por el Prototipo 4 a una revisión jerárquica y determinista que exige apenas un par de segundos por evento fáctico.




Figura 9.2: Visualización jerárquica de noticias de Alta Relevancia en el Dashboard.

Conclusiones

El desarrollo y culminación del *Sistema Inteligente para la Identificación y Seguimiento de NNA* ratifica de manera categórica e innegable el cumplimiento íntegro de los objetivos tecnológicos y sociales delineados en el protocolo de registro 2026-A135. El ciclo de vida de este proyecto atestiguó la metamorfosis de un planteamiento computacionalmente frágil, fundamentado en el análisis sintáctico lineal y el almacenamiento plano, hacia una plataforma neuro-simbólica de grado de producción, dotada de bases de datos transaccionales, infraestructura *anti-bot* y visualización analítica avanzada.

El hallazgo arquitectónico de mayor trascendencia emanado de esta investigación reside en el entendimiento empírico de las limitantes de la Inteligencia Artificial moderna frente al caos del lenguaje periodístico humano. Durante la fase experimental, quedó demostrado que depender exclusivamente del conexionismo puro de los modelos de lenguaje masivos, como los *Transformers* (BETO), resulta insuficiente para un despliegue sin supervisión. Estas arquitecturas neuronales sufren de "fugas de confianza" ante narrativas semánticamente difusas, provocando alucinaciones estructurales, tales como confundir a un adolescente que comete un feminicidio con un menor de edad que ha quedado en orfandad tras el asesinato de su madre.

La respuesta definitiva a este escollo técnico fue la conceptualización y despliegue exitoso de la Arquitectura Neuro-Simbólica. Se demostró que al injertar la estricta rigurosidad del simbolismo algorítmico tradicional (mecanismos de "Bypass" heurístico y el "Bozal de Penalización") como guardianes controladores de la inferencia neuronal, el sistema adquiere una resiliencia formidable. Esta fusión logró amalgamar la flexibilidad cognitiva de BETO con el determinismo inquebrantable de la lógica condicional, abatiendo la tasa de falsos positivos a márgenes históricamente bajos (cerca de cero) y estableciendo un nuevo estándar metodológico para la lectura automatizada de notas fácticas de extrema sensibilidad.

Más allá de la complejidad del código y las optimizaciones matemáticas en el espacio hiperdimensional de BERTopic, el éxito supremo de este Trabajo Terminal II se materializa en su impacto social directo. La solución entregada trasciende el entorno académico para convertirse en una herramienta de alivio operativo real. Organizaciones civiles y colectivos defensores de los derechos humanos, como la fundación *Futuro con Derechos*, quedan liberadas del agotador desgaste psicológico y logístico que impone la curaduría manual de la prensa roja. Al automatizar la recolección, deduplicación y clasificación de los eventos de orfandad, el sistema reduce intervenciones manuales de horas o días a escasos segundos, proveyendo bases de datos estructuradas que habilitan una acción rápida, priorizada y estratégicamente focalizada sobre las víctimas.

Finalmente, este proyecto reafirma una de las máximas más nobles de la ingeniería de sistemas: el poder compu-

tacional carece de valor si no está anclado en el profundo respeto por la dignidad humana. A pesar de procesar e ingerir volúmenes masivos de datos periodísticos a velocidades maquinales, contabilizar tragedias y clústeres geográficos, el sistema se diseñó bajo una inquebrantable doctrina de privacidad *by design*. La arquitectura clasifica, cuantifica y visibiliza la urgencia de los menores, pero jamás expone sus nombres ni vulnera su derecho inalienable a la privacidad, operando en absoluta consonancia con los más altos estándares de la ética informática y la protección integral de las infancias vulneradas en México.

A pesar de la madurez tecnológica alcanzada por la arquitectura neuro-simbólica y la culminación exitosa de los prototipos delineados en el Trabajo Terminal II, la magnitud y urgencia del problema social abordado exigen una visión de escalabilidad continua. Este capítulo traza la hoja de ruta técnica a mediano y largo plazo, proponiendo las optimizaciones e integraciones de *software* necesarias para transicionar el sistema de un entorno de validación hacia una infraestructura operativa a nivel nacional.

11.1. Extracción de Entidades Nombradas (NER) bajo Principios Éticos

El siguiente hito evolutivo en el procesamiento de lenguaje natural del sistema consiste en la implementación de un módulo robusto de Extracción de Entidades Nombradas (NER, por sus siglas en inglés). Si bien BETO y BERTopic otorgan comprensión y contexto a nivel de documento, es imperativo extraer la granularidad de los actores involucrados. Se propone realizar un *fine-tuning* sobre arquitecturas especializadas como *spaCy* o integrar Modelos de Lenguaje de Gran Escala (LLMs) para minar entidades críticas como nombres de municipios, autoridades judiciales a cargo (jueces, fiscales) e instituciones gubernamentales responsables (e.g., el Desarrollo Integral de la Familia, DIF).

Sin embargo, el rasgo distintivo de esta futura implementación será su diseño *ético por defecto*. El módulo NER deberá ser programado con heurísticas de enmascaramiento estricto para ignorar, ofuscar o destruir deliberadamente cualquier token clasificado como nombre propio de un menor de edad. De este modo, se garantiza la extracción de inteligencia táctica para el seguimiento institucional, blindando al mismo tiempo la identidad y la integridad de las víctimas indirectas contra cualquier exposición accidental en las bases de datos.

11.2. Generación Automática de Reportes (Exportación)

El tablero interactivo actual posee un alto valor para el análisis en tiempo real, pero el trabajo de defensa de derechos humanos requiere materialización documental. El desarrollo futuro debe contemplar la creación de un subsistema de renderizado para la generación de expedientes descargables en formatos estandarizados, como PDF y hojas de cálculo (Excel).

Esta capacidad de exportación automatizada dotará a las organizaciones civiles de una herramienta formidable. Podrán transformar instantáneamente los clústeres semánticos de BERTopic y las métricas de BETO en expedientes

impresos, proveyendo evidencia estadística sólida y curada que puede ser directamente presentada ante comisiones legislativas, mesas de trabajo interinstitucionales o tribunales, eliminando las horas de transcripción manual que sufren los trabajadores sociales.

11.3. API Pública e Interoperabilidad para Organizaciones Civiles

La verdadera democratización de la tecnología radica en su interoperabilidad. Actualmente, el ecosistema funciona como un monolito cerrado al exterior, donde el usuario debe ingresar forzosamente al *Dashboard* visual. Como trabajo a mediano plazo, se proyecta el desarrollo de una Interfaz de Programación de Aplicaciones (API) pública, implementada bajo el estándar RESTful o a través de GraphQL, protegida mediante autenticación robusta (OAuth 2.0).

La apertura de esta API permitirá que fundaciones como *Futuro con Derechos* conecten sus propios sistemas internos, aplicaciones móviles o bases de datos directamente a nuestro núcleo neuro-simbólico. En lugar de adaptar sus flujos de trabajo a nuestra plataforma, podrán consumir bajo demanda los datos deduplicados, clasificados y libres de ruido, integrando la inteligencia de NNA directamente en los tableros propietarios que ya dominan y operan diariamente.

11.4. Despliegue en la Nube (Cloud Architecture) y Escalabilidad

El entorno de ejecución presente depende de la contenerización local en *Docker*, lo cual restringe el poder de cómputo a los fierros del servidor anfitrión. Para sostener un monitoreo ininterrumpido sobre cientos de fuentes de todo el país, la arquitectura debe migrar obligatoriamente hacia una infraestructura de nube pública, como Amazon Web Services (AWS) o Google Cloud Platform (GCP).

Esta transición arquitectónica habilitará el uso de bases de datos relacionales completamente gestionadas y replicadas, como Amazon RDS para PostgreSQL, garantizando tolerancia a fallos y copias de seguridad continuas. Asimismo, la orquestación del núcleo de inteligencia artificial se verá profundamente beneficiada. Desplegar los pesados modelos de tensores de BETO y BERTopic bajo servicios de elasticidad computacional permitiría asignar Unidades de Procesamiento Gráfico (GPUs) bajo demanda, escalando la capacidad del análisis semántico automáticamente durante picos de contingencia noticiosa, y apagando los recursos cuando el flujo informativo disminuya, optimizando dramáticamente los costos operativos.

11.5. Validación Piloto en Campo y Refinamiento UX/UI

Finalmente, la culminación de cualquier herramienta de *software* con impacto social no ocurre en el repositorio de código, sino en las manos de sus usuarios. El trabajo futuro ineludible consiste en sacar el sistema del entorno académico y someterlo a pruebas piloto exhaustivas directamente en campo.

El despliegue en fase *beta* con los trabajadores sociales, psicólogos y analistas de datos de las Organizaciones No Gubernamentales resulta indispensable. Solo a través del monitoreo de su interacción diaria se podrán capturar las métricas cualitativas necesarias para afinar la Experiencia de Usuario (UX) y la Interfaz de Usuario (UI). Comprender cómo leen los clústeres, qué información necesitan de un vistazo y qué botones resultan confusos, es el paso final para transformar este modelo de ingeniería en un aliado transparente y natural en la lucha diaria por la protección de las infancias en México.